

Conocimiento y Razonamiento Aproximado

Tema 1. Introducción

MARI CARMEN GARRIDO CARRERA

RODRIGO MARTÍNEZ BÉJAR

MERCEDES VALDÉS VELA

CIENCIA DE LA COMPUTACIÓN E INTELIGENCIA ARTIFICIAL

DEPT. INGENIERÍA DE LA INFORMACIÓN Y LAS COMUNICACIONES

Universidad de Murcia

Máster en Inteligencia Artificial

2026/2027



1. Razonamiento con Modelos Ontológicos.
2. Razonamiento Aproximado Basado en Lógica Difusa.
3. Aprendizaje de Modelos Difusos desde Datos.
4. Razonamiento Aproximado con Incertidumbre.
5. Aprendizaje de Modelos con Incertidumbre desde Datos.
6. Conexión con Asignaturas de GII.
7. Puntos de Conexión con Asignaturas de MIA.

1. **Razonamiento con Modelos Ontológicos.**
2. Razonamiento Aproximado Basado en Lógica Difusa.
3. Aprendizaje de Modelos Difusos desde Datos.
4. Razonamiento Aproximado con Incertidumbre.
5. Aprendizaje de Modelos con Incertidumbre desde Datos.
6. Conexión con Asignaturas de GII.
7. Puntos de Conexión con Asignaturas de MIA.

Representación del Conocimiento

- ▶ Una buena representación de los datos, la información y el conocimiento son cruciales para el éxito del sistema inteligente en la resolución de tarea para la que se creó.
- ▶ La Representación del Conocimiento es un área de la IA que se ocupa de las técnicas para codificar el conocimiento humano para que pueda utilizarse computacionalmente.

Esquemas de Representación

- ▶ El conocimiento se puede representar siguiendo distintos **esquemas de representación**
- ▶ Establecen una **sintaxis** y una **semántica** para la obtención de estructuras que representarán una fragmento del dominio de conocimiento.
- ▶ La sintaxis describe los símbolos y las reglas para combinarlos en estructuras válidas.
- ▶ La semántica determina el significado de las estructuras y su referente en el dominio real.

Propiedades de los Esquemas de Representación


- ▶ Expresividad suficiente para representar todo el conocimiento del dominio en cuestión y todos los detalles necesarios para resolver el problema.
- ▶ **Capacidad de inferencia (razonamiento)** de nuevas estructuras a partir de las que existen e incorporar mecanismos para que esta inferencia sea lo más eficiente posible computacionalmente.
- ▶ Incorporación sencilla de nuevo conocimiento.
- ▶ Claro, natural y modular.

Esquemas de representación: Modelos Ontológicos

- ▶ Existen muchos y diversos esquemas de representación del conocimiento: marcos o frames, redes semánticas, **sistemas basados en reglas, modelos ontológicos**, etc.
- ▶ El esquema de representación del conocimiento más ampliamente utilizado hoy en día es el basado en ontologías y grafos de conocimiento, en concreto las tecnologías como **OWL (Web Ontology Language)** y **RDF (Resource Description Framework)**.
- ▶ Este enfoque es fundamental para la **Web Semántica** que busca hacer que los datos de la web sean legibles y procesables tanto por humanos como por máquinas.
 - ▶ Extensión de la World Wide Web que añade significado a los datos de internet.
 - ▶ Objetivo: que las máquinas puedan entender, interpretar y utilizar la información de manera eficiente, en lugar de solo procesarla como un documento.
 - ▶ Al estructurar y anotar los datos con metadatos semánticos y vocabularios estandarizados como las ontologías, se facilita la creación de motores de búsqueda más potentes, servicios de información inteligentes y aplicaciones que pueden deducir nuevo conocimiento de los datos web.

Introducción

Razonamiento con Modelos Ontológicos



Protegé.

1. Razonamiento con Modelos Ontológicos.
2. **Razonamiento Aproximado Basado en Lógica Difusa.**
3. Aprendizaje de Modelos Difusos desde Datos.
4. **Razonamiento Aproximado con Incertidumbre.**
5. Aprendizaje de Modelos con Incertidumbre desde Datos.
6. Conexión con Asignaturas de GII.
7. Puntos de Conexión con Asignaturas de MIA.

Reglas de Producción

- ▶ Un esquema de representación del conocimiento muy antiguo es el basado en reglas de la forma: SI *antecedente* ENTONCES *consecuente* (reglas **IF-THEN**).
- ▶ El antecedente establece un hecho que se da, una premisa o una situación
- ▶ El consecuente establece un hecho que se deriva, una conclusión o una acción
- ▶ Ejemplos:

SI es un animal con garras ENTONCES es carnívoro

SI el semáforo está en rojo ENTONCES parar

- ▶ A veces los elementos de las reglas no se conocen con exactitud. Entonces las reglas incluyen mecanismos para representar esa **información imperfecta**.

Información Imperfecta


- ▶ Tipos de imperfecciones en la información:
 - ▶ Información incompleta.
 - ▶ Información contradictoria
 - ▶ Información redundante.
 - ▶ Información vaga o imprecisa inherente al uso del lenguaje natural.
 - ▶ Información poco fiable (con incertidumbre) debido a limitaciones físicas de los sensores o apreciaciones subjetivas.

Tratamiento de la Incertidumbre y Tratamiento de la Imprecisión

- ▶ La incertidumbre y la imprecisión son dos características relacionadas pero diferentes.
- ▶ La incertidumbre se refiere a la falta de seguridad por parte del observador en la veracidad de una afirmación.
- ▶ Ejemplo: la posición de un objeto dada por un radar es un valor preciso de latitud y longitud, pero puede existir cierta duda sobre su veracidad.
- ▶ Por otro lado, una afirmación imprecisa es aquella que no es completamente verdadera o falsa, sino que su veracidad puede medirse con un grado.
- ▶ Ejemplo: Es una persona joven.
- ▶ Existen diversos marcos teóricos para modelar esta incertidumbre como los Modelos Probabilísticos y la Teoría de Dempster-Shafer o Teoría de la Evidencia (Tema 5).
- ▶ El principal formalismo para representación de imprecisión es la **Lógica Difusa** (Tema 3).

Introducción

Razonamiento Aproximado Basado en Lógica Difusa



Sistema de reglas difusas para calcular la propina.

1. Razonamiento con Modelos Ontológicos.
2. Razonamiento Aproximado Basado en Lógica Difusa.
3. **Aprendizaje de Modelos Difusos desde Datos.**
4. Razonamiento Aproximado con Incertidumbre.
5. **Aprendizaje de Modelos con Incertidumbre desde Datos.**
6. Conexión con Asignaturas de GII.
7. Puntos de Conexión con Asignaturas de MIA.

Causas de Imperfección en la Información:


- ▶ Información procedente de experto humano: falta de un conocimiento absoluto sobre los hechos y las leyes que rigen el mundo observado. Vaguedad inherente al uso del lenguaje natural.
- ▶ Información procedente de sensores: imprecisión del sensor (ruido), tasa de fallo, condiciones meteorológicas.

Soft Computing

- ▶ Colección de técnicas de computación diseñadas para manejar información imperfecta y emular la capacidad humana de razonar en situaciones complejas y ambiguas.
- ▶ Tolerancia a imprecisión, incertidumbre y ruido en los datos.
- ▶ Métodos más flexibles que incorporan conocimiento experto y permiten la extracción de conocimiento **a partir de datos**.
- ▶ Técnicas: redes neuronales, algoritmos genéticos, técnicas de clustering, hibridación de técnicas (neuro-difuso, árboles de decisión difusos, clustering difuso, ...)

Introducción

Aprendizaje de Modelos en el Marco del Soft Computing



Red neuro-difusa.

1. Razonamiento con Modelos Ontológicos.
2. Razonamiento Aproximado Basado en Lógica Difusa.
3. Aprendizaje de Modelos Difusos desde Datos.
4. Razonamiento Aproximado con Incertidumbre.
5. Aprendizaje de Modelos con Incertidumbre desde Datos.
6. **Conexión con Asignaturas de GII.**
7. Puntos de Conexión con Asignaturas de MIA.

Introducción

Conexión con Asignaturas de GII

- ▶ Se utilizan contenidos de
 - ▶ Lógica Proposicional (conectivas, tablas de verdad, consecuencias lógicas).
 - ▶ Lógica de Predicados (cuantificadores).
- ▶ Se desarrollan contenidos de
 - ▶ Representación del conocimiento.
 - ▶ Sistemas basados en reglas.
 - ▶ Gestión de la incertidumbre.
- ▶ Se aplican:
 - ▶ Árboles de Decisión.
 - ▶ Clustering.
 - ▶ Redes Neuronales.
- ▶ **Por tanto, existe conexión con**
 - ▶ FLI 1º GII-UMU.
 - ▶ SI 3º GII- UMU.
 - ▶ DESIN 4º GII-UMU. Computación.
 - ▶ AC 4º GII-UMU. Computación.

1. Razonamiento con Modelos Ontológicos.
2. Razonamiento Aproximado Basado en Lógica Difusa.
3. Aprendizaje de Modelos Difusos desde Datos.
4. Razonamiento Aproximado con Incertidumbre.
5. Aprendizaje de Modelos con Incertidumbre desde Datos.
6. Conexión con Asignaturas de GII.
7. **Puntos de Conexión con Asignaturas de MIA.**

Obviamente, todas las asignaturas del máster guardan cierta relación. Nuestra asignatura no es una excepción.


- ▶ **Machine Learning:**

- ▶ Fragmento de la GD: *El Machine Learning (ML) es una disciplina dentro de la inteligencia artificial que se encarga de todo el proceso para extraer conocimiento útil a partir de datos a priori desconocidos. En otras palabras, el ML trata de encontrar modelos inteligibles a partir de los datos.*
- ▶ El Soft Computing tiene el **mismo objetivo** y realiza las mismas fases para ello.

- ▶ **Computación Bio-inspirada:** se estudian algoritmos evolutivos que se pueden aplicar para la **generación y optimización** de reglas difusas:

- ▶ *Multi-objective evolutionary algorithms for fuzzy classification in survival prediction.*
- ▶ *A multi-objective neuro-evolutionary algorithm to obtain interpretable fuzzy models.*


- **Extensiones de Machine Learning:** Se estudian otras técnicas de ML como el Aprendizaje por Refuerzo que se puede combinar con los modelos difusos:
 - *Fuzzy Inference System Learning by Reinforcement Methods.*
 - *Accelerating Deep Reinforcement Learning with Fuzzy Logic Rules.*



Esquema de Aprendizaje por refuerzo.

► Visión Artificial:

- Las ontologías aportan la semántica que complementa la visión artificial, permitiendo que los sistemas no solo reconozcan lo que hay en una imagen, sino que también comprendan el contexto y las relaciones entre los objetos.
- Los modelos difusos son útiles para clasificar objetos cuando las fronteras no están claramente definidas o cuando las diferencias de color o iluminación no son claras.
 - *A fuzzy approach in color object detection.*




Segmentación con reglas difusas.

► Machine Learning Explicable:

- Fragmento de la GD: ... *se abordará desde un punto de vista teórico como práctico: (1) las limitaciones de la IA y los problemas de **interpretabilidad**, (2) **cómo abordar el uso de modelos interpretables**, (3) métodos para dar explicación a modelos ML de caja negra y (4) los procesos para desarrollar sistemas basados en IA más confiables.*
- Los modelos ontológicos así como los modelos basados en reglas difusas siempre han sido la antítesis de modelos caja negra.

► Inteligencia Artificial y Sociedad:

- Uno de los principios de diseño de los sistemas inteligentes es la **explicabilidad**.
- Los mecanismos de representación del conocimiento y razonamiento aproximado van en sintonía con esta característica.



Modelo caja negra.