Machine Learning I

Tema 2. Aprendizaje Supervisado
2.3 Maquinas de Vectores Soporte (SVM)

Profesor: Raquel Martínez y José Tomás Palma

Curso 2024-2025

1 SVM: Introducción

2 SVM Lineales para clasificación

3 SVM Lineales para clasificación: Soft Margin

4 SVM No Lineales para clasificación

5 SVM No Lineales para clasificación: Kernel

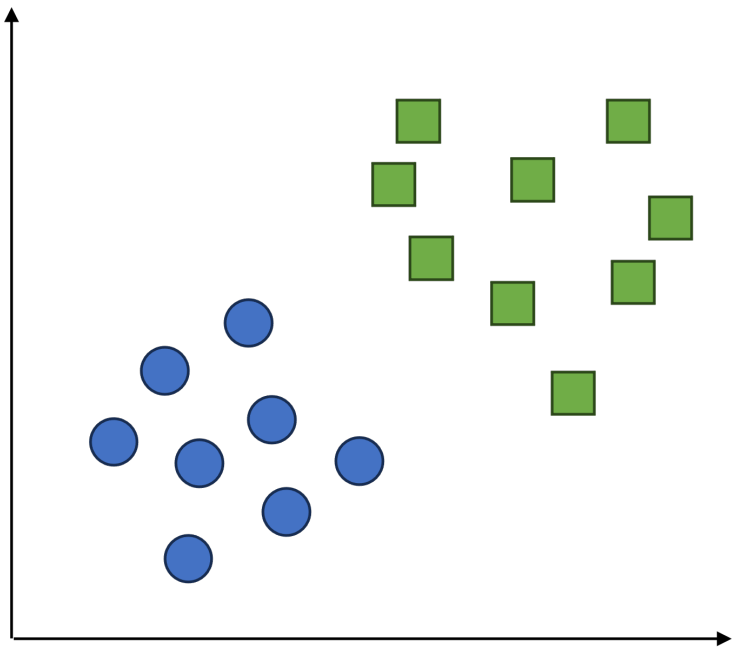
6 SVM para Regresión

7 SVM: Conclusiones

8 Referencias

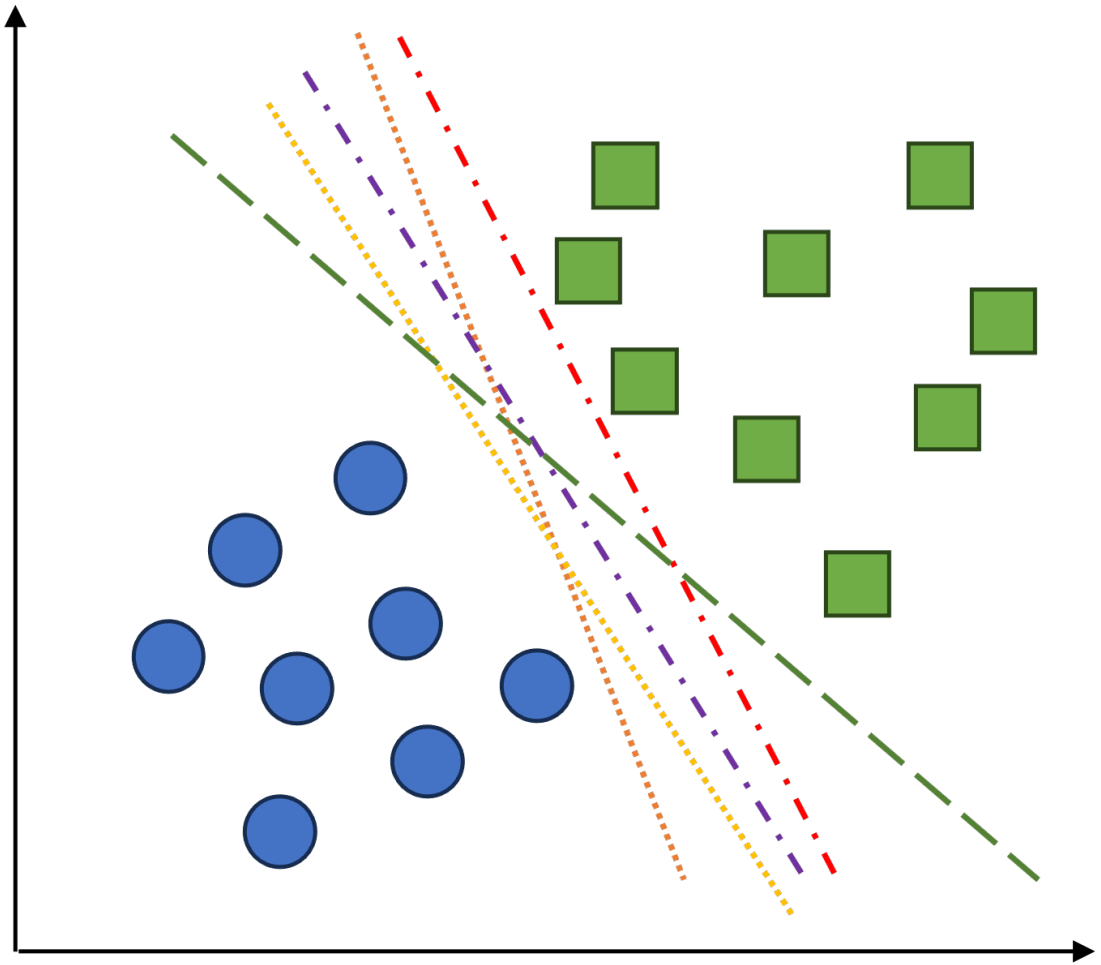
SVM: Introducción

- Las maquinas de vectores soporte (Support vector machine (SVM)) son algoritmos de aprendizaje supervisado para realizar tareas tanto de clasificación como de regresión.
- **Idea subyacente**. Si tengo dos clases, ¿cómo puedo crear un hiperplano capaz de separar esas dos clases lo mejor posible?
- El hiperplano buscado es la frontera de decisión (decision boundary).



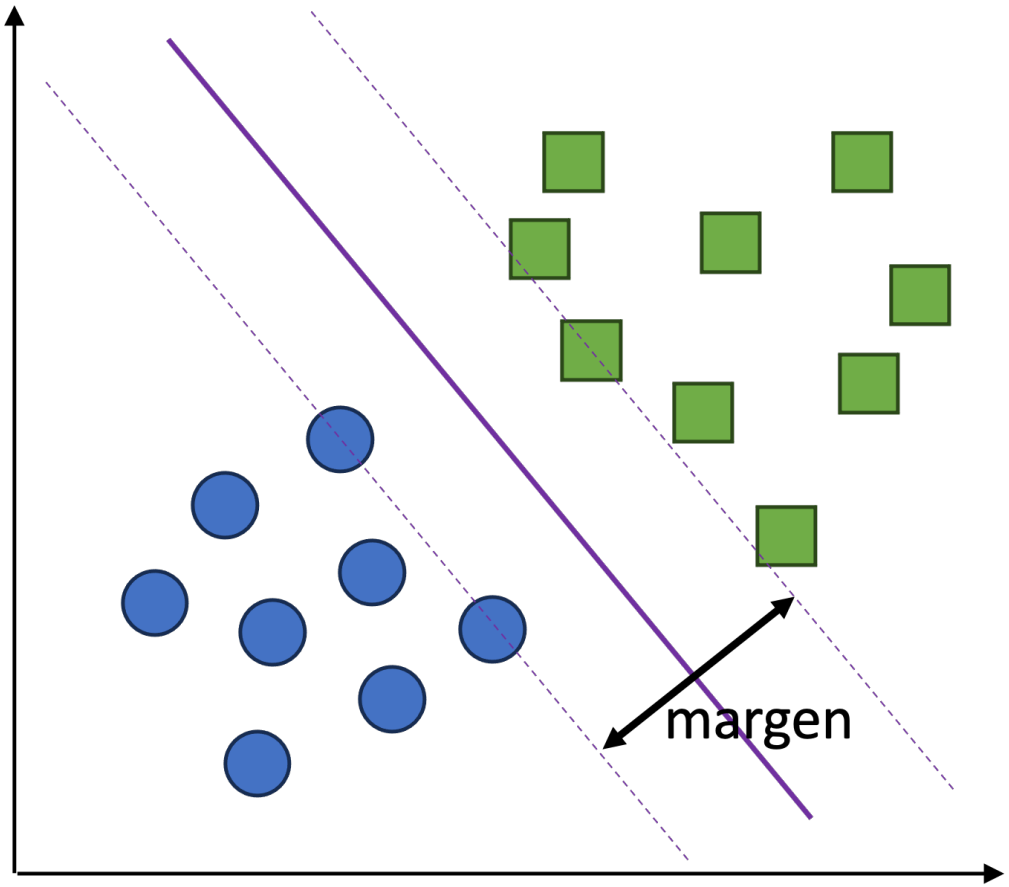
SVM: Introducción

Posibles soluciones para construir el hiperplano:



SVM: Introducción

¿Qué hiperplano se elige? ¿Qué condición hay que poner?



Hiperplano que cree una separación máxima entre ambas clases. A mayor margen, más generalización.

SVM Lineales para clasificación

Un SVM lineal es un clasificador que busca un hiperplano con el máximo margen.

- Sea un problema de clasificación binaria con N ejemplos, cada ejemplo se representa como el par $< \mathbf{x_i}, y_i >$ $(i = 1, 2, ..., N)$, donde $\mathbf{x_i}$ es un vector de D dimensiones $(x_{i1}, x_{i2}, ..., x_{iD})$ e $y_i \in, \{-1, 1\}$ (ejemplos negativos y positivos).
- El hiperplano que define la frontera de decisión de un clasificador lineal se escribe de la siguiente manera:

$$\mathbf{w}^T\mathbf{x} + b = 0$$

  donde $\mathbf{w}$ y b son parámetros a determinar en el modelo.
- Por lo tanto, el hiperplano de máxima separación $\mathbf{w}^T\mathbf{x} + b = 0$ debe cumplir que:

$$f(\mathbf{x_i}) = \begin{cases} 1, & \text{si } \mathbf{w}^T\mathbf{x_i} + b \geq 0 \\ -1, & \text{si } \mathbf{w}^T\mathbf{x_i} + b < 0 \end{cases}$$

SVM Lineales para clasificación

- El hiperplano $\mathbf{w}^T\mathbf{x} + b = 0$ separa los ejemplos positivos (cuadrados) de los negativos (círculos)
- Cualquier ejemplo que se encuentre en el límite de decisión debe satisfacer la ecuación del hiperplano.
- En el entrenamiento de una SVM lineal implica la estimación de los parámetros $\mathbf{w}$ y b para construir el hidroplano de margen máximo.
  - Para ello es necesario identificar los **vectores soporte**.
  - Los vectores soporte son aquellas instancias más próximas, de cada clase, al hiperplano de margen máximo.
  - El conjunto de vectores soporte define de forma única el hiperplano de margen máximo.

SVM Lineales para clasificación

- Sean $\mathbf{a_1}$ y $\mathbf{a_2}$ dos instancias localizadas en los límites del margen de decisión y equidistantes al hiperplano de margen máximo.
- Esto implica que $\exists k \in \mathbb{R}; \quad k > 0$
  $b_1 : \mathbf{w_o}^T \mathbf{a_1} + b_o = k$
  $b_2 : \mathbf{w_o}^T \mathbf{a_2} + b_o = -k$
- Normalizando ambas ecuaciones (dividimos por k) obtenemos:
  $b_1 : \mathbf{w}^T \mathbf{a_1} + b = 1$
  $b_2 : \mathbf{w}^T \mathbf{a_2} + b = -1$

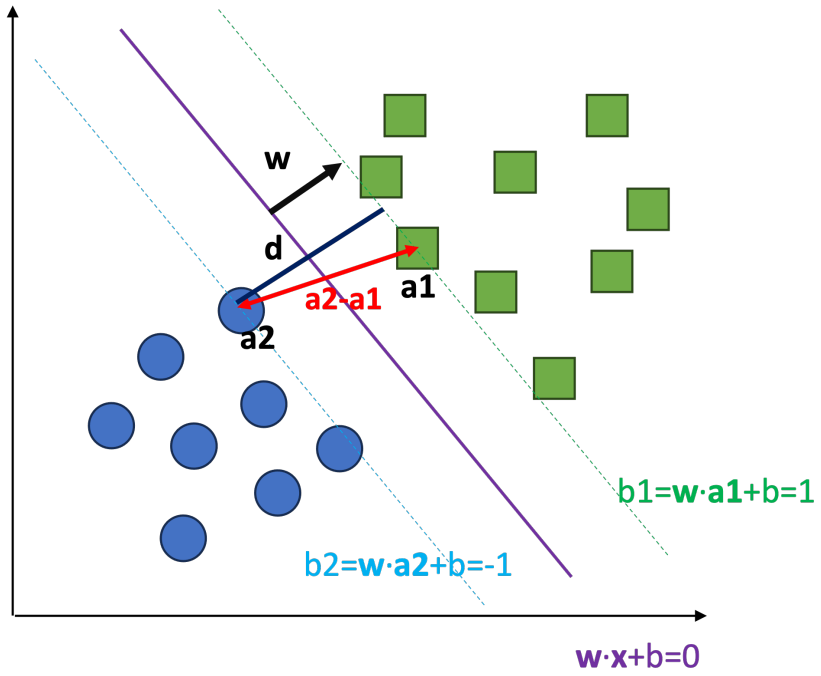


Figura: Ejemplo de SVM

SVM Lineales para clasificación

- Por lo tanto, se tiene que cumplir que $\forall i \in [1..N]$,

$$\mathbf{w}^T\mathbf{x_i} + b \geq 1, \text{ si } y_i = 1$$
$$\mathbf{w}^T\mathbf{x_i} + b \leq -1, \text{ si } y_i = -1$$

- O lo que es lo mismo, se debe de cumplir que

$$y_i(\mathbf{w}^T\mathbf{x_i} + b) \geq 1$$

- Siendo la anchura del margen máximo d es la distancia entre los hiperplanos b_1 y b_2

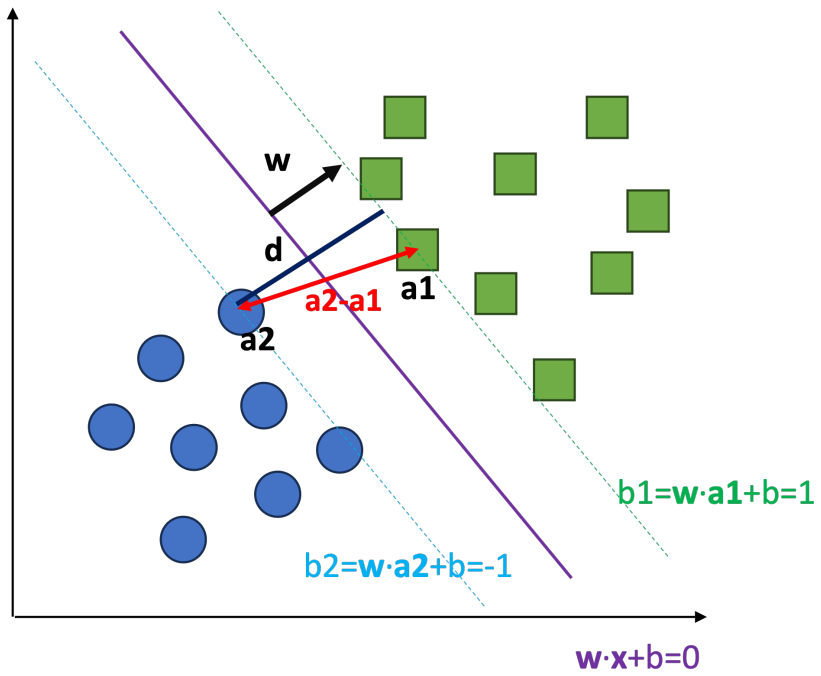


Figura: Ejemplo de SVM

SVM Lineales para clasificación: Entrenamiento

¿Cómo podemos calcular la anchura del margen máximo d?

- Tal y como hemos deducido anteriormente tenemos para los puntos en la frontera a_1 y a_2

$$\mathbf{w}^T\mathbf{a_1} + b = 1$$
$$\mathbf{w}^T\mathbf{a_2} + b = -1$$

- Si restamos ambas ecuaciones:

$$\mathbf{w}^T(\mathbf{a_1} - \mathbf{a_2}) = 2$$

- Teniendo en cuenta la definición del producto escalar:

$$||\mathbf{w}|| * ||\mathbf{a_1} - \mathbf{a_2}|| * \cos(\theta) = 2$$

- y teniendo en cuenta la figura tenemos que $||\mathbf{a_1} - \mathbf{a_2}|| * cos(\theta) = d$, sustituyendo tenemos

$$||\mathbf{w}|| * d = 2$$

- despejando d llegamos a :

$$d = \frac{2}{||\mathbf{w}||}$$

- Por lo tanto, el cálculo de la distancia máxima de se margen depende de $\mathbf{w}$.

SVM Lineales para clasificación: Entrenamiento

- Si utilizamos el cuadrado de la norma L_2 para calcular d y la restricción

$$\forall i \in [1..N], \quad y_i(\mathbf{w}^T\mathbf{x_i} + b) >= 1$$

- calcular el máximo de margen equivale a resolver el siguiente problema de optimización:

$$\begin{aligned} \max_{\mathbf{w},b} \quad & f(\mathbf{w}) = \frac{2}{\|\mathbf{w}\|_2^2} \\ \text{sujeto a :} \quad & y_i(\mathbf{w}^T\mathbf{x_i} + b) \geq 1 \\ & \forall i \in [1..N] \end{aligned}$$

- que también se puede plantear como un problema de minimización

$$\begin{aligned} \min_{\mathbf{w},b} \quad & f(\mathbf{w}) = \frac{1}{2}\|\mathbf{w}\|_2^2 \\ \text{sujeto a :} \quad & y_i(\mathbf{w}^T\mathbf{x_i} + b) \geq 1 \\ & \forall i \in [1..N] \end{aligned}$$

- quedando el problema de aprendizaje reducido a un problema de optimización cuadrática

SVM Lineales para clasificación: Entrenamiento

- Dado que la función objetivo es cuadrática y las restricciones son lineales para los parámetros, el problema puede resolverse mediante el método de multiplicadores de Lagrange.
- Para calcular la función objetivo con los multiplicadores de Lagrange, tenemos que adaptar la función objetivo a las restricciones del problema:
  - Así, la nueva función objetivo se conoce como el Lagrangiano para el problema de optimización:

$$L_P(\alpha, \mathbf{w}) = \frac{1}{2}\|\mathbf{w}\|_2^2 - \sum_{i=1}^{N} \alpha_i (y_i(\mathbf{w}^T \mathbf{x_i} + b) - 1) \tag{1}$$

  donde los parámetros α_i se llaman los **multiplicadores de Lagrange**.
  - El primer término en el Lagrangiano es el mismo que la función objetivo original, mientras que el segundo término captura las restricciones de desigualdad.
  - Ahora el objetivo es minimizar la función $L_p(\alpha, \mathbf{w})$.

SVM Lineales para clasificación: Entrenamiento

- Para minimizar el Lagrangiano, debemos calcular la derivada de $L_P(\alpha, \mathbf{w})$ con respecto a $\mathbf{w}$ y b e igualarlas a cero:

$$\frac{\partial L_P(\alpha, \mathbf{w})}{\mathbf{w}} = 0 \rightarrow \mathbf{w} = \sum_{i=1}^{N} \alpha_i y_i \mathbf{x_i} \tag{2}$$

$$\frac{\partial L_P(\alpha, \mathbf{w})}{b} = 0 \rightarrow \sum_{i=1}^{N} \alpha_i y_i = 0 \tag{3}$$

- Debido a que los multiplicadores de Lagrange son desconocidos, aún no podemos encontrar los valores para $\mathbf{w}$ y b.

SVM Lineales para clasificación: Entrenamiento

- Si el problema de optimización tuviese restricciones de igualdad en vez de desigualdad, podríamos usar las N restricciones para encontrar soluciones válidas de $\mathbf{w}$,b, y α_i haciendo lo siguiente:

$$\frac{\partial L_P(\alpha, \mathbf{w})}{\partial \mathbf{w}} = 0 \quad \frac{\partial L_P(\alpha, \mathbf{w})}{\partial b} = 0 \quad \frac{\partial L_P(\alpha, \mathbf{w})}{\partial \alpha_i} = 0$$

- Una forma de manejar problemas con restricciones de desigualdad es transformar estas restricciones en restricciones de igualdad y luego verificar que las soluciones encontradas satisfagan las condiciones de Karush-Kuhn-Tucker (KKT).

$$\alpha_i \geq 0 \tag{4}$$

$$\alpha_i[y_i(\mathbf{w}^T \mathbf{x_i} + b) - 1] = 0 \tag{5}$$

- La primera restricción nos exige que los multiplicadores de Lagrange sean no negativos.
- La segunda restricción se conoce como "anchura complementaria" y es crucial para encontrar los vectores de soporte.

SVM Lineales para clasificación: Entrenamiento

- A primera vista, puede parecer que existen tantos multiplicadores de Lagrange como instancias de entrenamiento.
- Sin embargo, muchos de los multiplicadores de Lagrange quedan en cero después de aplicar la restricción de la ecuación (5).
- La restricción (5) establece que, o bien el multiplicador de Lagrange α_i debe ser cero, o la instancia $\mathbf{x_i}$ debe estar en los hiperplanos que definen el margen máximo $y_i(\mathbf{w}^T\mathbf{x_i} + b) = 1$
  - Por lo tanto, toda instancia $\mathbf{x_i}$ tal que $\alpha_i > 0$ se encuentra en los hiperplanos que definen el máximo margen b_1 y b_2
  - En este caso estas $\mathbf{x_i}$ se conocen como **vectores soporte**.
  - Las instancias con $\alpha_i = 0$ no están en dichos hiperplanos
- Las ecuaciones (2) y (3) también indican que los parámetros $\mathbf{w}$ y b, que definen el límite de decisión, dependen sólo de los vectores de soporte.

SVM Lineales para clasificación: Entrenamiento

- Resolver este problema de optimización es aún computacionalmente caro porque involucra un gran número de parámetros: $\mathbf{w}$, b, y α_i.
- El problema puede simplificarse transformando el Lagrangiano en una función que depende solamente de los multiplicadores de Lagrange conocida como el problema dual ($L_D(\alpha)$).
- El dual de un problema de optimización es una visión alternativa del problema primal ($L_P(\alpha, \mathbf{w})$) que para problemas convexos (como este) tienen resultados equivalentes.
- Para encontrar el dual, sustituimos las ecuaciones (2) y (3) en la ecuación (1)

$$\mathbf{w} = \sum_{i=1}^{N} \alpha_i y_i \mathbf{x}_i, \quad \sum_{i=1}^{N} \alpha_i y_i = 0, \quad \rightarrow L_P(\alpha, \mathbf{w}) = \frac{1}{2}||\mathbf{w}||^2 - \sum_{i=1}^{N} \alpha_i (y_i(\mathbf{w}^T \mathbf{x_i} + b) - 1)$$

SVM Lineales para clasificación: Entrenamiento

- Esto nos llevará a la siguiente formulación dual del problema de optimización:

$$\begin{aligned} \max_{\alpha} \quad & L_D(\alpha) = \sum_{i=1}^{N} \alpha_i - \frac{1}{2} \sum_{i,j=1}^{N} \alpha_i \alpha_j y_i y_j \mathbf{x_i}^T \mathbf{x_j} \\ \text{sujeto a :} \quad & \alpha_i \geq 0, \ \forall i \in [1..N] \\ & \sum_{i=1}^{N} \alpha_i y_i = 0 \end{aligned}$$

- El **Lagrangiano dual**, $L_D(\alpha)$ involucra sólo los multiplicadores de Lagrange y los datos de entrenamiento y el **Lagrangiano primal**, $L_p(\alpha, \mathbf{w})$ involucra los multiplicadores de Lagrange así como los parámetros del hiperplano separador $(\mathbf{w}, b)$.

SVM Lineales para clasificación: Entrenamiento

- El problema de minimización original para el Lagrangiano primal $L_P(\alpha, \mathbf{w})$ se convierte en un problema de maximización para el Lagrangiano dual $L_D(\alpha)$.
- Como este es un problema de optimización convexo las soluciones para ambos problemas de optimización son equivalentes (siempre y cuando la solución satisfaga las condiciones KKT).
- El problema de la optimización dual puede resolverse mediante técnicas numéricas de programación cuadrática.
- Existe un algoritmo muy eficiente para resolver ese problema llamado Sequential Minimal Optimization.

SVM Lineales para clasificación: Entrenamiento

- Una vez encontrados los valores de α_i, podemos utilizar la ecuación (2) para obtener $\mathbf{w}$.

$$\mathbf{w} = \sum_{i=1}^{N} \alpha_i y_i \mathbf{x_i}$$

- El valor de b se obtiene resolviendo la ecuación (5) para los vectores de soporte
  - Debido a que los α_i se calculan numéricamente, éstos pueden tener errores numéricos y el valor calculado para b puede no ser único. De hecho, depende del vector de soporte utilizado en la Ecuación (5).
  - En la práctica, se elige el valor promedio de b para todos los vectores de soporte.

$$b = \frac{1}{N_{SV}} \sum_{i \in SV}^{N} \left(y_i - \sum_{j \in SV}^{N} \alpha_j y_j \mathbf{x_i}^T \mathbf{x_j} \right)$$

  - siendo N_{SV} el número de vectores soporte (puntos con $\alpha_i > 0$.

SVM Lineales para clasificación: Inferencia

- De esta forma, el hiperplano de máxima separación queda expresado de la siguiente forma, en función únicamente de los vectores de soporte:

$$\sum_{i=1}^{N} \alpha_i y_i \mathbf{x_i}^T \mathbf{x} + b = 0 \tag{6}$$

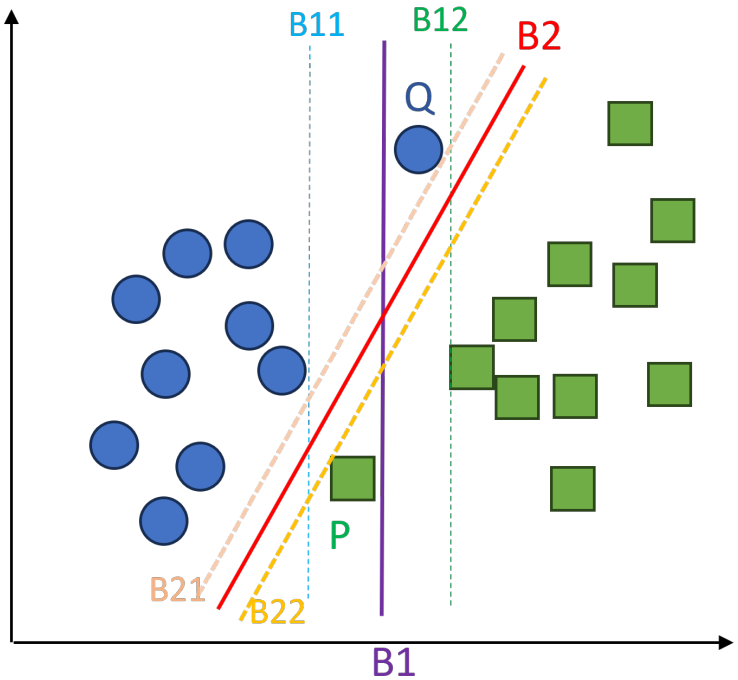
- Una vez que se encuentran los parámetros que construyen el hiperplano, la función de clasificación se reduce a:

$$f(\mathbf{z}) = \text{sign}(\mathbf{w}^T \mathbf{z} + b) = \text{sign}\left(\sum_{i=1}^{N} \alpha_i y_i \mathbf{x_i}^T \mathbf{z} + b \right)$$

- Si $f(\mathbf{z}) = 1$, entonces el ejemplo se clasifica con la clase positiva; de lo contrario, se clasifica con la clase negativa.
- Para clasificar solo necesitamos iterar sobre los vectores de soporte $\mathbf{x_i}$, aquello para los que $\alpha_i > 0$, que son muchos menos que los datos entrenamiento

SVM Lineales para clasificación: Soft Margin

- ¿Qué ocurre, cuando en entrenamiento, no son linealmente separables todos los ejemplos? Imaginemos el siguiente ejemplo, donde inicialmente hay una frontera de decisión y después aparecen dos ejemplos con ruido.



- ¿Qué hiperplano es mejor B1 o B2?

SVM Lineales para clasificación: Soft Margin

- El límite de decisión $B1$ clasifica erróneamente los dos nuevos ejemplos, mientras que $B2$ los clasifica correctamente.
  - Pero esto no significa que $B2$ sea un mejor límite de decisión que B1.
  - Los nuevos ejemplos pueden corresponder a ruido en los datos de entrenamiento.
  - $B1$ debería seguir siendo preferible a $B2$ porque tiene un margen más amplio lo que lo hace menos susceptible a padecer sobreajuste.
- La formulación de la SVM presentada en la anteriormente no contempla errores en los datos de entrenamiento.

SVM Lineales para clasificación: Soft Margin

- **Solución:** Modificar el problema de optimización para aprender un límite de decisión que sea tolerable al ruido usando un método conocido como el margen suave (**soft margin**).
  - Soft margin permite a la SVM construir la frontera de decisión en situaciones en las que las clases no sean linealmente separables.
  - Hay que encontrar un equilibrio entre el ancho del margen y el número de errores permitidos en entrenamiento.

SVM Lineales para clasificación: Soft Margin

- EL hiperplano $B1$ no satisface la restricción de:

$$y_i(\mathbf{w}^T\mathbf{x}_i + b) \geq 1, \ \forall i = [1, .., N]$$

- Debemos relajar las restricciones para poder suportar datos no linealmente separables.
- Esto se puede hacer introduciendo **variables de holgura o slack variables** (ξ_i) a las restricciones del problema:

$$(\mathbf{w}^T\mathbf{x}_i + b) \geq 1 - \xi_i, \text{ si } y_i = 1$$

$$(\mathbf{w}^T\mathbf{x}_i + b) \leq -1 + \xi_i, \text{ si } y_i = -1$$

donde $\forall i : \xi_i > 0$

SVM Lineales para clasificación: Soft Margin

- El problema de optimización primal quedaría formulado como minimizar la siguiente función objetivo:

$$\begin{aligned} \min_{\mathbf{w},b,\xi} \quad & f(\mathbf{w}, C, \xi) = \frac{1}{2}\|\mathbf{w}\|_2^2 + C\sum_{i=1}^{N}\xi_i \\ \text{sujeto a :} \quad & y_i(\mathbf{w}^T\mathbf{x}_i + b) \geq 1 - \xi_i \\ & \xi_i \geq 0 \\ & \forall i \in [1..N] \end{aligned}$$

- Donde ξ_i representa la magnitud del error para la instancia $\mathbf{x_i}$ y C es el coste que se penaliza por los errores.

SVM Lineales para clasificación: Soft Margin

- C es parámetro de regularización que controla el tamaño de **w** para un conjunto de entrenamiento dado.
  - C establece el compromiso entre el error de entrenamiento y la complejidad del modelo
  - Valores pequeños de C implican un modelo sencillo, mayor error de entrenamiento y suavidad en la frontera $\longrightarrow$ margen grande.
  - Valores grandes de C grande implican un modelo complejo, poca suavidad en la frontera y riesgo de sobreajuste. $\longrightarrow$ margen estrecho.
  - $C = \infty$ implica el "Hard Margin".
- Para establecer el parámetro C se debe calibrar sobre un conjunto de datos independientes llamado de validación mediante una búsqueda en grid.
- Una vez formulado el problema procedemos de manera análoga: planteamos el nuevo Lagrangiano, el dual y verificamos que las soluciones respeten las condiciones KKT.

SVM Lineales para clasificación: Soft Margin

- Como $\xi_i \geq 0$, la restricción $y_i(\mathbf{w}^T\mathbf{x}_i + b) \geq 1 - \xi_i$ equivale a

$$\xi_i = \text{máx}(0, 1 - y_i(\mathbf{w}^T\mathbf{x}_i + b))$$

- Esta última función es conocida como la **función de pérdida** o **loss function** y, por lo tanto, el problema de optimización es equivalente al siguiente problema de optimización sin restricciones

$$\min_{\mathbf{w}} \|\mathbf{w}\|_2^2 + C\sum_{i=1}^{N} \text{máx}(0, 1 - y_i(\mathbf{w}^T\mathbf{x}_i + b))$$

- Esta función pérdida nos permite clasificar una instancia $\mathbf{x_i}$ en tres categorías:
  - Si $y_i(\mathbf{w}^T\mathbf{x}_i + b) \geq 1$. El punto está fuera del margen y no contribuye a la función de pérdida (error).
  - Si $y_i(\mathbf{w}^T\mathbf{x}_i + b) = 1$. El punto está en el margen y no contribuye a la función de pérdida (error) como en el caso del "Hard Margin´´.
  - Si $y_i(\mathbf{w}^T\mathbf{x}_i + b) < 1$. El punto viola la restricción del margen y contribuye a la función de pérdida (error).

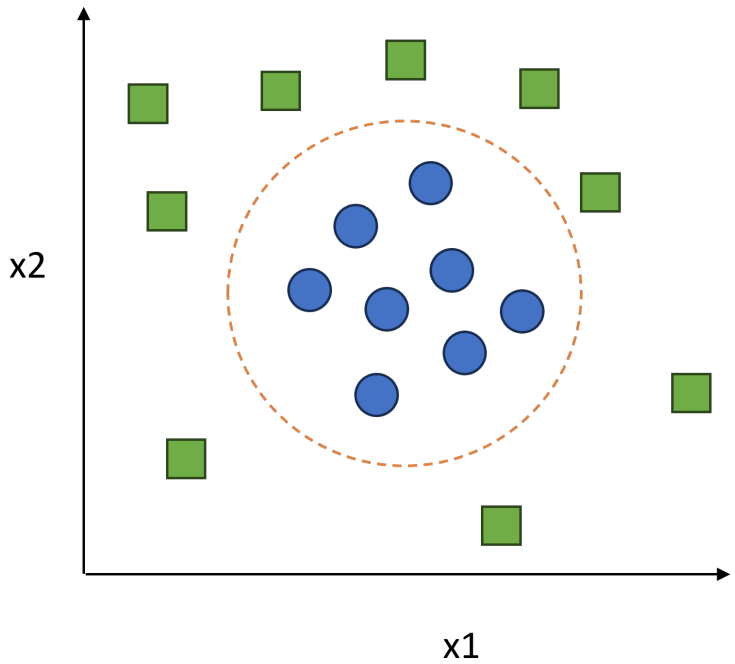
SVM Lineales para clasificación: Soft Margin

- Una vez formulado el problema procedemos de manera análoga al caso anterior utilizando los multiplicadores de Lagrange, se plantea el problema dual se verifica que las soluciones respeten las condiciones KKT.

$$\begin{aligned} \max_{\alpha} \quad & L_D(\alpha) = \sum_{i=1}^{N} \alpha_i - -\frac{1}{2} \sum_{i,j=1}^{N} \alpha_i \alpha_j y_i y_j \mathbf{x_i x_j} \\ \text{sujeto a :} \quad & 0 \leq \alpha_i \leq C \\ & \sum_{i=1}^{N} \alpha_i y_i = 0 \\ & \forall i \in [1..N] \end{aligned}$$

SVM No Lineales para clasificación

- ¿Qué ocurre cuando los datos no son separables linealmente, sino que tienen una separación no lineal?
- El problema no se puede solucionar con una SVM lineal.
- **Idea:** Podríamos hacer una transformación no lineal $\Phi(\mathbf{x})$ para mapear los datos de su espacio original a un nuevo espacio (con más dimensiones) donde el límite de decisión se vuelva lineal.



SVM No Lineales para clasificación

- Matemáticamente esta idea es una consecuencia del **Teorema de Cover** que establece lo siguiente:

Dado un conjunto de datos de entrenamiento no linealmente separable, es posible, con una alta probabilidad, transformarlo en un conjunto de datos de entrenamiento que sea linealmente separable proyectándolo en un nuevo espacio, siempre que

a) la transformación sea no lineal

b) la dimensión del nuevo espacio sea lo suficientemente alta

- **En otras palabras:** El teorema de Cover dice que un problema complejo de clasificación de patrones, proyectado en un espacio de alta dimensión de forma no lineal, es más probable que sea linealmente separable que en un espacio de baja dimensión, siempre que el espacio no esté densamente poblado.

SVM No Lineales para clasificación

- La idea básica consta de dos operaciones matemáticas:
  1. Una transformación no lineal del espacio de los datos L (m_0 dimensional) a un espacio de alta dimensión H (m_1-dimensional), llamado espacio de características.
  2. Construcción del hiperplano de máximo margen en el espacio de características.
- Ejemplo:
  - Supongamos que elegimos la siguiente transformación que transforma un espacio de 2 dimensiones (x_1, x_2) en uno de 5 dimensiones

$$\Phi : (x_1, x_2) \rightarrow (x_1^2, x_2^2, \sqrt{2x_1}, \sqrt{2x_2}, 1)$$

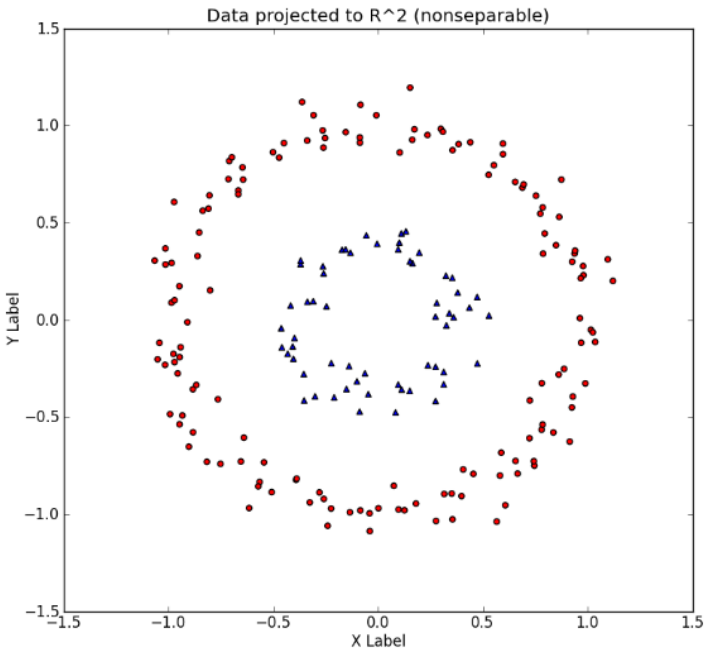
  - En este espacio transformado podríamos encontrar el vector $\mathbf{w}$ que defina un hiperplano que separen linealmente los datos.

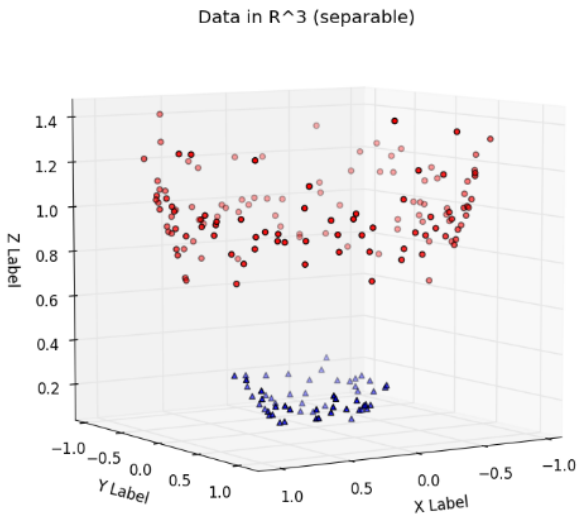
$$w_4 x_1^2 + w_3 x_2^2 + w_2 \sqrt{2x_1} + w_1 \sqrt{2x_2} + w_0 1 = 0$$

SVM No Lineales para clasificación

- **Ejemplo:** A la izquierda un dataset en $\mathbb{R}^2$ no separable linealmente. A la derecha el mismo dataset en $\mathbb{R}^3$ transformado por:

$$[x_1, x_2] = [x_1, x_2, x_1^2 + x_2^2]$$



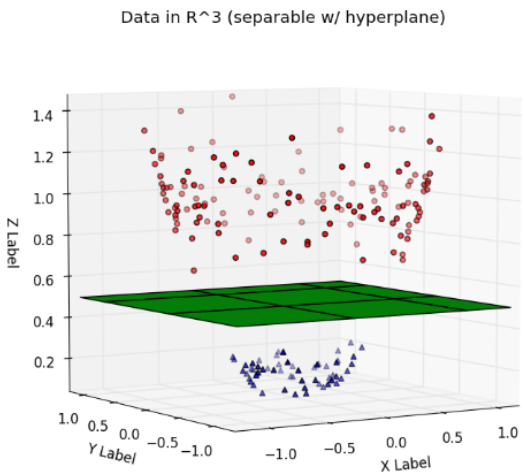


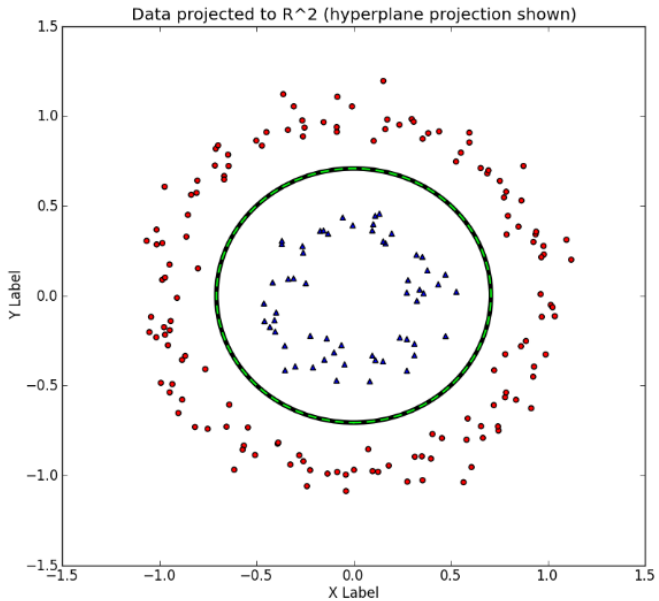
1

[1] https://www.eric-kim.net/eric-kim-net/posts/1/kernel_trick.html

SVM No Lineales para clasificación

- En la figura de la izquierda se puede apreciar que, una vez transformados los datos de $\mathbb{R}^2$ a $\mathbb{R}^3$, se puede encontrar una frontera de decisión lineal.
- En la figura de la derecha se aprecia como sería la proyección en el espacio original $\mathbb{R}^2$ de dicha frontera de decisión lineal, esta vez no lineal.





2

[2] https://www.eric-kim.net/eric-kim-net/posts/1/kernel_trick.html

SVM No Lineales para clasificación: Entrenamiento

- Usando la idea de tener una función $\Phi(\mathbf{x})$ que mapea los datos a una dimensión mayor, el problema de optimización se formula de la siguiente manera:

$$\begin{aligned} \min_{\mathbf{w},b,C} \quad & f(\mathbf{w}) = \frac{1}{2}\|\mathbf{w}\|_2^2 \\ \text{sujeto a:} \quad & 0 \leq \alpha_i \leq C \\ & y_i(\mathbf{w}^T \Phi(\mathbf{x_i}) + b) \geq 1 \\ & \forall i \in [1..N] \end{aligned}$$

- Lo único que hemos hecho es reemplazar todas las instancia del vector $\mathbf{x}$ por $\Phi(\mathbf{x})$.

SVM No Lineales para clasificación: Entrenamiento

- Podemos formular nuevamente el problema dual para el caso del "Soft Margin".

$$\begin{aligned} \max_{\alpha} \quad & L_D(\alpha) = \sum_{i}^{N} \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j \Phi(\mathbf{x_i})^T \Phi(\mathbf{x_j}) \\ \text{sujeto a :} \quad & 0 \leq \alpha_i \leq C \\ & \sum_{i=1}^{N} \alpha_i y_i = 0 \\ & \forall i \in [1..N] \end{aligned}$$

SVM No Lineales para clasificación: Inferencia

- Una vez resuelto el problema de optimización y calculados $\mathbf{w}$ y b, la función de clasificación para realizar la inferencia quedaría de la siguiente forma:

$$f(\mathbf{z}) = \text{sign}(\mathbf{w}^T \Phi(\mathbf{z}) + b) = \text{sign}\left(\sum_{i=1}^{N} \alpha_i y_i \Phi(\mathbf{x_i})^T \Phi(\mathbf{z}) + b \right)$$

- Como podemos ver la función de clasificación se define en función del producto escalar de las instancias en el espacio transformado $\Phi(\mathbf{x})^T \Phi(\mathbf{z}))$.
- Recordemos que el producto escalar de dos vectores tiene relación con su similitud con lo que la función de clasificación depende de la similitud de las instancias en el espacio transformado.
- **Problema:** Si las transformaciones $\Phi(\mathbf{x})$ implican un número alto de dimensiones, el calculo de $\Phi(\mathbf{x})^T \Phi(\mathbf{z})$ es computacionalmente costoso.
- **Solución:** El truco del kernel o **Kernel Trick**.

SVM No Lineales para clasificación: Kernel

- El **Kernel trick** se basa en el hecho de que para algunas transformaciones $\Phi(\mathbf{x})$ es posible calcular el producto escalar $\Phi(\mathbf{x})^T\Phi(\mathbf{z})$ directamente sin necesidad de realizar la transformación $\Phi(\mathbf{x})$ o $\Phi(\mathbf{z})$ explícitamente.
  - **Ejemplo:** Anteriormente definimos la siguiente función de transformación

$$\Phi : (x_1, x_2) \rightarrow (x_1^2, x_2^2, \sqrt{2x_1}, \sqrt{2x_2}, 1)$$

.

  - Sean $\mathbf{u}$ y $\mathbf{u}$ dos vectores en $\mathbb{R}^2$ su producto escalar en el espacio transformado es:

$$\begin{aligned}\Phi(\mathbf{u})^T\Phi(\mathbf{v}) &= (u_1^2, u_2^2, \sqrt{2u_1}, \sqrt{2u_2}, 1)(v_1^2, v_2^2, \sqrt{2v_1}, \sqrt{2v_2}, 1) \\ &= u_1^2v_1^2 + u_2^2 + v_2^2, 2u_1v_1 + 2u_2v_2 + 1 \\ &= (\mathbf{u}^T\mathbf{v} + 1)^2\end{aligned}$$

SVM No Lineales para clasificación: Kernel

- Por lo tanto, el producto escalar en el espacio transformado se puede expresar como una función de similitud en el espacio original. Así, en el ejemplo tendríamos:

$$K(\mathbf{u}, \mathbf{v}) = \Phi(\mathbf{u})^T \Phi(\mathbf{v}) = (\mathbf{u}^T \mathbf{v} + 1)^2$$

- La función de similitud, K, que se calcula en el espacio de atributos original, se conoce como la **función de kernel**.
- El **kernel trick** consiste en reemplazar $\Phi(\mathbf{x})^T \Phi(\mathbf{z})$ por $K(\mathbf{x}, \mathbf{z})$ en las ecuaciones de la SVM y así trabajar en el espacio transformado de manera implícita.

SVM No Lineales para clasificación: Kernel

- En el ejemplo anterior la función Kernel K utilizada a sido un kernel polinomial

$$K(\mathbf{u}, \mathbf{v}) = \Phi(\mathbf{u})^T \Phi(\mathbf{v}) = (\mathbf{u}^T \mathbf{v} + 1)^2$$

- Una SVM con este kernel polinomial tendría la siguiente función de clasificación:

$$\begin{aligned} f(\mathbf{z}) &= \text{sign}\left(\sum_{i=1}^{N} \alpha_i y_i \Phi(\mathbf{x_i})^T \Phi(\mathbf{z}) + b \right) \\ &= sign\left(\sum_{i=1}^{N} \alpha_i y_i K(\mathbf{x_i}, \mathbf{z}) + b \right) \\ &= sign\left(\sum_{i=1}^{N} \alpha_i y_i (\mathbf{x_i}^T \mathbf{z} + 1)^2 + b \right) \end{aligned}$$

SVM No Lineales para clasificación: Kernel

- Para que una función concreta pueda se considerada un kernel debe cumprir el **Teorema de Mercer**

Teorema de Mercer

Sea $K(\mathbf{x}, \mathbf{x}')$ kernel simétrico definido en el intervalo cerrado $a \leq x \leq b$ y $a \leq x' \leq b$, con $\mathbf{x}, \mathbf{x}' \in \mathbb{R}^n$. $K(\mathbf{x}, \mathbf{x}')$ se puede expandir de la siguiente forma:

$$K(\mathbf{x}, \mathbf{x}') = \sum_{i=1}^{\infty} \lambda_i \Phi_i(\mathbf{x})^T \phi_i(\mathbf{x}')$$

con $\lambda_i > 0$. Para que esta expansión sea válida (con convergencia absoluta y uniforme), es condición necesaria y suficiente que

$$\int_b^a \int_b^a K(\mathbf{x}, \mathbf{x}') \Phi_i(\mathbf{x})^T \phi_i(\mathbf{x}') d\mathbf{x} d\mathbf{x}' \geq 0$$

para toda función $\Phi(\mathbf{x})$ que cumpla:

$$\int_b^a \Phi^2(\mathbf{x}) d\mathbf{x} > \infty$$

SVM No Lineales para clasificación: Kernel

- El teorema de Mercer muestra matemáticamente que la función K debe ser semi-definida positiva.
- Por lo tanto, una función K que cumpla el teorema de Mercer representa el producto escalar de dos vectores en el espacio transformado:

$$K(\mathbf{x}, \mathbf{z}) = \Phi(\mathbf{x})^T \Phi(\mathbf{z})$$

.

- En la práctica nos limitamos a usar las funciones de Kernel conocidas que sabemos que cumplen con la condición.
- El espacio transformado de una función de Kernel en una SVM se llama Reproducing Kernel Hilbert Space (RKHS).
- El cálculo de los productos escalares usando las funciones del Kernel es considerablemente menos costoso computacionalmente que realizarlo sobre sobre el espacio transformado mediante la función $\Phi(\mathbf{x})$.
- Como los cálculos se realizan en el espacio original, se evitan los problemas asociados con la maldición de la dimensionalidad.

SVM No Lineales para clasificación: Kernel

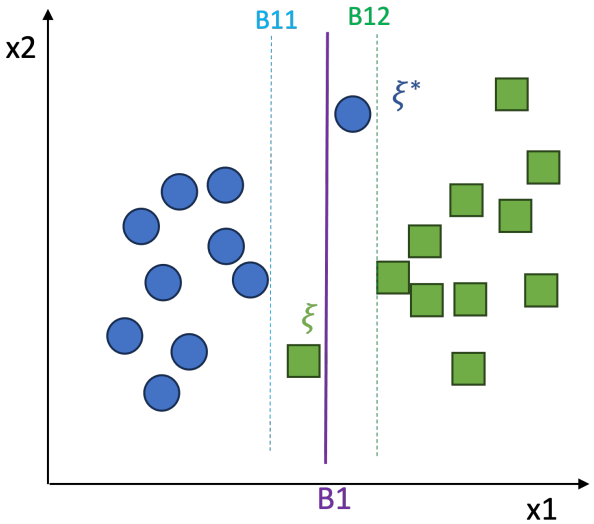
- Ejemplos de Kernel

Tipo SVM	$K(\mathbf{x}, \mathbf{x}')$	Comentarios
Polinomial	$(\mathbf{x}^T\mathbf{x}' + 1)^p$	p la especifica el usuario
Radial o Gaussiano	$e^{(-\frac{1}{2\sigma^2}\|\|\mathbf{x}-\mathbf{x}'\|\|^2)}$	σ^2 la especifica el usuario
Sigmoidal	$\tanh(k\mathbf{x}^T\mathbf{x}' - \delta)$	sólo para algunos valores de k y δ

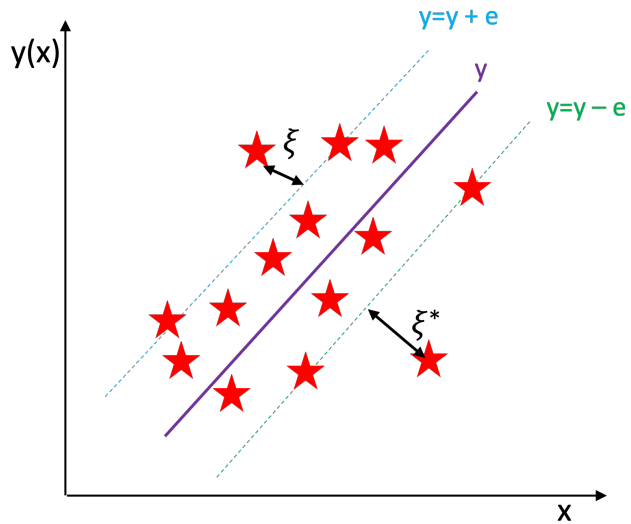
- Los parámetros de la función de Kernel, son los hiperparámetros del modelo (ej: el valor de σ para un Kernel radial) y deben ajustarse experimentalmente mediante una búsqueda de hiperparámetros:
  - El valor C del margen suave
  - El valor σ del Kernel radial
  - El valor p del Kernel polinomial.

SVM para Regresión

- En clasificación, tanto en "soft margin" como en "hard margin", el objetivo era encontrar el hiperplano que separase las dos clases con el máximo margen. En el caso del soft margin permitiendo un cierto error.
- Ahora en regresión, buscamos lo contrario, buscamos aquel hiperplano y máximo margen donde los ejemplos se encuentren dentro de ese margen. En el enfoque "soft margin" permitiremos que algunas instancias estén a una distancia ξ_i fuera de dicho margen,



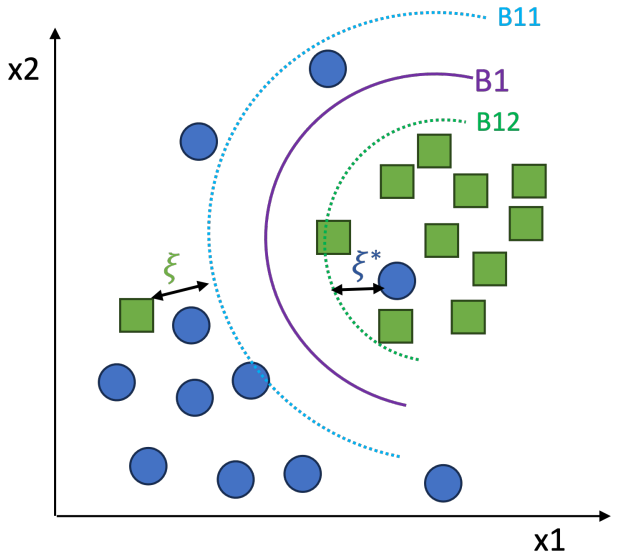
Clasificación Lineal



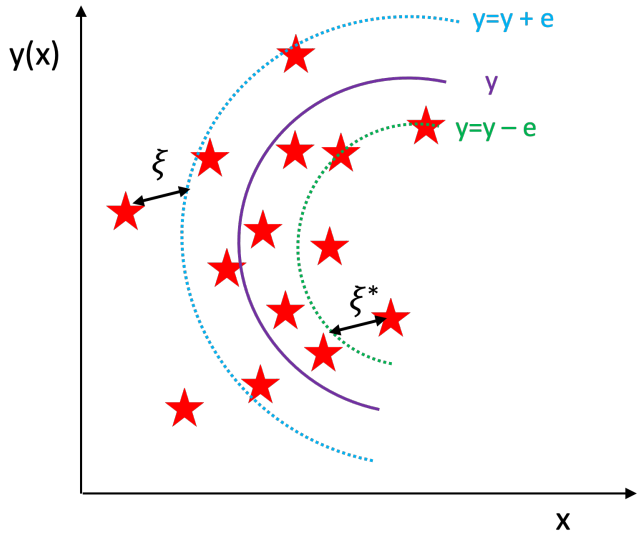
Regresión Lineal

SVM para Regresión

- En el caso de SVM para regresión NO lineales, se sigue la misma filosofía. Se busca que los ejemplos queden dentro del máximo margen encontrado, permitiendo un margen de error para algunas instancias en el caso del "soft margin".



Clasificación NO Lineal



Regresión NO Lineal

- En regresion, al ser el error no simétrico, debemos introducir dos conjunto de variables holgura ξ_i y ξ_i^*, una para los errores positivos y otra para los negativos.

SVM para Regresión: Entrenamiento

- Así, en un problema de regresión y partiendo de que $y = \mathbf{w}^T\mathbf{x} + b$, el problema de optimización para SVR lineal sería:

$$\begin{aligned} \min_{\mathbf{w},b,\boldsymbol{\xi},\boldsymbol{\xi}^*} \quad & f(\mathbf{w}, C, \boldsymbol{\xi}, \boldsymbol{\xi}^*) = \frac{1}{2}\|\mathbf{w}\|_2^2 + C\sum_{i=1}^{N}(\xi_i + \xi_i^*), \\ \text{sujeto a:} \quad & y_i - \mathbf{w}^T\mathbf{x}_i - b \leq \epsilon + \xi_i, \\ & \mathbf{w}^T\mathbf{x}_i + b - y_i \leq \epsilon + \xi_i^*, \\ & \xi_i, \xi_i^* \geq 0 \\ & \forall i = 1, \ldots, N. \end{aligned}$$

- Siendo ϵ representa un margen de tolerancia fijo.

SVM para Regresión: Entrenamiento

- En el problema dual la función a maximizar sería:

$$L_D(\alpha, \alpha^*) = \left[-\frac{1}{2} \sum_{i=1}^{N} \sum_{j=1}^{N} (\alpha_i - \alpha_i^*)(\alpha_j - \alpha_j^*) K(\mathbf{x}_i, \mathbf{x}_j) \right.$$
$$\left. -\epsilon \sum_{i=1}^{N} (\alpha_i + \alpha_i^*) + \sum_{i=1}^{N} y_i (\alpha_i - \alpha_i^*) \right]$$

- y el problema de optimización se definiría de la siguiente forma:

$$\begin{aligned} \max_{\alpha, \alpha^*} \quad & L_D(\alpha, \alpha^*) \\ \text{sujeto a :} \quad & \sum_{i=1}^{N} (\alpha_i - \alpha_i^*) = 0 \\ & 0 \leq \alpha_i, \alpha_i^* \leq C \\ & \forall i \in [1..N] \end{aligned}$$

SVM para Regresión: Inferencia

- Una vez que se obtienen los multiplicadores de Lagrange α_i que resuelven el problema de optimización, podemos calcular los parámetros $\mathbf{w}$ y b que definen el hiperplano de margen máximo:

$$\mathbf{w} = \sum_{i=1}^{N} (\alpha_i - \alpha_i^*) \mathbf{x_i}$$

$$b = \frac{1}{N_{SV}} \sum_{i \in SV} \left(y_i - (\alpha_i - \alpha_j^*) K(\mathbf{x_i}, \mathbf{x_j}) \right)$$

- donde N_{SV} es el número de vectores soporte (puntos con $0 < \alpha_i, \alpha_i^* < C$).

SVM para Regresión: Inferencia

- Así, la función de inferencia para calcular la predicción de un nuevo ejemplo $\mathbf{z}$ es:
  - La inferencia para una SVR lineal sería:

$$f(\mathbf{z}) = \mathbf{w}^T\mathbf{z} + b = \sum_{i=1}^{N}(\alpha_i - \alpha_i^*)\mathbf{x_i}^T\mathbf{z} + b$$

  - La inferencia para una SVR NO lineal utilizando una función kernel:

$$f(\mathbf{z}) = \sum_{i=1}^{N}(\alpha_i - \alpha_i^*)K(\mathbf{x_i}, \mathbf{z}) + b$$

SVM para Regresión: Inferencia

- Como vemos, en regresión se siguen utilizando las funciones kernel y el kernel Trick para la transformación de las dimensiones de las instancias de entrada $\mathbf{x}$. Así, las SVM para regresión tienen las mismas ventajas que las SVM para clasificación.
- En regresión los vectores Soporte son aquellos ejemplos que se encuentran justo en la frontera que define el máximo margen, dentro del cuál se encuentran el resto de ejemplos. Así, los ejemplos dentro del margen tendrán un valor 0 en la fórmula, mientras que los vectores soporte serán los que participan en la ecuación.

SVM No Lineales para clasificación: Conclusiones

- Los vectores describiendo los objetos deben ser numéricos.
- La SVM puede aplicarse a los datos categóricos creando variables dummy binarias por cada categoría.
- Se suelen escalar los datos antes de aplicarlos.
  - Evitar que los atributos con rangos grandes dominen a los de rango más pequeño.
  - Se suele escalar al rango [-1,1] o [0,1].
- La SVM optimiza explícitamente la capacidad de generalización al maximizar el margen del límite de decisión.
- La formulación de SVM de clasificación presentada en este documento se limita a problemas de clasificación binaria.

SVM No Lineales para clasificación: Conclusiones

- Existen adaptaciones para trabajar con múltiples clases. Por ejemplo:
  - Lo más simple es entrenar un clasificador por cada clase donde los ejemplos negativos se obtienen combinando todos los ejemplos que no sean de la clase correspondiente. Luego se clasifica a la clase que se prediga con mayor margen (confianza).
  - Esto se llama One-vs-all.
- La gran limitación de las SVMs es que no escalan bien para datasets masivos.

Referencias

- Libros
  - Bishop, C. M. 2006. Pattern Recognition and Machine Learning. Springer.
  - Cristianini, N., and John Shawe-Taylor. 2000. An Introduction to Support Vector Machines. Cambridge University Press.
- Videos:
  - Support Vector Machines - Patrick Winston - https://www.youtube.com/watch?v=_PwhiWxHK8o
  - Support Vector Machines (https://www.youtube.com/watch?v=eHsErlPJWUU&t=3966s)
  - Kernel Machines - Professor Abu-Mostafa (https://www.youtube.com/watch?v=XUj5JbQihlU&t=3048s)