

Machine Learning

Tema 1. Introducción al machine learning

RAQUEL MARTÍNEZ ESPAÑA

CIENCIA DE LA COMPUTACIÓN E INTELIGENCIA ARTIFICIAL

DEPT. INGENIERÍA DE LA INFORMACIÓN Y LAS COMUNICACIONES

JOSE TOMÁS PALMA

CIENCIA DE LA COMPUTACIÓN E INTELIGENCIA ARTIFICIAL

DEPT. INGENIERÍA DE LA INFORMACIÓN Y LAS COMUNICACIONES

Universidad de Murcia

Máster en Inteligencia Artificial

2026/2027





Introducción

Definiciones Básicas

Problemas y Soluciones del Machine Learning

Preprocesamiento de datos

Técnicas de aprendizaje supervisado

Métricas de rendimiento

Validación de modelos

Resumen



Definición

Machine Learning: “Descubrir regularidades en datos mediante el uso de algoritmos, y mediante el uso de esas regularidades realizar alguna acción”
(C. M. Bishop)

Fases del proceso

- ▶ Obtención y extracción de los datos.
- ▶ Preprocesamiento de datos
- ▶ Creación de Modelos
- ▶ Evaluación y validación de modelos
- ▶ Creación del modelo final y entrega al usuario



Obtención y extracción de datos

- ▶ Obtener los datos para el problema a tratar.
- ▶ Identificar el tipo de problema
- ▶ Conseguir un formato de datos adecuado
- ▶ Considerar y conocer el posible sesgo de los datos o posibles errores

Preprocesamiento de datos

- ▶ ¿Los datos están en el tipo de dato adecuado? ¿Tipo texto: Nominal, numérico? ¿Tipo imagen? ¿Tipo sonido?
- ▶ ¿Todas las variables de mi base de datos son necesarias y relevantes?
- ▶ ¿Tengo instancias suficientes para cubrir todas las necesidades del problema o tengo demasiadas?
- ▶ ¿Tengo valores missing? ¿Los elimino, los imputo, la técnica puede trabajar con ellos?
- ▶ Conozco el posible sesgo de los datos, ¿puedo aplicar técnicas fuzzy?



Creación de Modelos

- ▶ Ante un problema dado, ¿qué técnica tengo que utilizar?
- ▶ Es importante conocer la clasificación de los problemas, en función del objetivo que se persigue y de los datos de los que se dispone.
- ▶ Si se elige mal el tipo de técnica a aplicar el resultado será nefasto.
- ▶ ¿Todas las técnicas me dan el mismo resultado?
- ▶ ¿Todas las técnicas funcionan para todos los problemas?
- ▶ ¿Utilizo todos los datos para crear el modelo?
- ▶ ¿Como evalúo los modelos?



Clasificación de los tipos de técnicas

- ▶ Supervisado: Se conoce previamente el valor de salida (target).
Ejemplo: Clasificación de SPAM, predicción de temperatura.
- ▶ No supervisado: No se conoce previamente el valor objetivo de salida.
Ejemplo: Datos de diferentes figuras geométricas de diferentes colores, pero no se conoce como se agrupan.
- ▶ Semisupervisado: Combina el aprendizaje supervisado y no supervisado para aprovechar conjuntos de datos que contienen pocos ejemplos etiquetados y muchos ejemplos no etiquetados. Ejemplo: Sistema de reconocimiento de voz
- ▶ Por refuerzo: Tiene como finalidad construir modelos que aumenten el rendimiento tomando como base el resultado o la recompensa que se genera por cada interacción realizada. Ejemplo: AlphaZero, aplicación de DeepMind para jugar al ajedrez.

Definiciones Básicas

Aprendizaje Supervisado: Clasificación



Máster en
Inteligencia
Artificial
UMU

- ▶ **Detección de spam:** Se trata de clasificar, mediante identificación de patrones, los correos electrónicos como spam o no spam.
- ▶ **Detección de fraudes:** Distinción entre transacciones legítimas y sospechosas basándose en patrones y características relevantes.
- ▶ **Análisis de sentimientos:** Los algoritmos de clasificación pueden utilizarse para determinar el sentimiento expresado en un texto, como positivo, negativo o neutro. Esto es útil para el análisis de opiniones en redes sociales, comentarios de clientes, revisiones de productos, etc.
- ▶ **Detección de objetos en imágenes:** Especialmente útil en la conducción de coches autónomos.
- ▶ ...

Definiciones Básicas

Aprendizaje Supervisado: Regresión



Máster en
Inteligencia
Artificial
UMU


- ▶ **Predicción del precio de una vivienda** Dado un conjunto de características de una casa (como el tamaño, el número de habitaciones, la ubicación, etc.), se puede utilizar la regresión para predecir su precio en el mercado inmobiliario.
- ▶ **Estimación de la demanda de un producto.** Predicción de la demanda de un producto en función de variables como el precio, la publicidad, las tendencias del mercado, entre otras.
- ▶ **Predicción de la contaminación atmosférica.** Utilizando datos históricos de contaminantes, meteorología y otras variables relevantes, se puede aplicar la regresión para predecir los niveles de contaminación en una ubicación específica.
- ▶ **Análisis de la relación entre variables económicas.** La regresión puede utilizarse para explorar la relación entre variables económicas, como el crecimiento del PIB y el desempleo, con el fin de entender mejor su interdependencia y tomar decisiones políticas o empresariales informadas.
- ▶ ...

Clustering

El **agrupamiento o clustering** consiste en detectar agrupaciones en datos no etiquetados empleando alguna medida de similitud entre ellas. El objetivo es descubrir patrones y estructuras dentro de los datos.

Algoritmos populares para el clustering incluyen el K-Means, el DBSCAN, el clustering jerárquico y Mapas Autoorganizados (SOM).

Ejemplo: K-means



Definiciones Básicas

Aprendizaje NO Supervisado: Asociación



La tarea de **asociación** se centra en descubrir reglas de asociación entre eventos en un conjunto de datos, lo que significa identificar qué elementos tienden a aparecer juntos en dichos eventos. El objetivo es revelar patrones de **co-ocurrencia**. Ejemplo: si un cliente compra una cuchilla y una loción para después del afeitado, hay un 80% de posibilidades de que el cliente compre también crema de afeitado.

La asociación es una tarea no supervisada, los datos a menudo provienen de transacciones o eventos, y no se requieren etiquetas previas.

Algoritmos como Apriori se utilizan comúnmente para generar reglas de asociación en los datos, reglas como "Si A, entonces B". Estas reglas se utilizan en análisis de mercado y sistemas de recomendación.




En el contexto del machine learning, el **conjunto de hipótesis** se refiere a un conjunto de funciones o modelos matemáticos que se utilizan para aproximar una relación desconocida entre las **entradas (x)** y las **salidas deseadas o targets (t)** de un conjunto de datos.

Cada hipótesis representa una posible aproximación de la relación subyacente en los datos.


El objetivo del **aprendizaje supervisado** es encontrar la hipótesis que mejor se ajuste a los datos de entrenamiento manteniendo la capacidad de hacer predicciones precisas para datos nuevos (**capacidad de generalización**).



Subajuste y sobreajuste



Ajuste pobre



Sobreajuste (“overfitting”)




¿Es posible tener error 0?

Siempre buscamos que la salida del modelo de predicción sea lo más precisa posible. Sin embargo, no siempre será posible reducir todo el error. La salida de un modelo viene determinado por el Error esperado E que hemos visto :

$$E = \text{Sesgo}^2 + \text{Varianza} + \text{Ruido}$$

- ▶ Sesgo: Representa el error asociado a la simplicidad del modelo.
- ▶ Varianza: Representa la variabilidad del modelo frente a distintos conjuntos de entrenamiento. Pequeños cambios en el conjunto de entrenamiento pueden producir grandes errores.
- ▶ Ruido: Representa el error proveniente de los datos, por ejemplo datos missing, datos mal medidos, etc. Este error hay que asumirlo y no se puede ajustar.


Representación gráfica: Error esperado vs. Complejidad



- ▶ Modelos complejos (alta capacidad, flexibles) producen varianzas elevadas y sesgos bajos
- ▶ Modelos simples (baja capacidad, rígidos) producen varianzas bajas y sesgos elevados



Solución: Compromiso sesgo-varianza





¿Cómo evitar el sobre-ajuste?

- ▶ **“Early stopping”**: Se detiene el entrenamiento del modelo antes de que alcance la convergencia total en los datos de entrenamiento. Se emplea un conjunto de parada.
- ▶ **Regularización L1 y L2** (Regresión Ridge y Lasso): Se agregan términos de penalización (normas L1 ó L2 de los coeficientes del modelo) a la función de pérdida durante el entrenamiento. Son técnicas **“Weight decay”**.
- ▶ **Dropout**: Es una técnica específica para redes neuronales. Durante el entrenamiento, aleatoriamente se desactivan (ponen a cero) ciertas neuronas en cada paso. Esto evita que el modelo dependa demasiado de neuronas específicas y promueve una mejor generalización.
- ▶ **Aumento de datos**: Se aumenta el tamaño del conjunto de datos mediante técnicas como la rotación, la inversión y el recorte de imágenes. Esto ayuda a exponer al modelo a una mayor variedad de datos y reduce el riesgo de sobreajuste.
- ▶ **Feature Selection**: La selección adecuada de características es esencial para evitar el sobreajuste. Eliminar características irrelevantes o altamente correlacionadas puede reducir la complejidad del modelo y mejorar su generalización.
- ▶ **Ensemble learning**: Combina múltiples modelos más simples y menos propensos al sobreajuste. El Bagging (Bootstrap Aggregating) y el Boosting son ejemplos de ensemble learning.



¿Cómo evitar el **sub**-ajuste?


Evitar el sub-ajuste es tan importante como evitar el sobre-ajuste

- ▶ Aumentar la complejidad del modelo
- ▶ Aumentando el tiempo de entrenamiento
- ▶ Añadiendo más características
- ▶ Reducir la regularización

Evitar el sobreajuste: “early stopping”

Sobreentrenamiento: demasiados ciclos adaptan en exceso la red a las muestras de entrenamiento, no generalizando bien

Para evitarlo (mantener la generalización), se emplea un conjunto adicional, extraído del conjunto de entrenamiento llamado **conjunto de validación** (en este caso, actúa como conjunto de parada).





Evitar el sobreajuste: “Weight decay”

Incorporación de una penalización en la función de coste (como la regularización en las técnicas de regresión).

- ▶ La penalización estándar añade un término que incluye los pesos al cuadrado (regularización L2).
- ▶ En ocasiones, funciona mejor penalizar usando el valor absoluto de los pesos (regularización L1), con lo que muchos pesos acaban siendo exactamente 0.
- ▶ Otras veces, puede ser recomendable utilizar una penalización que no tenga apenas efecto sobre pesos grandes (para permitir algunos pesos grandes en la red).



Cuando tenemos los datos, necesitamos analizarlos, ver su calidad y entender su naturaleza.

Problemas a considerar:

- ▶ ¿Puedo trabajar con nominales?: Aplicar técnicas de variables dummy.
- ▶ ¿Puedo trabajar con numéricos?: Discretización de valores.
- ▶ ¿Necesito trabajar con datos fuzzy?: Discretización en valores fuzzy.
- ▶ Tengo muchas características: Aplicar técnicas de selección de características.
- ▶ Tengo demasiadas instancias: Aplicar técnicas de selección de instancias o de creación de instancias artificiales.
- ▶ Tengo desbalanceo de clases: Aplicar técnicas para balancear las clases.
- ▶ Tengo datos missing: Aplicar técnicas de imputación de valores missing.
- ▶ Tengo outlier: Eliminación de outlier.



- ▶ Los datos reales pueden contener gran cantidad de datos potencialmente incorrectos: fallos en los instrumentos de adquisición, error computacional o humano, error de transmisión,
- ▶ Por lo tanto, los errores pueden ser debidos a diferente causas:
 - ▶ **Datos incompletos:** pueden faltar algunos atributos de interés, o alguno valores de los mismos, ..
 - ▶ **Datos con ruido** o errores, outliers e incluso datos duplicados.
 - ▶ **Datos inconsistentes** en la forma de discrepancias en códigos y nombres, o en datos duplicados:
 - ▶ Edad="42" y Fecha de Nacimiento= "12/07/2015"
 - ▶ Algunos objetos se avalúan en la escala "1,2,3" y otros en la escala "A,B,C".
 - ▶ **Errores intencionados** como forma de encubrir la falta de algunos datos
 - ▶ Encontrarnos la misma fecha de nacimiento para todas las personas, o gran parte de ellas.



- ▶ Los **datos missing** pueden introducir varios problemas:
 - ▶ Pérdida de eficacia: se extraen menos patrones y, además, las conclusiones pueden ser estadísticamente menos concluyentes.
 - ▶ Complicaciones a la hora de analizar los datos, ya que muchas técnicas no están preparadas para gestionarlos.
 - ▶ y si pueden gestionarlos, puede que ignoren todo el objeto o el atributo.
 - ▶ En el caso de que se requieran calcular valores agregados pueden impedir el cálculo.
 - ▶ Pueden producir sesgos en los modelos resultantes al aplicar los métodos a los datos ausentes o a los datos completos.



- ▶ Si los datos proceden de una base de datos, generalmente los datos ausentes están representados como nulos.
- ▶ Pero en la mayoría de los casos puede resultar difícil detectarlos, es el caso de los *nulos camuflados*:
 - ▶ Las restricciones de integridad del sistema no nos permiten la introducción de nulos en campos con formato: direcciones, teléfonos, códigos postales o número de tarjetas de crédito, segundo apellido en extranjeros.
- ▶ Para el tratamiento de estos datos hay que conocer su causa:
 - ▶ Algunos valores faltantes expresan situaciones relevantes. La falta del teléfono puede implicar que la persona no quiere ser molestada.
 - ▶ Algunos datos realmente no existen.
 - ▶ Datos incompletos después de una combinación.



- ▶ No hacer nada. Algunos métodos son robustos ante este hecho (por ejemplo, árboles de decisión).
- ▶ Filtrar (eliminar) aquellos atributos con valores nulos.
 - ▶ Es una solución extrema.
 - ▶ Necesaria en el caso de un alto porcentaje de nulos.
 - ▶ En otros casos podemos encontrar otro atributo dependiente con una mayor calidad.
- ▶ Filtrar (eliminar) el objeto:
 - ▶ Se suele hacer cuando en un problema de clasificación cuando la clase está ausente.
 - ▶ No es efectivo cuando el porcentaje de ausentes varía mucho entre atributos.
 - ▶ puede introducir sesgos en los datos.



- ▶ Reemplazar el hueco por un valor.
 - ▶ Manualmente si no hay muchos o por una constante global.
 - ▶ Por un valor que preserve la media o la varianza para datos numéricos o la moda para nominales.
 - ▶ **Imputación:**
 - ▶ Usar el valor medio, de todos los valores de los atributos o sólo de los que pertenecen a la misma clase
 - ▶ Usar el valor más probable
 - ▶ predecir el valor mediante alguna técnica predictiva (regresión o clasificación) como knn, árboles, regresión,...
 - ▶ Mediante técnicas específicas. Por ejemplo, determinación del sexo a partir del nombre o el código postal a partir de la dirección.



- ▶ Aunque la imputación es la técnica más frecuente, hay que ser consciente de que:
 - ▶ se está perdiendo información, no sabremos que el dato era ausente.
 - ▶ puede que el dato que estamos introduciendo sea erróneo.
- ▶ En algunos casos, se puede crear un atributo adicional booleano que indique que el dato era ausente.



- ▶ Entendemos por **Ruido** un error o varianza aleatoria en una medición de una variable, puede ser un valor outlier.
- ▶ Existen varios métodos para suavizar los datos para eliminar el ruido.
 - ▶ **Discretización.** Este método permite suavizar un conjunto de valores ordenados consultando su vecindad.
 - ▶ Los valores ordenados se distribuyen en una serie de categorías con el mismo número de elementos (*equal frequency*) o el mismo tamaño (*equal width*).
 - ▶ Se sustituyen los valores de cada categoría un un valor: media (*smooth by means*), mediana (*smooth by median*) o el extremo más cercano (*smooth by bin boundaries*).
 - ▶ **Regresión.** Se realiza un proceso de regresión para ajustar la función y sustituir los valores por los predichos por la función. Se pueden utilizar multitud de métodos diferentes.
 - ▶ **Clustering.** El proceso de clustering o agrupamiento nos permite identificar los outliers.



- ▶ Antes de proceder a resolver los problemas planteados por los datos ausentes y el ruido, se deben detectar las discrepancias en los datos.
- ▶ Las inconsistencias pueden ser debidas a:
 - ▶ Formularios de entrada de datos mal diseñados o errores en los dispositivos de entrada.
 - ▶ Error humano en la introducción de datos o errores deliberados.
 - ▶ Obsolescencia de los datos, o que los datos hayan sido recogidos para otros usos.
 - ▶ Uso inconsistente del formato de datos o de los códigos.



- ▶ Uso de metadatos: Dominio y tipo de los atributos, valores permitidos, longitudes permitidas, análisis de su distribución.
- ▶ Uso inconsistente de los formatos, por ejemplo, el uso de diferentes formatos para las fechas.
- ▶ En los casos que se pueda aplicar: la regla de la unicidad, la regla de la consecutividad y la regla de la nulidad.
- ▶ Para resolver este problema podemos utilizar dos tipos de herramientas:
 - ▶ Las herramientas de **depuración de datos** (data scrubbing) utilizan conocimiento del dominio para detectar y corregir errores.
 - ▶ Las herramientas de **auditoría de datos** se centran en encontrar discrepancias mediante un análisis que permita descubrir reglas y relaciones en los datos y detectar las violaciones a las mismas.

Preprocesamiento de datos I

Variables con varianza cercana a cero



- ▶ En muchas situaciones podemos tener variables que tiene un sólo valor (variables de varianza cero). En este caso hay modelos que no pueden tratar con este tipo de variables o muestran un comportamiento inestable.
- ▶ En otros casos pueden existir variables en las que un valor se presenta con una baja frecuencia, es decir, variables con varianza cercana a zero o muy desbalanceadas.
 - ▶ Estas variables se pueden convertir en variables con varianza cero cuando validamos por validación cruzada o bootstrap, afectando al resultado de la técnica elegida.
- ▶ Debido a esto, en muchos casos se suelen detectar y eliminar aquellas variables con varianza cercana a cero.

Preprocesamiento de datos II

Variables con varianza cercana a cero



- ▶ Para detectarlas se utilizan dos métricas de forma conjunta:
 - ▶ el ratio entre la frecuencia del valor más frecuente y la frecuencia del segundo valor más frecuente (ratio de frecuencia): 1 para variables balanceadas, grande para variables mal balanceadas.
 - ▶ el porcentaje de valores únicos sobre el total objetos, que se aproximará a cero a medida que la granularidad de la variable aumenta.
- ▶ Si el ratio de frecuencia supera un límite establecido y el porcentaje de valores único cae por debajo de un límite establecido, podemos considerar la variable como una variable con varianza cercana a cero.



- ▶ Las técnicas de transformación nos permiten preparar los datos de forma apropiada para poder aplicar las distintas técnicas de minería de datos.
- ▶ Básicamente la mayor parte de las técnicas de transformación de datos es aplicación sobreyectiva, es decir, a cada valor original le hace corresponder un valor transformado, pero varios valores originales pueden estar asociados a un mismo valor transformado.



- ▶ Entre las técnicas de transformación de datos tenemos:
 - ▶ **Suavizado:** para eliminar el ruido tal y como acabamos de ver.
 - ▶ **Agregación:** cuando queremos resumir o agregar datos. Por ejemplo, acumular las ventas mensuales en las anuales. Este tipo de transformación se suele realizar en la construcción de los cubos de datos.
 - ▶ **Generalización:** de datos de bajo nivel o primitivos a datos de nivel mas alto. Para ello es necesario la existencia de jerarquías conceptuales que definan el nivel de abstracción de los conceptos.
 - ▶ **Creación de atributos** a partir de lo ya existentes (algunas técnicas las veremos en el siguiente capítulo).
 - ▶ **Normalización** que permite escalar los datos a un determinado rango, por ejemplo, $[0, 1]$ o $[-1, 1]$.



- ▶ La idea básica consiste en escalar los valores de una variable a un rango determinado.
- ▶ Existen técnicas de minería de datos que requieren que los datos estén normalizados (máquinas de soporte de vectores o técnicas de agrupamiento) o qué mejoran su rendimiento si previamente se normalizan los datos (redes neuronales).
- ▶ En las técnicas basadas en el concepto de distancia, la normalización evita que los variables con rangos mayores predominen sobre las de rangos menores.
- ▶ Existen numerosos métodos de normalización de los que destacamos:
normalización min-max, normalización por transformada z y normalización por escalado decimal



- ▶ **Normalización Min-max.** Se realiza una transformación lineal sobre los datos originales.
 - ▶ Supongamos que tenemos una variable A cuyo rango es $[min_A, max_A]$.
 - ▶ Esta transformación nos va a permitir transformar los valores v de la variable A en unos nuevos valores v' en el rango $[min'_A, max'_B]$, mediante la transformación:

$$v' = \frac{v - min_A}{max_A - min_A} (max'_A - min'_A) + min'_A$$

Esta transformación mantiene las relación entre los datos originales.



- ▶ **Normalización por transformada z (z-score).** En este caso, los valores de un variable A son normalizados en función de la su media $\bar{A}$ y su desviación típica, σ_A :

$$v' = \frac{v - \bar{A}}{\sigma_A}$$

- ▶ Este método se suele utilizar cuando los rangos de las variables son desconocidos, o existen valores anormales que dominan en la normalización min-max.
- ▶ Es un centrado y un escalado:
 - ▶ media 0
 - ▶ desviación típica 1
- ▶ Esto permite obtener:
 - ▶ datos independientes de la unidad o de la escala
 - ▶ variables con la misma varianza y media
- ▶ Es un cambio de unidad y no tiene efecto a la hora de comparar variables
- ▶ Las relaciones de correlación se mantienen.

Preprocesamiento de datos IV

Normalización



Máster en
Inteligencia
Artificial
UMU




Figure: Datos no escalados




Figure: Datos Escalados




- ▶ Tipos de discretización:
 - ▶ **Supervisada o no supervisada.**
 - ▶ Si la técnica de clasificación utiliza la información sobre la clase estaremos en un caso de **discretización supervisada**.
 - ▶ Al utilizar la información la distribución de clases, este tipo de discretización puede facilitar las tareas de clasificación.
 - ▶ En otro caso, hablaremos de **discretización no supervisada**.
 - ▶ **Local o global.**
 - ▶ Los métodos **globales** aplican los mismos puntos de corte a todas las instancias.
 - ▶ Los métodos **locales** utilizan diferentes puntos de corte a diferentes conjunto de instancias.
- ▶ **Ascendente (bottom-up) o descendente (top-down).**
 - ▶ **Top-down (splitting).** Se comienza seleccionando uno o más puntos para dividir el rango del atributo. Se va repitiendo el proceso con cada nuevo intervalo hasta que no se pueda dividir más.
 - ▶ **Bottom-up (merging).** Se van fusionando puntos cercanos entre sí para formar intervalos y repetir el proceso con los nuevos intervalos.

Preprocesamiento de datos II

Discretización



Máster en
Inteligencia
Artificial
UMU





Técnicas más comunes. Entre las técnicas más utilizadas vamos a analizar:

- ▶ **Binning** (descendente, no supervisada). Que ya hemos introducido al hablar del suavizado.
- ▶ **Análisis del histograma** (descendente, no supervisada).
- ▶ **Discretización Basada en la Entropía** (descendente supervisada).
- ▶ **Fusión de intervalos mediante análisis χ^2** (ascendente, supervisado).
- ▶ **Análisis de cluster** (ascendente o descendente, no supervisado).

Preprocesamiento de datos

De variables categóricas a numéricas



- ▶ **Variable categórica:** Variable cuyo dominio lo forman un número finito etiquetas/categorías.
 - ▶ **Nominales:** etiquetas/categorías no relacionadas
 - ▶ **Ordinales:** etiquetas/categorías ordenadas.
- ▶ Existen técnicas que pueden manipular datos categóricos y otras que sólo admiten variables numéricas
- ▶ **Técnicas:**
 - ▶ Codificación ordinal
 - ▶ Codificación One-Hot
 - ▶ Codificación por variables dummy



- ▶ Se aplica a las variables categóricas ordinales.
- ▶ La idea es mantener el orden de las categorías asignando un número entero a cada categoría.
- ▶ Por ejemplo, las calificaciones $\{A, B, C, D, E, F\}$ se podrían codificar como $\{5, 4, 3, 2, 1, 0\}$
- ▶ !! Cuidado con hacer esta transformación en la variable a predecir !!
 - ▶ Podemos estar prediciendo valores entre las categorías, p.e. 4.5, que puede no tener sentido
 - ▶ En la mayoría de los casos la variable a predecir se puede (y debe) mantener como categórica.



- ▶ Se aplica a las variables categóricas nominales.
 - ▶ No existe una relación entre las categorías.
 - ▶ La anterior codificación no tiene sentido aplicarla porque estaríamos imponiendo el orden.
- ▶ Procedimiento:
 - ▶ Se crea una nueva variable binaria para cada categoría.
 - ▶ Cada nueva variable tomará el valor 1 si está presente la categoría, 0 en caso contrario

Ejemplo:

- Nacionalidad = {*Alemana*, *Francesa*, *Italiana*, *Portuguesa*}

id	Nacionalidad
i_1	Alemana
i_2	Portuguesa
i_3	Italiana
i_4	Francesa

id	Nac_Ale.	Nac_Fra.	Nac_Ita	Nac_Por.
i_1	1	0	0	0
i_2	0	0	0	1
i_3	0	0	1	0
i_4	0	1	0	0

- ¿Qué problema plantea esta codificación?



- ▶ La codificación One-Hot tiene el problema de introducir información redundante
 - ▶ Conocer el valor asignado a tres categorías permite inferir el valor asociado a la otra categoría
 - ▶ Esto introduce un problema de multicolinealidad¹
 - ▶ Problemático en redes neuronales o técnicas de regresión sin regularización.
- ▶ Solución:
 - ▶ Para N categorías se crean $N - 1$ variables
 - ▶ La categoría excluida se codifica mediante un 0 en el resto de variables creadas.
- ▶ Este tipo de codificación es el ideal para el caso de dos categorías

Ejemplo

- Nacionalidad = {*Alemana, Francesa, Italiana, Portuguesa*}

id	Nacionalidad
i_1	Alemana
i_2	Portuguesa
i_3	Italiana
i_4	Francesa

id	Nac_Fra.	Nac_Ita	Nac_Por.
i_1	0	0	0
i_2	0	0	1
i_3	0	1	0
i_4	1	0	0

¹Ver a partir de la 82 del libro [An Introduction to Statistical Learning](#) para ver las implicaciones de las variables *dummy* en una regresión lineal.



- ▶ Las frecuencias relativas de las clases en un problema de clasificación tiene un impacto importante en la eficacia del modelo.
- ▶ **Datos desbalanceados:** Cuando una o más clases presentan proporciones muy bajas respecto a las otras clases en el conjunto de entrenamiento.
- ▶ Ejemplo:
 - ▶ Supongamos que tenemos un conjunto de datos agrupados en dos clases: un 94% A y un 6% B.
 - ▶ Utilizando estos datos obtenemos un modelo con una precisión del 95%.
 - ▶ ¿Es bueno el modelo?
 - ▶ Paradoja de la exactitud (Accuracy Paradox)



¿Por qué es necesario reducir la dimensionalidad?

- ▶ La complejidad de la mayoría de algoritmos de aprendizaje depende de la dimensión del conjunto de entrada (número de variables) y del número de instancias.
 - ▶ **La maldición de la dimensionalidad:** A medida que aumentamos el número de variables se reduce la densidad de los datos, con lo que la determinación de los hipersuperficies de clasificación se vuelve más difícil.
 - ▶ La precisión de las consultas y su eficiencia se degrada rápidamente a medida que aumenta la dimensionalidad.
 - ▶ a representatividad de los datos (su distribución) requiere de un número de instancias que crece exponencialmente con su dimensión.
 - ▶ Modelos simples son más robustos en conjuntos pequeños.



- ▶ La dimensión intrínseca del problema suele ser pequeña.
 - ▶ Sólo un subconjunto de las variables de entrada suele tener relevancia para el proceso de aprendizaje.
- ▶ Cuando tenemos menos variables para explicar los datos:
 - ▶ nos podemos hacer una mejor idea de los procesos que generan dichos datos, y
 - ▶ esto facilita la extracción de conocimiento.
- ▶ Al representar los datos en unas pocas dimensiones facilitamos su representación gráfica y su análisis visual.



- ▶ Existen dos tipos de métodos para la reducción de la dimensionalidad:
Extracción de Características y Selección de Características.
- ▶ **Extracción de Características.**
 - ▶ **Objetivo:** Encontrar k dimensiones que sean combinación de las d ($d > k$) dimensiones originales.
 - ▶ Básicamente consiste en encontrar una transformación desde un espacio de dimensión d a un espacio con menos dimensiones, k .
 - ▶ Hacen uso de todas las dimensiones originales.
 - ▶ Supervisados: maximizar la discriminación entre clases.
 - ▶ No supervisados: minimizar la pérdida de información.



► Técnicas:

- Análisis lineal discriminante (LDA)
- Análisis discriminante generalizado (GDA)
- Análisis de componentes principales (PCA) y su versión con funciones Kernel.
- Modelos de variables latentes basados en procesos gaussianos constreñidos
- “t-distributed stochastic neighbor embedding” (t-SNE)
- “Uniform Manifold Approximation and Projection” (UMAP)
- Técnicas basadas en Deep Learning: Convolución, embeddings, transformers,...



► Selección de Características.

- **Objetivo:** Encontrar que k dimensiones, de las d dimensiones originales, aportan la mayor cantidad de información, descartando el resto ($d - k$).
- Básicamente, se trata de encontrar el subconjunto óptimo de dimensiones de acuerdo con alguna determinada función objetivo.
- Sólo se selecciona un subconjunto de las dimensiones originales.
- Se trabaja directamente con las dimensiones originales sin realizar transformación alguna.



- ▶ La **Selección de Características** trata de encontrar el subconjunto de características óptimo de acuerdo con un determinado criterio de selección.
- ▶ Dicho subconjunto óptimo de características debe garantizar que el proceso de construcción de modelos se pueda desarrollar con totales garantías, minimizando el número de características.




- ▶ El **subconjunto óptimo** de características es el subconjunto mínimo que permite construir una hipótesis consistente con los datos de entrenamiento.
 - ▶ Podemos utilizar todos los datos o sólo los de entrenamiento.
 - ▶ El subconjunto se puede sobreajustar a los datos de entrenamiento.
- ▶ Sea F el conjunto de todas las características y C el conjunto de clases.
- ▶ El subconjunto óptimo es el conjunto mínimo de características G tal que $P(C|G)$ es igual, o lo más próxima posible, a $P(C|F)$.
 - ▶ La selección del conjunto óptimo se puede realizar sobre todo el conjunto de datos o sólo sobre los de entrenamiento.



- ▶ El proceso de selección de características se desarrolla en dos fases:
 1. Generación de subconjuntos de características. Se van generando los distintos subconjunto de características candidatos a ser el subconjunto óptimo.
 2. Se evalúan cada uno de los subconjuntos candidatos hasta que se cumpla algún criterio de parada.
- ▶ Finalmente, se procede a generar un modelo teniendo en cuenta sólo las características seleccionadas.

Preprocesamiento de datos IV

Selección de Características






- ▶ Dependiendo de si se lleva a cabo una generación de subconjuntos y posterior evaluación de los mismos:
 1. **Métodos basados en selección de conjuntos de características**, que son aquellos que incluyen alguna estrategia para la generación y evaluación de características.
 2. **Métodos de evaluación de características (“Feature ranking” o “rankers”)** que son aquellos que no realizan ninguna generación de subconjuntos, evaluando sólo las variables, estableciendo un “ranking” de acuerdo con alguna medida.



- ▶ El proceso de selección de características se puede plantear como un proceso de búsqueda en el espacio de posibles subconjuntos de características.
- ▶ Una búsqueda exhaustiva, en la mayoría de los casos, no es computacionalmente posible.
 - ▶ con $n = 12$ características tendríamos 4096 subconjuntos y para $n = 100$ características tendríamos 10^{100} .
 - ▶ Incluso en el caso de que estuviéramos buscando exactamente un subconjunto de tamaño m el número de posibles subconjuntos sería:

$$\binom{n}{m} = \frac{n!}{(n-m)!m!}$$

que puede ser mucho menor que 2^n , pero desde el punto de vista computacional muy grande.



Ejemplo de espacio de estado para 4 características.



Generación de subconjuntos: Estrategias de búsqueda

- ▶ Se pueden utilizar diferentes estrategias de búsqueda en el espacio de posibles subconjuntos:
 - ▶ **Exhaustiva.** Se barre todo el espacio de posibles subconjuntos:
 - ▶ Se puede recorrer el espacio en profundidad o en anchura.
 - ▶ Sólo es posible para pocas características.
 - ▶ Es la única forma de garantizar encontrar el subconjunto óptimo.
 - ▶ **Heurística.** Disponen de alguna información sobre qué subconjunto es el más prometedor.
 - ▶ No garantizan que el subconjunto encontrado sea el óptimo.
 - ▶ Normalmente encuentran una buena solución en un tiempo razonable.



- ▶ **Aleatoria.** Se parte de una configuración inicial formada por un conjunto finito de posibles subconjuntos.
 - ▶ Mediante una pequeña transformación, se va modificando la configuración inicial para dirigir la búsqueda hasta la solución final.
 - ▶ No garantiza la solución óptima.



Generación de subconjuntos: Dirección de Búsqueda

- ▶ Para definir una estrategia de búsqueda primero debemos definir **la dirección de búsqueda**:
 - ▶ **Hacia delante (Forward)**. Se empieza con el conjunto vacío y se van añadiendo una característica no seleccionada cada vez.
 - ▶ **Hacia atrás (Backward)**. Se empieza con todas las características y se va eliminando una característica cada vez.
 - ▶ **Bidireccional**. Se comienza por los dos extremos del espacio de búsqueda y se realiza de forma paralela una búsqueda hacia delante y otra hacia detrás.



- ▶ Dependiendo de cómo se realice la evaluación de cada uno de los subconjuntos tenemos:
 - ▶ **Métodos basados en filtros**, que evalúan la relevancia de las características sin tener en cuenta la tarea que se va a realizar con los datos.
 - ▶ **Métodos basados en envoltura (wrappers)**, en los que cada subconjunto candidato es evaluado a través de la eficacia de un predictor. Por lo tanto, se tiene en cuenta la tarea que se va a realizar.
 - ▶ **Métodos empotrados (embedded)**, en los que el proceso de selección de variables está integrado en la técnica de construcción del predictor.



Métodos basados en Filtros


- ▶ Los métodos basados en filtros evalúan la relevancia de las características teniendo en cuenta sólo las propiedades intrínsecas de las mismas, ya que no tienen en cuenta la tarea que se va a realizar.
- ▶ Son independientes de la técnica de clasificación/regresión que a realizar.
 - ▶ La búsqueda en el espacio de subconjunto de características está desacoplado del de las hipótesis.
- ▶ No se ven sesgados por la influencia de una determinada técnica de clasificación/regresión.

Preprocesamiento de datos XIII

Selección de Características



Máster en
Inteligencia
Artificial
UMU



Esquema general de un método de selección basado en filtros



- ▶ Ejemplos de medidas de relevancia en los métodos de selección de características mediante filtros pueden ser
 - ▶ **Ratio de inconsistencias.** Una inconsistencia aparece cuando dos instancias iguales, de acuerdo con el subconjunto de características evaluados, pertenecen a clases distintas.
 - ▶ **Medidas basadas en distancias,** que se centran en encontrar el subconjunto de características que mejor separe las diferentes clases. Ejemplos de medidas ya han sido analizadas en el capítulo de técnicas de clustering.



Métodos Wrappers


- ▶ Este tipo de métodos, la evaluación de cada uno de los subconjuntos candidatos se realiza mediante la construcción de un clasificador (o regresor).
 - ▶ Por lo tanto, como medida de evaluación utilizan la capacidad predictiva del clasificador.
- ▶ De esta forma, se selecciona el subconjunto de características que produce el mejor clasificador.
- ▶ Ventajas:
 - ▶ Producen mejores resultados al estar orientados al problema de clasificación.
- ▶ Desventajas:
 - ▶ Tienen un mayor riesgo de sobreajuste que los filtros.
 - ▶ Son más costosos computacionalmente.

Preprocesamiento de datos XVI

Selección de Características



Máster en
Inteligencia
Artificial
UMU



Esquema general de un método de un wrapper



Métodos embebidos

- ▶ En los métodos embebidos, la selección de características está integrada en el proceso de construcción del modelo.
 - ▶ Al mismo tiempo que se ajustan los parámetros internos, la técnica de aprendizaje selecciona las características más relevantes.
- ▶ Computacionalmente, al igual que los métodos basados en filtros, son menos costosos que los métodos “wrappers”, con la ventaja sobre los filtros de que, además, generan el modelo.
- ▶ Al igual que ocurre con los métodos “wrappers”, tienen la ventaja de que la selección de características está sesgada hacia una mejor eficiencia del proceso de clasificación/regresión.



Algunos ejemplos:

- ▶ Técnicas basadas en árboles de decisión, como por ejemplo, C5.0, Random Forest, Gradient Boosting.
 - ▶ Este tipo de técnicas permite analizar la interacción entre características (métodos multivariantes).
- ▶ Modelos con regularización, como por ejemplo LASSO o Elastic Nets
 - ▶ Estas técnicas de regularización se utilizan normalmente en modelos lineales (SVM, regresión lineal o logística) penalizando los coeficientes de las características menos significativas.
- ▶ La mayoría de este tipo de técnicas permiten obtener un ranking de características.
 - ▶ Importancia de las variables en las técnicas basadas en árbol.
 - ▶ Los valores de los coeficientes en las técnicas basadas en regularización.



La selección de instancias se ocupa de seleccionar un subconjunto de los datos de modo que el problema de Reconocimiento de Patrones se resuelva con la “misma efectividad” que se lograría de usar todos los datos. ¿Por qué es necesario?

- ▶ El número de instancias puede incidir negativamente en el tiempo de entrenamiento o respuesta.
- ▶ Datos redundantes, no aportan información.
- ▶ Puede reducir la complejidad del modelo.
- ▶ Elimina instancias ruidosas que deterioran la eficiencia.



La selección de instancias permite:

- ▶ Que los algoritmos de aprendizaje trabajen con grandes volúmenes de datos.
- ▶ Enfocarse solo en aspectos de los datos que son de interés en el dominio del problema.
- ▶ Limpiar los datos de modo que las instancias redundantes o ruidosas sean descartadas, mejorando la calidad de los datos.

La selección de instancias se diferencia de un simple muestreo en que se guía por un criterio de irrelevancia o ruido de los datos descartados.

¿Cómo identificar o seleccionar datos relevantes dentro de una colección inmensa de instancias? *Balance entre el tamaño de la muestra y el desempeño del algoritmo de aprendizaje.*



Clasificación de los tipos de técnicas de selección de Instancias

- ▶ Condensación: Estas técnicas descartan instancias que no influyen en la clasificación, tienden a conservar puntos cercanos a la frontera de decisión.
- ▶ Edición: también llamado filtro de ruido, eliminan instancias situadas en otra región. Borran las instancias en la frontera o de diferente clase que sus vecinos,
- ▶ Prototipado: Se construyen prototipos que representan a un conjunto de instancias, no tienen que ser instancias del conjunto de datos original.



Clasificación de las técnicas de selección según dirección de búsqueda:

- ▶ **Incrementales:** Comienzan por un conjunto vacío S y añaden instancias si estas cumplen un criterio determinado. El orden en que se analizan las instancias es muy importante. Estas técnicas permiten analizar nuevas instancias sin rehacer todo el proceso.
- ▶ **Decrementales:** Eliminan instancias del conjunto original hasta que se cumplan ciertos criterios de parada. Estas técnicas también son sensibles, aunque en menor medida, al orden en que se analizan las instancias. En general son computacionalmente más costosos que los algoritmos incrementales.
- ▶ **Batch:** Similar a los incrementales, pero no se borran las instancias inmediatamente, solo se dejan marcadas para su eliminación al concluir la iteración. Como inconveniente, pueden borrar grupos completos de instancias.
- ▶ **Híbridos:** Comienzan por un conjunto preseleccionado de instancias de donde añaden o eliminan instancias que cumplan determinadas condiciones.



Algunos de los métodos más conocidos de selección de instancias:

- ▶ Condensed Nearest Neighbor
- ▶ Selective Nearest Neighbour
- ▶ Generalized Condensed Nearest Neighbor
- ▶ Edited Nearest Neighbor
- ▶ Repeated Edited Nearest Neighbor
- ▶ Support Vector Machine
- ▶ Support Vector Machine k-NN
- ▶ Metodos basados en algoritmos evolutivos
- ▶ ...



- ▶ Árboles de Decisión(ID3, C4.5, C5.0)
- ▶ Maquinas de soporte vectorial (SVM)
- ▶ Redes neuronales (MLP)
- ▶ Naïve Bayes (Naïve Bayes multinomial, Naïve Bayes Bernoulli y Naïve Bayes gaussiano)
- ▶ K-vecinos más cercanos (KNN)
- ▶ Ensamblados(Random Forest, XGBoost, Bagging,...)



Métricas

Para evaluar las prestaciones (**rendimiento**) de un modelo de machine learning ya entrenado, se utilizan diversas métricas de evaluación dependiendo del tipo de problema (clasificación, regresión, etc.) y las características del conjunto de datos.

Métricas más comunes:

- ▶ Problemas de regresión
 - ▶ Error cuadrático medio (Mean Squared Error, MSE)
 - ▶ Error absoluto medio (Mean Absolute Error, MAE)
 - ▶ Coeficiente de Determinación R^2
- ▶ Problemas de clasificación
 - ▶ Matriz de confusión
 - ▶ Exactitud (Accuracy)
 - ▶ Precisión (Precision)
 - ▶ Sensibilidad (Recall) y Especificidad (Specificity)
 - ▶ F1-score
 - ▶ ROC



Error Cuadrático Medio (MSE)

Calcula el error cuadrado promedio de las predicciones.

$$MSE(\mathbf{w}) = \frac{1}{N} \sum_{n=1}^N \{y(x_n, \mathbf{w}) - t_n\}^2$$

- ▶ Ventaja: Útil si tenemos valores inesperados que nos deberían interesar. Muy alto o bajo valor que debemos prestar atención.
- ▶ Desventaja: Si hacemos una predicción muy mala, al elevar al cuadrado, el error será mayor y puede sesgar la métrica para sobreestimar la maldad del modelo. Este es un comportamiento particularmente problemático si tenemos datos ruidosos



Error Absoluto Medio (MAE)

Se calcula como el promedio de diferencias absolutas entre los valores objetivo y las predicciones. Es una puntuación lineal, lo que significa que todas las diferencias individuales se ponderan por igual en el promedio.

$$MAE(\mathbf{w}) = \frac{1}{N} \sum_{n=1}^N |y(x_n, \mathbf{w}) - t_n|$$

- No es tan sensible a los valores atípicos como el MSE.

En estas fórmulas de MAE y MSE, N el número total de instancias, $y(x_n, \mathbf{w})$ la salida obtenida del modelo $\mathbf{w}$ y t_n la salida real de la instancia n .

Interpretación de MSE y MAE: A menor error, siempre será mejor el modelo.



Coeficiente de Determinación R^2

Métrica a utilizar en tareas de regresión. Indica la cantidad proporcional de variación en la variable de respuesta y , explicada según las variables independientes X . Es una medida adimensional. Toma valores en el intervalo $[0, 1]$. Cuando mayor es el valor mejor es el ajuste del modelo.


La formula es:

$$R^2 = 1 - \frac{\sum (y_i - t_i)^2}{\sum (t_i - \mu_t)^2}$$


Siendo t_i la salida esperada de la instancia i , y_i la salida estimada del modelo para la instancia i y μ_t la media de los valores de salida de todas las instancias. Interpretación de R^2 .

- ▶ Valor entre 0 y 1
- ▶ Más cercano a 0 $\Rightarrow$ modelo con poco ajuste
- ▶ Más cercano a 1 $\Rightarrow$ modelo con mayor ajuste
- ▶ Umbral entre el nivel de ajuste se encuentra superior a 0.5, para algunas áreas superior a 0.75.

Supongamos un problema de clasificación binario con datos bidimensionales positivos (clase P) y negativos (clase N). En la figura anexa, se muestra el espacio de los datos y la frontera real (ideal) del problema.



Cuando se entrena un modelo con los datos disponibles, se obtendrá una frontera diferente a la ideal, como se muestra en la figura



El objetivo es conseguir un clasificador que produzca una frontera lo más parecida a la real, es decir,

$$VP = P \Rightarrow FN = 0$$

y

$$VN = N \Rightarrow FP = 0$$



¿Cómo medir este parecido?

Con **métricas** como:

- ▶ Matriz de Confusión
- ▶ Exactitud (Accuracy)
- ▶ Precisión (Precision)
- ▶ Sensibilidad (Recall) y Especificidad (Specificity)
- ▶ F1-score
- ▶ ROC
- ▶ Kappa

Matriz de Confusión

Matriz de Confusión		Etiquetas reales		
		Positivo (P)	Negativo (N)	
Resultado del clasificador	Positivo (P)	VP	FP	P'
	Negativo (N)	FN	VN	N'
		P	N	

Exactitud (Accuracy)

Es porcentaje de acierto (con independencia de la clase)


$$\text{Exactitud} = \frac{VP + VN}{P + N}$$

Desventaja: mala métrica para problemas desbalanceados.

Precisión (Precision)

Es el porcentaje de acierto de las predicciones positivas.

$$\text{Precisión} = \frac{VP}{VP + FP} = \frac{VP}{P'}$$



La Sensibilidad

También conocido como Recall es el porcentaje de casos positivos detectados.

$$\text{Sensibilidad} = \frac{VP}{VP + FN} = \frac{VP}{P}$$

Ejemplo en diagnóstico médico: probabilidad de detectar a un enfermo.

También se denomina TPR (True Positive Ratio) o Probabilidad de detección (P_D).


La Especificidad

(Specificity) es el porcentaje de casos negativos detectados.

$$\text{Especificidad} = \frac{VN}{VN + FP} = \frac{VN}{N}$$

Ejemplo en diagnóstico médico: probabilidad de detectar a un sano.


También se denomina TNR (True Negative Ratio).




Interpretación de la Precisión y la Sensibilidad

Conjuntamente indican si existe un sesgo hacia valores positivos o negativos

Precisión baja + Sensibilidad alta = sesgo hacia la clase de negativos (frontera desplazada hacia la clase de negativos). Se puede tener un 100% de sensibilidad con una sola muestra negativa acertada.



Precisión alta + Sensibilidad baja = sesgo hacia la clase de positivos (frontera desplazada hacia la clase de positivos). Se puede tener un 100% de precisión con una sola muestra positiva acertada.



Típico de **conjuntos desbalanceados**



- ▶ **Puntuación F1** (F1 score): La puntuación F1 es la **media armónica** de la precisión y sensibilidad, donde la puntuación de la F1 alcanza su mejor valor en 1 (precisión y sensibilidad perfectas) y el peor en 0.
- ▶ Esta es una métrica muy utilizada en problemas desbalanceados.

Se define como:

$$F1 = 2 * \frac{\text{sensibilidad} * \text{precisión}}{\text{sensibilidad} + \text{precisión}}$$



ROC (Receiver Operating Characteristic)

Es la representación gráfica de la **Sensibilidad** vs **Probabilidad de Falsa Alarma** para un sistema clasificador binario según se varía el umbral de discriminación (valor a partir del cual decidimos que un caso es un positivo).

Probabilidad de Falsa Alarma, FPR

Es la probabilidad de detección incorrecta de un negativo, es decir, $1 -$ (la probabilidad de detección correcta de un negativo). Así

$$\text{Falsa alarma} = 1 - \text{Especificidad} = 1 - \frac{VN}{N} = \frac{FP}{N}$$

RECORDAR:

Sensibilidad = TPR ó P_D





Falsa Alarma = FPR (False Positive Ratio) ó P_{FA}

Métricas de rendimiento VIII

Clasificación




Máster en
Inteligencia
Artificial
UMU



AUC (Área Bajo la Curva)

- Medida del rendimiento de todos los umbrales posibles.
- Medida relacionada con la probabilidad de detectar correctamente.

(<http://navan.name/roc/>)



Puntuación Kappa

La métrica de puntuación kappa κ tiene sus orígenes se remontan al campo de la psicología: se utiliza para medir la concordancia entre dos evaluadores o calificadores humanos a la hora de calificar sujetos. En el área del machine learning se utiliza para medir el rendimiento de la clasificación. Se trata de un coeficiente para medir la concordancia existente en la observación de un fenómeno por dos observadores distintos

$$\kappa = \frac{P_o - P_e}{1 - P_e}$$

donde:

- ▶ P_o representa la probabilidad observada de que coincida el modelo con la clase real y se calcula simplemente como las instancias correctamente clasificadas frente al total: $P_o = \frac{VP+VN}{N}$
- ▶ P_e representa la probabilidad de que ambos coincidan por mera casualidad (probabilidad esperada):
$$P_e = \left(\frac{VP+FN}{N} \frac{VP+FP}{N} \right) + \left(\frac{FP+VN}{N} \frac{FN+VN}{N} \right)$$

Interpretación de κ :

- ▶ Si el modelo coincide con la realidad será perfecto $\kappa = 1$
- ▶ A partir de 0.6 y/o 0.8 según autor se considera un buen modelo de predicción.

Las métricas deben evaluarse tras el entrenamiento con **datos nuevos** para medir la capacidad de generalización del modelo.

El método Hold-out

Técnica del machine learning para evaluar el rendimiento y la precisión de un modelo de aprendizaje supervisado.

- ▶ Se divide el conjunto de datos disponible en dos subconjuntos mutuamente excluyentes: el conjunto de entrenamiento y el conjunto de test (o de prueba).
- ▶ Porcentajes típicos 75% para entrenamiento y 25% para test.
- ▶ En general, depende del tamaño del conjunto de datos y la complejidad del problema.





Evaluación de un modelo concreto:

Una vez que el conjunto de datos ha sido dividido, se procede de la siguiente manera:

1. Se entrena el modelo empleando el conjunto de entrenamiento y el de validación.
2. Se evalúa su rendimiento del modelo utilizando el conjunto de test para medir la capacidad de generalización. Se calculan las métricas oportunas.

Selección del mejor modelo (entre varios posibles):

1. Se entrena un número de modelos (ajuste de parámetros) y se escoge aquel que produce menor error de validación.
2. Después, el modelo seleccionado se entrena con todas las muestras disponibles y se evalúa con el conjunto de test.



La ventaja principal del método de Hold-out es su simplicidad y rapidez. Sin embargo, es importante tener en cuenta algunas consideraciones:

- ▶ La división del conjunto de datos debe realizarse de manera **aleatoria y estratificada** para evitar sesgos en la selección de muestras.
- ▶ Es posible que los resultados varíen dependiendo de cómo se realice la partición de los datos. Por lo tanto, es recomendable repetir el proceso de Hold-out varias veces (**resampling**) y promediar los resultados para obtener una estimación más confiable del rendimiento del modelo.
- ▶ En algunos casos, especialmente cuando el conjunto de datos es pequeño, puede ser más apropiado utilizar técnicas de **validación cruzada**, como la k-fold, que proporcionan una estimación más robusta del rendimiento del modelo al usar múltiples subdivisiones de los datos.

Si N no es grande, el resultado del hold-out **depende de la partición** y el resultado es poco fiable. Ejemplo:



Para paliar este problema se emplea el **Resampling**.



Resampling

Consiste en hacer varios entrenamientos-testeos (divisiones aleatorias), y basar nuestra evaluación usando la distribución de los errores de test. Por ejemplo, promediando para:

- ▶ calcular el error esperado de un algoritmo
- ▶ compararlo con otro algoritmo

Nunca coger el mejor resultado sobre los errores de validación: sub-estimaremos el verdadero error.



La validación cruzada surge como mejora del hold-out y resampling.

Definición:


La validación cruzada es una manera de estimar el error de un modelo cuando disponemos de **pocos datos** y, por tanto, no se puede dedicar un conjunto explícito para test.

Se realiza una partición del conjunto de datos en una serie de subconjuntos buscando:


1. Conjuntos de entrenamiento y test lo más **grandes** posible
2. **Solape** entre conjuntos lo más **pequeño** o posible
3. Mantener la **estratificación**



k-Fold Cross-Validation (ejemplo $k = 4$)



k-Fold Cross-Validation: representación alternativa





Resultado central

El error de test promedio sobre todas las k redes es un **estimador insesgado** del error verdadero sobre cualquiera de las redes elegida aleatoriamente.

¿Cómo proceder en la práctica para elegir el modelo y la red final?

Elegir el modelo (optimización de parámetros)

Para elegir entre varios modelos se realiza la Validación Cruzada (k -fold) y se elige el modelo que da menor error promedio sobre el conjunto de test.

Construir el modelo final

Entrenar el modelo con todos los datos y con los mejores parámetros encontrados.



K-Fold: problemas y recomendaciones

- ▶ Dos problemas:
 - ▶ Conjunto de entrenamiento **grande** a costa de ser pequeño el de validación
 - ▶ Hay mucho **solape** entre los conjuntos de entrenamiento: comparten $k - 2$ partes
- ▶ Típicamente, $5 < k < 10$ (buen compromiso entre sesgo-varianza).
- ▶ Si k aumenta, se obtienen estimadores más robustos aunque los conjuntos de validación sean menores. Sin embargo, aumenta el número de redes a entrenar y, por tanto, el coste computacional.
- ▶ Si N aumenta, k puede ser más pequeño; si N es pequeño, k debe ser grande para permitir conjuntos grandes de entrenamiento.



Leave-one-out

Caso extremo, $k = N$ llamado método leave-one-out. Especialmente empleado en aplicaciones como diagnóstico médica (sistemas CAD) donde es difícil disponer de datos etiquetados (conjuntos de datos pequeños).

Ventajas:

1. La estimación del error NO depende de la partición de los datos, es decir, la estimación del error es mucho más estable.
2. NO se tiende a sobrestimar la estimación del error, es decir, el error de test no es mayor que el error de todos los datos.

Desventajas:

1. La programación se vuelve mucho más complicada.
2. El tiempo de ejecución puede ser muy alto.


Validación de modelos II

Leave-one-out



Máster en
Inteligencia
Artificial
UMU

Leave-one out





- ▶ Hasta ahora los métodos analizados aplicaban un muestreo sin sustitución.
 - ▶ Una vez seleccionado un elemento, este ya no puede volver a ser seleccionado.
 - ▶ No existen duplicados.
- ▶ El **bootstrap** se basa en un muestreo con sustitución.
 - ▶ Se crea un nuevo conjunto de datos, del mismo tamaño que el original, mediante un muestreo aleatorio con sustitución.
 - ▶ Este conjunto se utiliza para crear el modelo (pueden existir elementos duplicados)
 - ▶ El conjunto de instancias no seleccionadas constituyen el conjunto de prueba.
 - ▶ El proceso se repite un número determinado de veces.


Validación de modelos II

Bootstrap



Máster en
Inteligencia
Artificial
UMU

Bootstrap





- ▶ La estimación del estadístico tiende a ser pesimista:
 - ▶ La probabilidad de que un elemento no sea seleccionado nunca es:

$$\lim_{n \rightarrow \infty} \left(1 - \frac{1}{n}\right)^n = e^{-1} \approx 0.368$$

- ▶ Por lo tanto, el 63'2% de los elementos está representado al menos una vez en algún conjunto de entrenamiento.
- ▶ Este hecho introduce un sesgo importante en los datos.
 - ▶ Tiende a ser importante cuando hay pocos datos, reduciéndose a medida que el conjunto de datos se hace más grande.



- **boot.632** mitiga este problema redefiniendo el estadístico como:

$$E_S(h) = 0.632 \cdot E_{test} + 0.368 \cdot E_{trainig}$$

- En cada iteración se le da más peso al error en el conjunto de prueba.
- Probablemente sea el mejor método cuando el conjunto de datos es muy pequeño.



- ▶ ¿Es fiable el valor del estadístico obtenido por las técnicas de remuestreo anteriores?
- ▶ Para una muestra con n ejemplos se pueden establecer unos intervalos de confianza para el error verdadero $E_V(h)$, a partir del error de la muestra $E_S(h)$.
- ▶ Para ello, el intervalo de error con un nivel de confianza $c\%$ es (se suele utilizar la distribución binomial, pero para $n > 30$ se puede utilizar la distribución normal):

$$E_S(h) \pm z_c \sqrt{\frac{E_S(h)(1 - E_S(h))}{n}}$$

- ▶ Donde z_c se establece a partir del nivel de confianza según la normal:

$c\%$	50%	80%	90%	95%	99%
z_c	0,67	1,28	1.64	1,96	2,58



- ▶ No se puede afirmar que un método de muestreo sea mejor que otro.
- ▶ Si el tamaño del conjunto de datos es pequeño se recomienda la **repetición de validación cruzada con 10 pliegues** (repeated 10-fold cross validation):
 - ▶ Las propiedades de varianza y sesgo son buenas.
 - ▶ La complejidad computacional es adecuada para el tamaño del conjunto de datos.
- ▶ Pero debido a la variabilidad, si lo que queremos es comparar modelos es preferible algún método de **bootstrap**.
 - ▶ Introduce menos variabilidad.
- ▶ Para conjunto de datos grandes las diferencias entre métodos se reduce
 - ▶ Elegir el que menos complejidad computacional presente.

Fases del Proceso de Machine Learning

- ▶ Obtención y extracción de los datos: Obtener y analizar el problema a tratar
- ▶ Preprocesamiento de datos: Preparar los datos para que tengan la máxima calidad posible, conociendo sus circunstancias.
- ▶ Creación de Modelos: Creación del modelo para abordar el problema
- ▶ Evaluación y validación de modelos: Evaluar el modelo utilizando diferentes métricas y modelos de validación. Si el modelo no es satisfactorio, comenzar de nuevo el proceso.
- ▶ Creación del modelo final y entrega al usuario: Crear el modelo final y entregar al usuario con sus documentación correspondiente.