Machine Learning

Tema 2. Técnicas Supervisadas

Raquel Martínez España
Ciencia de la Computación e Inteligencia Artificial
Dept. Ingeniería de la Información y las Comunicaciones

Jose Tomás Palma
Ciencia de la Computación e Inteligencia Artificial
Dept. Ingeniería de la Información y las Comunicaciones

Universidad de Murcia



Máster en Inteligencia Artificial

2026/2027

Índice

Introducción

Clasificación desbalanceada

Ensambles

Multi-etiqueta - Multilabel

Multi-Instancia

Aprendizaje Multitarea

Otros tipos de aprendizaje

Inferencia estadística

Otros enfoques y conceptos

Recordatorio

Técnica Supervisada: Se conoce el valor objetivo del problema. Si el valor es:

- Es nominal (una etiqueta): Técnicas supervisadas de clasificación.
- Es numérico: Técnicas supervisadas de regresión.

Entre las fases del proceso estamos en Creación de modelos.

Problema

- No me preocupo por la técnica, enfoco el problema a resolver, lo clasifico y aplico, una o una combinación de técnicas para resolverlo.
- Es posible que necesite preprocesar los datos previamente a aplicar alguna técnica para conseguir una solución robusta.

- En muchos casos los clasificadores están diseñados para optimizar la precisión general sin considerar la distribución relativa de cada clase.
  - Afecta negativamente tanto proceso de entrenamiento como a la estimación de la eficacia de los modelos.
- ¿Qué se puede hacer?
  - Utilizar técnicas de muestreo para mitigar el desbalanceo de clases.
  - Utilizar otras medidas de rendimiento a la hora de evaluar los modelos.
  - Utilizar modelos que permitan mitigar esta problemática

- Técnicas básicas:
  - **Downsampling (o subsampling):** Seleccionar aleatoriamente un subconjunto de todas las clases para que sus frecuencias se ajusten a la de la clase minoritaria
  - **Upsampling (o over-sampling):** Realizar un muestreo aleatorio con reemplazo para que sus frecuencias se adapten a las de la clase mayoritaria.

- Otras técnicas:
  - **SMOTE** (Synthetic Minority over-sampling Téchnique). Es una técnicas de over-sampling.
    - Utiliza información de los vecinos más cercanos para generar nuevas muestras de la clase minoritaria.
    - De esta forma se consigue que las fronteras de la clase no se distorsione.
    - Existen muchas variantes de esta técnica.

- **ROSE** (Random Over-Sampling Examples). Técnica que genera nuevas muestras en la vecindad de las existentes para equilibrar la frecuencia de clases.
  - Problemas de clasificación binaria.
  - Se generan ejemplos de ambas clases en la proximidad de las muestras ya existentes de acuerdo con una distribución de probabilidad centrada en la muestra y con una matriz de covarianza concreta.
  - Se puede combinar con técnicas de sampling para evaluar modelos de aprendizaje.



- El error de clasificación y la exactitud (accuracy) no son métricas apropiadas cuando tenemos clases desbalanceadas.
- Utilizar otras medidas de eficacia considerando la clase mayoritaria como la negativa
  - **Matriz de confusión**
  - **Precisión o valor predictivo positivo**, $VP/(VP+FP)$, $\rightarrow$ la exactitud en la predicción de la clase minoritaria
  - **Recall o sensibilidad**, $VP/(VP+FN)$, la capacidad del modelo para predecir la clase minoritaria.
  - **F1 Score:** media ponderada de la precisión y el recall
  - **Área bajo la curva ROC** que mide la capacidad del modelo de diferenciar las observaciones entre clases.

- Combinaciones con Recall y precisión
  - Recall alto y precisión alta: La clase es detectada perfectamente por el modelo.
  - Recall bajo y precisión alta: el modelo no puede detectar la clase pero cuando lo hace es muy fiable.
  - Recall alto y precisión baja: la clase es detectada aceptablemente por el modelo pero también incluye muestras de otras clases.
  - Recall bajo y precisión baja: el modelo no puede detectar la clase.



- Algoritmos optimizados para tratar con clases desbalanceadas
  - Tienen en cuenta la distribución de clases en la construcción del modelo
  - SVM:
    - Dan buenos resultados para problemas desbalanceados.
    - Existen variaciones adaptadas: z-SVM y GSVM-RU
  - kNN: kENN, CCNND

- Aprendizaje sensitivo al costo:
  - Cambiar el coste de los errores.
  - Se puede dar mayor importancia a los falsos positivos de la clase mayoritaria, o a los verdaderos positivos de la clase minoritaria.
  - Problemas
    - El problema es que los la matriz de costes no se conocen apriori y puede ser difícil definirla.
    - Puede causar sobreajuste de los modelos.
    - Hay estudios que indican que estas técnicas son igual de eficientes que las técnicas de muestreo.

- Métodos ensembles:
  - Conseguimos reducir la varianza en la clasificación.
  - Existen métodos adaptados para clases desbalanceadas:
    - SMOTEBoost,RUSBoot, DataBoostIM, cost-sensitive boosting[1], SMOTEBagging.
- One-Class learning
  - También conocidos como métodos basados en reconocimiento.
  - El modelo es entrado para representar adecuadamente la clase minoritaria.
  - Muchas técnicas no están preparadas para ser entrenadas con una sola clase
  - One Class SVM, Isolation Forest, Minimum Covariance Determinant,..

[1] https://github.com/hussainkanafani/cost-sensitive-boosting

- Hasta ahora un sólo clasificador:
  - Navaja de Ockham: En igualdad de condiciones la explicación más sencilla es la más probable.
- Epicureo: Si varias hipótesis son consistente con los datos debemos mantenerlas todas.
  - Recabar varias opiniones y después tomar la decisión de acuerdo con ellas.
  - Esta idea es bien conocida en los sistemas de decisión: es preferible consultar a varios asesores.
- Idea: Crear un nuevo modelos combinando varios modelos.
  - Métodos multiclasificadores, metamodelos, métodos de fusión o ensamble (*ensemble methods*)

- **Ensemble Methods:** Construir diferentes modelos y hacer predicciones teniendo en cuenta todos los modelos Dietterich (2000):
  - Tanto para clasificación como para regresión.
  - La precisión conjunta obtenida suele mejorar la precisión de los elementos individuales.
  - Se consiguen modelos más estables y predicciones con menor varianza.
  - Aumentamos el poder expresivo del lenguaje de representación.
  - La combinación de modelos semánticamente diferentes puede solucionar el problema del sobreajuste.

- Aspectos claves:
  - Los modelos utilizados debes ser lo suficientemente diferentes.
    - Baja correlación en las predicciones.
  - La técnica de construcción.
  - La técnica de combinación.
- Requisitos:
  - Los modelos base deben disentir.
  - Cada modelo debe tener un error inferior al 0.5.
  - Los errores de los modelos no deben estar correlados.

- **Manipulación de los datos de entrenamiento:**
  - Construcción de modelos utilizando la misma técnica.
  - Para cada modelos se utilizan datos distintos.
  - Clave: ¿Cómo se generan dichos datos diferentes a partir del mismo conjunto de datos?
  - Ejemplos:
    - *Bagging* Breiman (1996)Quinlan (1996),
    - *Boosting* Quinlan (1996),Freund and Schapire (1996),
    - *Cross-validated committes* Parmanto et al. (1996)

- **Manipulación de los atributos de entrada:**
  - Alterar el conjunto de atributos del conjunto de entrada al construir los modelos.
  - *Random Forest* Ho (1998)
- **Manipulación de los datos de salida:**
  - Modificación de las clases de las instancias
  - Dietterich and Bakiri (1994) generar conjuntos mediante partición al azar de las clases.

- **Bootstrap Aggreating (Bagging)**: Para crear cada uno de los modelos utiliza diferentes conjuntos de entrenamiento.
  - Cada conjunto se obtiene por bootstraping del conjunto original.
  - Especialmente útil para técnicas inestables o débiles que dependen mucho del conjunto de datos $\longrightarrow$ árboles de decisión.
- La decisión final:
  - Clasificación: votación mayoritaria.
  - Regresión: media.

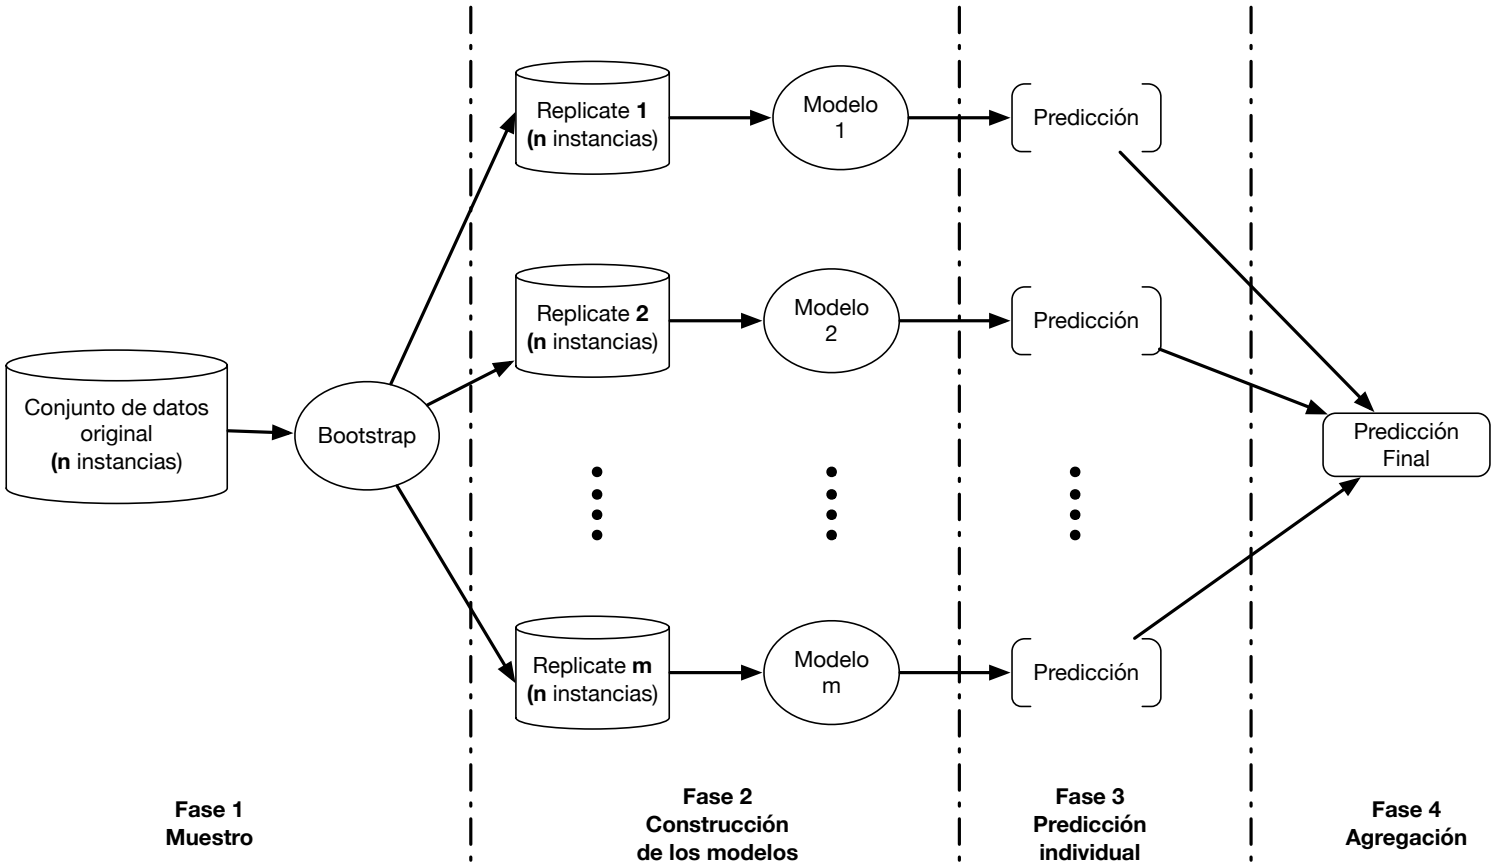


Figure: Esquema general de Bagging

- **Out of the Bag Error:** media de los errores que se cometen al clasificar en el resto de los clasificadores las instancias no utilizadas.
  - Es una buena aproximación al error de test.
  - Se puede utilizar para ajustar los hiperparámetros.
  - Si el número de modelos es suficientemente alto se aproxima al LOOCV.
- **Importancia de los predictores:**
  - Incremento del OOB por permutación de valores.
  - Incremento de la pureza de los nodos.
- Se pueden aplicar otras técnicas de muestreo: *[Cross-Validation Committee (CVC)Parmanto et al. (1996)]*

- **Boosting:** Ajustar de forma secuencial diferentes clasificadores (*weak learners*) a partir de una versión de los datos con pesos.
  - *weak learners*: modelos sencillos con poca capacidad de predicción un poco mejor que el aleatorio.
  - La decisión
- La decisión final:
  - Clasificación: votación mayoritaria.
  - Regresión: suma ponderada.
- El algoritmo más usado AdaBoost
  - El básico: dos clases (+1 y -1)

Algoritmo 1 AdaBoost

1: Inicializar los pesos ω_n a $1/N$.
2: **for** $m = 1$ to M **do**
3: Construir un predictor $y_m(x)$ minimizando el error ponderado J_m:
4: $J_m = \sum_{n=1}^{N} \omega_n^{(m)} I[y_m(x_n) \neq t_n]$
5: Calcular $\epsilon_m = J_m / \sum_{n=1}^{N} \omega_n^{(m)}$.
6: Calcular $\alpha_m = log(\frac{1-\epsilon_m}{\epsilon_m})$
7: Actualizar los pesos $\omega_n^{(m+1)} = \omega_n^{(m)} \exp\{\alpha_m I[y_m(x_n) \neq t_n]\}$
8: **end for**
9: Decisión: $Y_M(x) = sign\left(\sum_{n=1}^{M} \alpha_m y_m(x)\right)$

- Parámetros Boosting:
  - Suelen tener muchos parámetros $\longrightarrow$ búsqueda por validación cruzada.
  - Los más comunes:
    - El número de modelos o iteraciones.
    - *Learning Rate* cuanto más pequeño más modelos se necesitan pero menos riesgo de overfitting.
    - En el caso de árboles la complejidad de los mismos

- **Problema:** Dado un multiclasifcador con m clasificadores unificar las predicciones individuales para generar una única predicción
  - **Votación mayoritaria:** cada clasificador vota por una clase y la clase más votada es la que predice en multiclasificador
    - Posibles variaciones: *voto con umbral de popularidad*, *voto por unanimidad*, *votos con pesos*,..
  - En el caso de que los clasificadores devuelvan la probabilidad de pertenencia a cada clase:
    - *suma*, *media*, *producto*, *media geométrica*, *máximo*, *mínimo*, *mediana*
  - Las mismas técnicas se pueden emplear a problemas de regresión.

- Supongamos un ensemble con 5 modelos $\{m_1, m_2, m_3, m_4\}$ y un problema de 4 clases $\{A, B, C, D\}$.

	$P(A)$	$P(B)$	$P(C)$	$P(D)$
m_1	0.2	0.6	0.3	0.2
m_2	0.9	0.5	0.4	0.4
m_3	0.3	0.4	0.7	0.4
m_4	0.2	0.1	0.3	0.8

Suma	1.6	1.6	1.7	1.8	$\rightarrow D$
Media Arit.	0.4	0.4	0.42	0.45	$\rightarrow D$
Media geo.	0.32	0.33	0.39	0.4	$\rightarrow D$
Máximo	0.9	0.6	0.7	0.8	$\rightarrow A$
Minimo	0.2	0.1	0.3	0.2	$\rightarrow C$
Mediana	0.25	0.45	0.35	0.4	$\rightarrow B$

- Hasta ahora los multiclasificadores que hemos analizado se basan en combinar modelos creados a partir de la misma técnica.
- También es posible combinar modelos creados por diferentes técnicas.
  - Las hipótesis capturadas por los modelos tienden a ser más variadas.
  - Se pude cubrir más espacio.

- **Stacking:** Wolpert (1992):
  - Crear m modelos con diferentes técnicas a partir de los mismos datos.
  - Utilizar algunas de las técnicas de fusión.
  - Problema: Las técnicas de fusión funcionan bien cuando los diferentes tienen una precisión aceptable:
    - Esto no se pude garantizar si se utilizan técnicas diferentes.
  - Solución: una fase de *meta-aprendizaje*
    - Se intenta aprender la mejor manera de combinar las decisiones de los diferentes modelos.

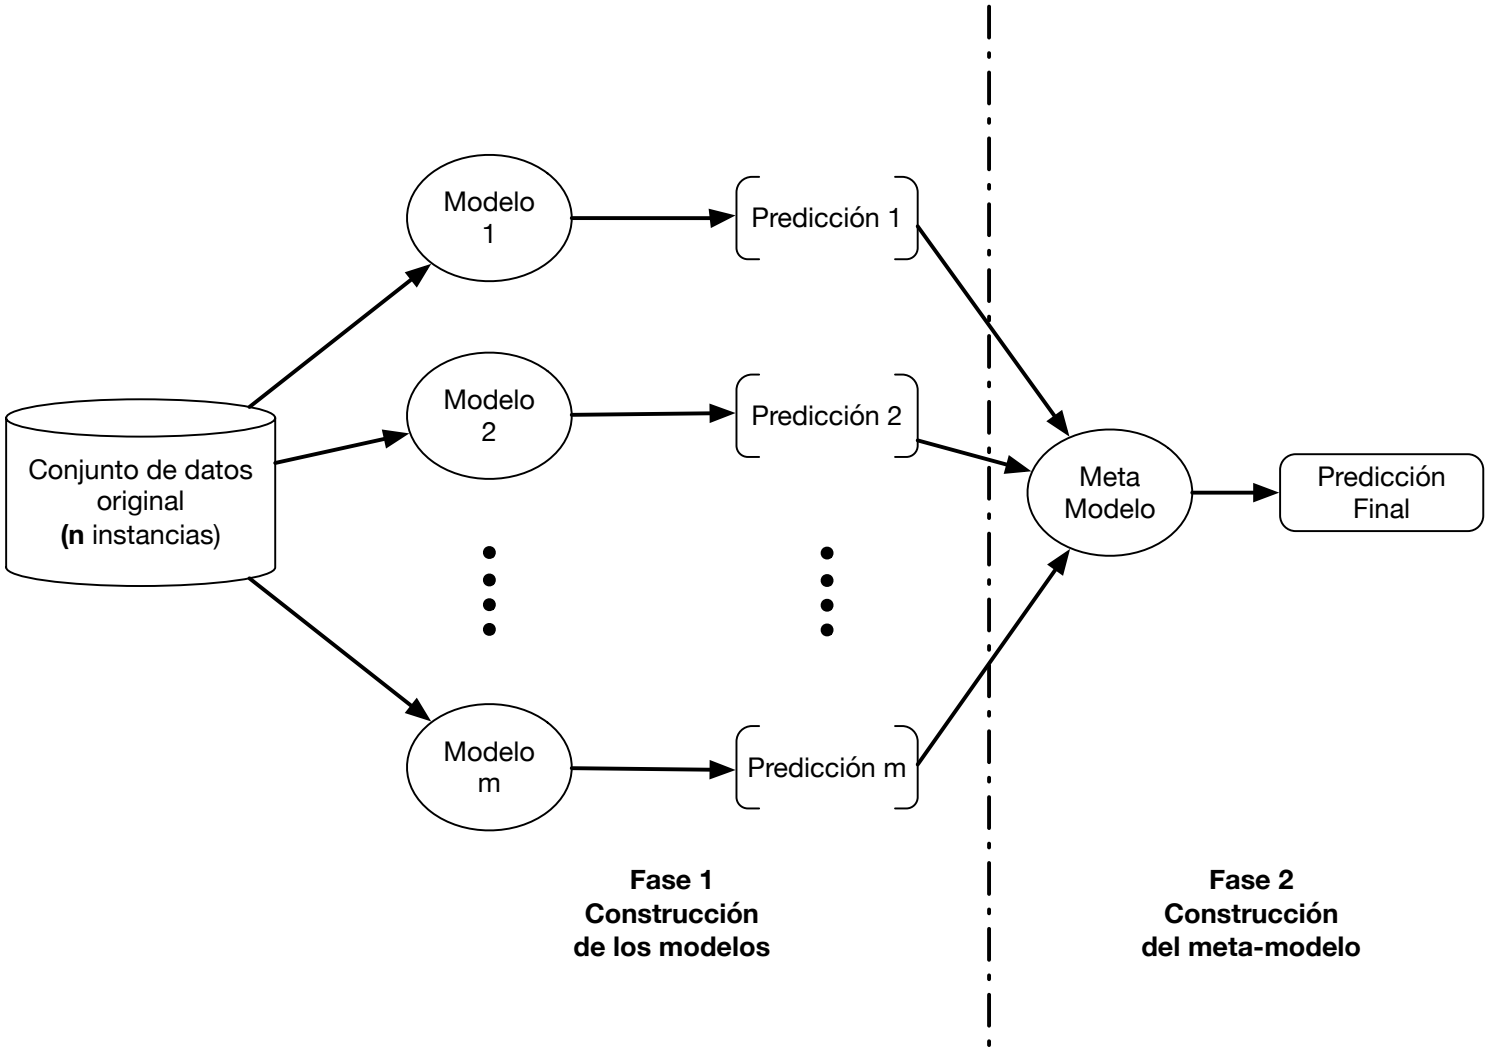


Figure: Esquema general de stacking

Algoritmo 2 Stacking

Entrada: datos de entrenamiento $D = \{x_i, y_i\}_{i=1}^{m}$
Salida: multiclasificador (ensemble) H
for $m = 1$ to M **do**
    Entrenar los modelos base
    Construir un predictor $h_m(x)$ a partir de D
end for
for $i = 1$ to m **do**
    dataset para entrenar el meta-modelo
    $D_h = \{x'_i, y_i\}$ con $x'_i = \{h_1(x_i), h_2(x_i), \cdots, h_m(x_i)\}$
end for
Construir H a partir de D_h {Construir el meta-modelo}
devolver H

- ¿Qué datos utilizar para entrenar el meta-modelo?
  - Riesgo de sobre-aprendizaje si utilizamos los mismo datos utilizados para entrenar los diferentes modelos.
  - Solución: los mismos mecanismos que hemos analizado en evaluación: utilizar datos distintos $\longrightarrow$ conjunto de validación para el meta-modelo
  - También se puede utilizar validación cruzada:
  - Para hacer predicciones:
    1. Realizar las predicciones con los modelos base.
    2. Utilizar las salidas de estos modelos como entradas al meta-modelo.

1. ¿Qué datos utilizar para entrenar el meta-modelo?
   - Riesgo de sobre-aprendizaje si utilizamos los mismo datos utilizados para entrenar los diferentes modelos.
   - Solución: los mismos mecanismos que hemos analizado en evaluación: utilizar datos distintos $\longrightarrow$ conjunto de validación para el meta-modelo
   - También se puede utilizar validación cruzada.
   - Para hacer predicciones:
     1.1 Realizar las predicciones con los modelos base.
     1.2 Utilizar las salidas de estos modelos como entradas al meta-modelo.

- Cascading Gama and Brazdil (2000) es una técnica que genera multiclasificadores muy precisos.
  - Recomendables cuando no podemos permitirnos un error (fraude en tarjetas de créditos, descartar enfermedades).
- Consiste en aplicar de forma secuencial un conjunto de clasificadores.
  - Idea: a medida que avanzamos en la ‘cascada”, los modelos intentan clasificar aquellos datos para los que los modelos predecesores no están seguros.

- Necesitamos asociar a cada modelo una *confianza*:
  - ¿Cuán seguro está el modelo acerca de su salida?
  - A priori: información sobre los datos de entrada sin tener en cuenta las predicciones que generan:
    - Probabilidades a priori.
  - A posteriori: información sobre las predicciones:
    - Tasa de error, probalidades a posterior,
- Se trata de que los primeros modelos sean simples y clasifiquen la mayor parte de las instancias.
  - se van construyendo modelos más complejos pero con menos datos.
- Confiaremos en la salida de un modelo si la confianza que tiene en su salida supera un umbral.

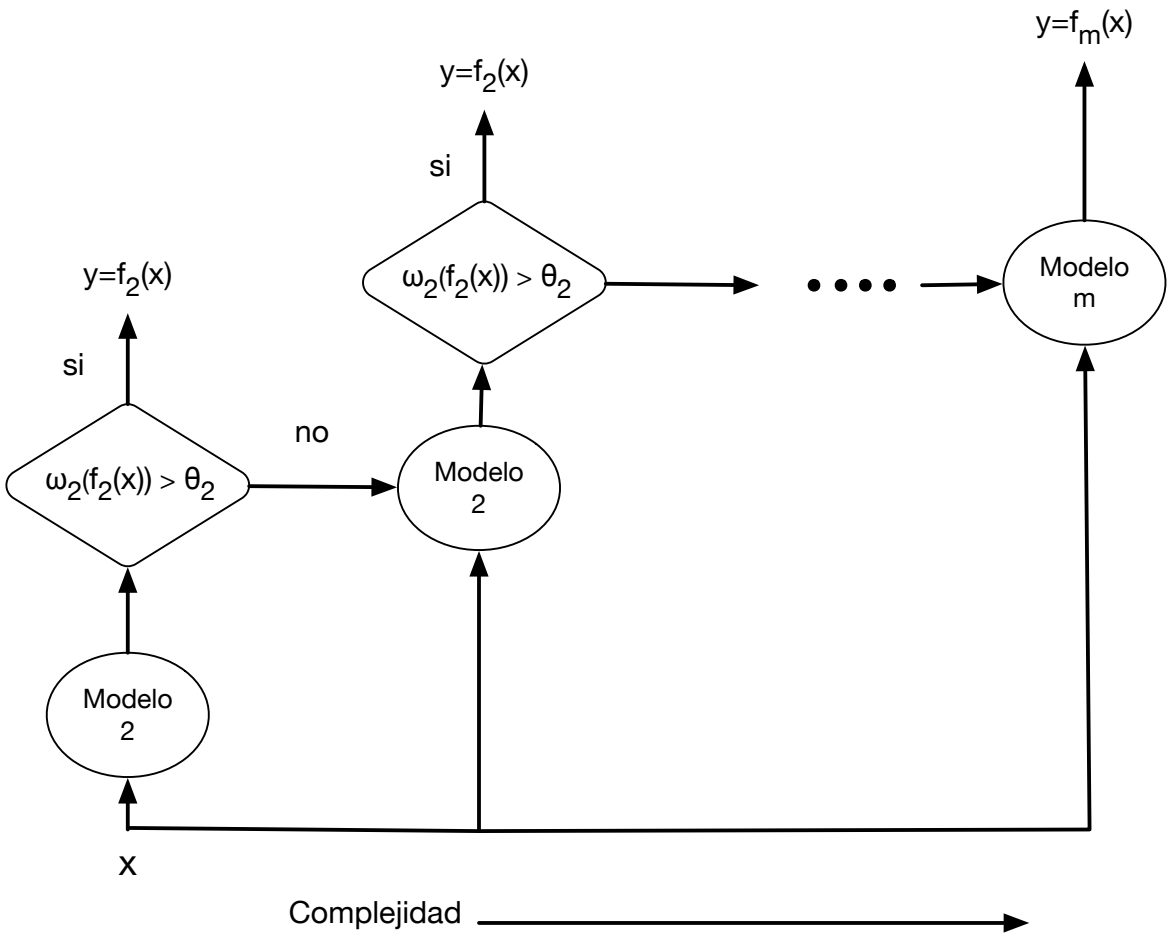


Figure: Esquema general de cascading



1. Se utiliza todo el conjunto de datos D para entrenar el primer modelo m_1.
   - m_1 clasifica con suficiente confianza D^1 instancias.
   - $D_2 = D^1 / D$.
2. Se construye el modelo m_2 con D_2.
   - $D_3 = D^2 / D$
3. Se sigue el proceso hasta que se hayan construido todos los modelos.

- Generalmente la combinación de modelo mejora la capacidad predictiva de los mismos.
  - La idea ya se conocía desde los 90s.
- Es preferible utilizar modelos con la diversidad suficiente como para que sus errores se puedan cancelar.
- Hay que tener en cuenta que también están sujetos al No Free Lunch Theorem.

- **Desventajas:**
  - Es difícil estimar la correlación entre los diferentes modelos.
  - Con costosos de construir en términos de memoria y tiempo.
  - El concepto aprendido es difícil de comprender, podemos perder en explicabilidad.

.

Los algoritmos de machine learning en clasificación vistos hasta ahora, crean un modelo, usando ejemplos de entrenamiento, para predecir el valor de una clase. Dada una Instancia = $(x_1, .., x_n; y_i)$, $x_1, .., x_n \in R; y_i \in C$

- Clasificación binaria: $C \in C_1, C_2$
- Clasificación multiclase: $C \in C_1, C_2, .., C_k$

En multietiqueta dada una instancia = $(x_1, .., x_n; Z)$, $(x_1, .., x_n) \in R$; $Z \subseteq L$ donde $L = C_1, C_2, .., C_k$

ciudad	fumador	casado	Años	estudios	clase-profesión
Murcia	NO	si	44	primaria	fontanero, albañil
Granada	SI	NO	23	universsdad	admisnitrativo, camarero
Madrid	NO	si	50	ESO	Autonomo, repartidor

Table: Ejemplo de dataset multi-etiqueta



Figure: Instancia

- Clasificación binaria: ¿Es una foto de un lago? $\in \{\textbf{si}, \textit{no}\}$
- Clasificación multiclase: ¿Qué hay en la foto?
  $\in \{\textit{playa}, \textit{gente}, \textit{árboles}, \textbf{montañas}\}$
- Clasificación multi-etiqueta: ¿Qué clases son relevantes en la foto?
  $\{\in \textit{playa}, \textit{gente}, \textbf{árboles}, \textbf{montañas}\}$

- Se tiene un conjunto finito de etiquetas menor que el número de atributos
- Las etiquetas pueden están correlacionadas
- Los datos pueden estar desbalanceados
- El aprendizaje multi-etiqueta pueda involucrar dos tareas:
  - Clasificación multi-etiqueta (MLL): Dado un dato, regresar un subconjunto de etiquetas asociadas a los datos (y su complemento)
  - Ordenamiento de etiquetas (LR): Dado un dato regresa todas las etiquetas ordenadas por relevancia
- Existen dos enfoques generales para clasificación multi-etiqueta:
  - Transformación: Transforman el problema en varios problemas de clasificación multiclase.
  - Adaptación: Adaptan algoritmos para trabajar con conjuntos de clases.



Figure: Técnicas multi-etiqueta

- Copia: Reemplaza cada ejemplo multi-etiqueta: $(X; Y_i)$ en $|Y_i|$ ejemplos de una sola etiqueta. Esto lo hace directamente o ponderando cada ejemplo como $\frac{1}{|Y_i|}$

Original		Transformado directo		Transformado ponderado		
Ejemplo	Clase	Ejemplo	Clase	Ejemplo	Clase	Peso
1	C1,C2	1	C1	1	C1	0.5
2	C2,C3,C4	1	C2	1	C2	0.5
3	C3,C4	2	C2	2	C2	0.33
		2	C3	2	C3	0.33
		2	C4	2	C4	0.33
		3	C3	3	C3	0.5
		3	C4	3	C4	0.5

- Copia seleccionada: Copia y selecciona una de las clases: La más frecuente (max), menos frecuente (min), en forma aleatoria (random), ignorando los ejemplos multi-etiqueta (ignore).

Original		Transformado Min		Transformado Max		Transformado Rand		Transformado Ignore	
Ejemplo	Clase	Ejemplo	Clase	Ejemplo	Clase	Ejemplo	Clase	Ejemplo	Clase
1	C1,C2	1	C1	1	C2	1	C2	4	C4
2	C2,C3,C4	2	C2	2	C4	2	C3		
3	C3,C4	3	C3	3	C4	3	C3		
4	C3	4	C3	4	C3	4	C3		

- Conjunto potencia (powerset): Simple y muy usado, en donde considera cada subconjunto diferente de clases como una nueva clase de un nuevo problema de clasificación multi-clase.
  - Problemas: Puede crear desbalanceos, no clasifica subconjuntos no vistos, y se pueden crear muchas clases.

Original		Transformado Conj.	
Ejemplo	Clase	Ejemplo	Clase
1	C1,C2	1	C1-2
2	C2,C3,C4	2	C2-3-4
3	C3,C4	3	C3-4
4	C3	4	C3

- ¿Como clasificamos con powerset? Si el clasificador nos da una probabilidad de salida, las podemos repartir en las clases y sumarlas

Clase	p (c|Xi)	C1	C2	C3	C4
C1-2	0.7	1	1	0	0
C2-3-4	0.1	0	1	1	1
C3-4	0.1	0	0	1	1
C3	0.1	0	0	1	0
	Xi=	0.7	0.8	0.3	0.2

Binary Relevance

- Es un método popular que genera n clasificadores binarios, uno por cada valor (i) de las clases.
- Cada clasificador se entrena con todos los datos originales, considerando ejemplos positivos a los que tienen la clase i, y negativos el resto ($j \neq i$), y lo hace para todas las clases.
  - Ventajas: Tiene baja complejidad computacional, al suponer independencia entre etiquetas estas se pueden añadir o quitar, se puede paralelizar.
  - Desventajas: Supone independencia de las etiquetas, después de la transformación se pueden crear desbalances que se incrementa con alta dimensionalidad en el número de etiquetas



Rakel

- Random k-label sets construye un ensemble de "LabelPowersets", cada clasificador construido con un subconjunto pequeño de clases.
  - Ventajas: Mantiene las correlaciones entre las clases y mantiene el número de clases reducido
  - De nuevo ordena las salidas de los clasificadores

Ranking by Pairwise Comparison

- Transforma el problema multiclase en $\frac{q(q-1)}{2}$ conjuntos de clases binarias (uno para cada par de clases).
- Cada conjunto de datos contiene ejemplos de alguna de las clases, pero no de las dos
- Dada una nueva instancia se corre en todos los clasificadores y se cuentan los votos recibidos para cada clase.

- Se han realizado adaptaciones a varios algoritmos para poder trabajar con ejemplos multi-etiquetas:
  - Árboles de decisión (permite a las hojas tener más de una clase y usa una medida de entropía multi-etiqueta).
  - Boosting (Adaboost): Evalua considerando múltiples clases.
  - Campos aleatorios de Markov: Lo modifican para considerar co-ocurrencia de etiquetas.
  - Redes neuronales: Adaptan back-propagation para considerar multi-etiquetas.
  - SVM: Generan n clasificadores binarios, sus predicciones se usan como atributos para nuevos clasificadores binarios.
  - kNN: Encuentra vecinos más cercanos tomando en cuenta la frecuencia de las clases (las clases más comunes).
  - Ensambles de clasificadores multi-etiqueta, usando variantes de Random Forest.

Chain Classifiers

- La idea de los clasificadores en cadena es por un lado tener clasificadores simples (binarios) y considerar las dependencias entre las clases.
- Se crea una "cadena" de clasificadores, en donde los atributos de clasificadores binarios se aumentan con las predicciones de los clasificadores anteriores en la cadena.
- El orden de la cadena es relevante si existen dependencias entre las clases. Como no se sabe cuál debe de ser el orden se crea un ensamble con muchos ordenes de clases generados aleatoriamente.
- Se usa un voto simple de las clases predichas por todos los ensambles usando un umbral.

$\mathbf{h}:$	$\mathbf{x} \rightarrow$	$\mathbf{y}$
h_1:	[0,1,0,1,0,0,1,1,0]	1
h_2:	[0,1,0,1,0,0,1,1,0]	0
h_3:	[0,1,0,1,0,0,1,1,0]	0
h_4:	[0,1,0,1,0,0,1,1,0]	1
h_5:	[0,1,0,1,0,0,1,1,0]	0

$\mathbf{h}:$	$\mathbf{x}' \rightarrow$	$\mathbf{y}$
h_1:	[0,1,0,1,0,0,1,1,0]	1
h_2:	[0,1,0,1,0,0,1,1,0,**1**]	0
h_3:	[0,1,0,1,0,0,1,1,0,**1**,0]	0
h_4:	[0,1,0,1,0,0,1,1,0,**1**,0,0]	1
h_5:	[0,1,0,1,0,0,1,1,0,**1**,0,0,1]	0

Jerarquicos

- A veces las clases están organizadas en una jerarquía
- Algunos algoritmos aprovechan esa información adicional (dependencias jerárquicas conocidas)
- Clasificación:
  - Árbol
  - Un grafo acíclico dirigido
- Profundidad de clasificación:
  - Predicción de nodo hoja obligatorio
  - Predicción de nodo hoja no obligatorio
- Esquema de exploración:
  - Local
  - Global
- Aprende un clasificador multiclase para cada nodo padre
- Con un nueva instancia usa todos los clasificadores para predecir las clases en todos los nodos y combina los resultados de todas los caminos
- Se devuelve el camino con probabilidad más alta.
- Se puede decidir parar la clasificación hasta cierto nivel (Nodo hoja no obligatorio)

Para los clasificadores multi-etiqueta se han propuesto diferentes medidas de evaluación:

- Mean accuracy (por clase para d clases):

$$Acc_d = \frac{1}{d}\sum_{j=1}^{d} Acc_j = \frac{1}{d}\sum_{j=1}^{d}\frac{1}{N}\sum_{i=1}^{N}\delta(c'_{ij}, c_{ij})$$

  donde $\delta(c'_{ij}, c_{ij}) = 1$ si $c'_{ij} = c_{ij}$ y 0 en otro caso.

- Global accuracy (por ejemplo):

$$Acc = \frac{1}{N}\sum_{i=1}^{N}\delta(c'_i, c_i)$$

  donde c_i es el vestor d-dimensional de la clases y $\delta(c'_i, c_i) = 1$ si $c'_i = c_i$ y 0 en otro caso.

Para los clasificadores multi-etiqueta se han propuesto diferentes medidas de evaluación:

- Multilabel accuracy (también llamado de Jaccard):

$$ML - Acc = \frac{1}{N} \sum_{i=1} N \frac{c_i \wedge c_i'}{c_i \vee c_i'}$$

- F1-measure: Para multi-etiqueta, redefiniendo precisión y recall (redefinos para multi-etiqueta.

$$F1 = \frac{2\ x\ precision\ x\ recall}{precision + recall}$$

- Hamming-Loss and Hamming-Accuracy:

$$H - Accuracy = 1 - HammingLoss$$

$$HammingLoss = \frac{1}{N|L|} \sum_{i=1}^{N} |Y_i \oplus \hat{Y}_i|$$

HammingLoss mejor cuando más bajo

MEKA: A Multi-Label Extension to WEKA (NO es python pero se puede importar). Algunos de los algoritmos que tiene son:

- Binary Relevance
- Chain classifier
- metaBagging
- Bayesian chain classifier (BCC)
- RAkEL

En Python librería scikit-multilearn:

- Multi-label data stratification
- Multiples clasificaciones multi etiqueta
- Utiliza estructura de sklearn.
- Búsqueda de parámetros mediante Grid

MULAN otra librería en Java, similar a MEKA.

El aprendizaje con multi-instancia (MIL) fue introducido por Dietterich Dietterich et al. (1997):

- El conjunto de entrenamiento está compuesto por bolsas donde cada una contiene un conjunto de instancias.
- Una bolsa se etiqueta como positiva si contiene al menos una instancia positiva, en caso contrario se etiqueta como negativa.
- La información que se posee es relativa a las bolsas, no conociendo la clase a la que pertenece cada instancia individual.
- La idea es subyacente es: varias personas tienen un llavero específico que contiene llaves. Algunas de estas personas pueden entrar en una determinada habitación y otras no. La tarea consiste entonces en predecir si una determinada llave o un determinado llavero puede hacerles entrar en esa habitación.

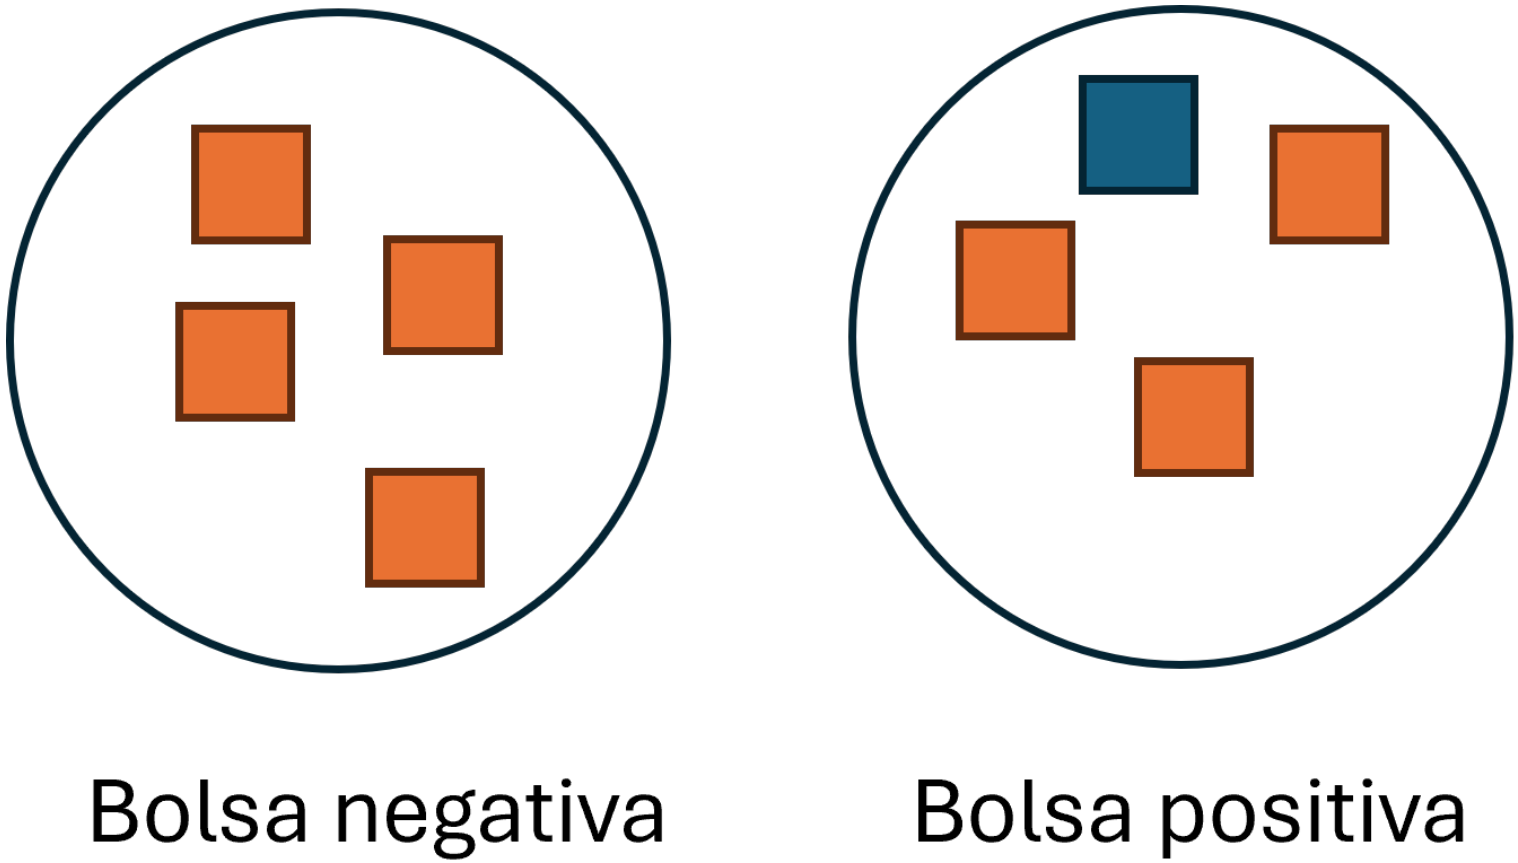


Figure: Composición de las bolsas

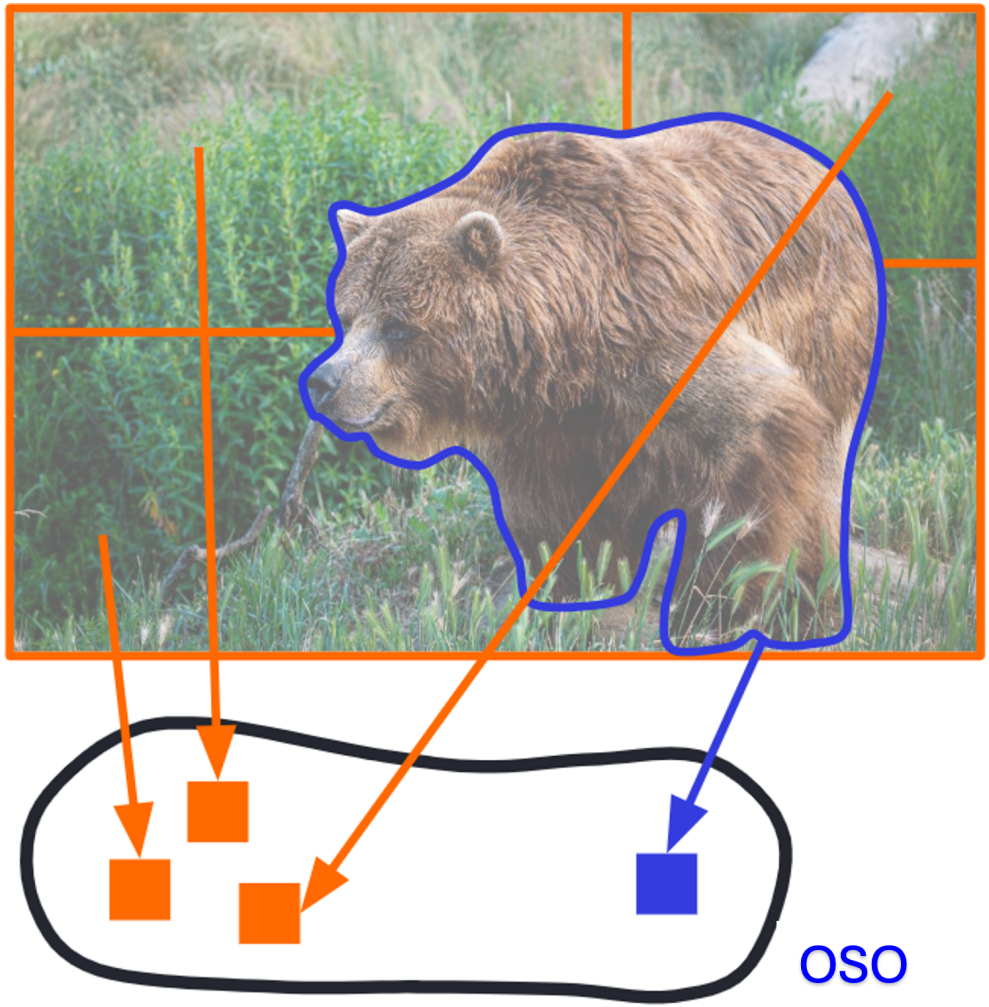


Figure: Ejemplo en clasificación de imágenes

- Ejemplos de aplicación:
  - Medicina: una imagen pueden contener áreas saludables y malignas (instancias), pero la etiqueta se aplica al nivel de la imagen completa (bolsa).
  - Análisis de texto: Para identificar la presencia de temas específicos en documentos donde solo el documento completo (bolsa) está etiquetado y no cada palabra o frase (instancia).
  - Detección de sonidos ambientales: Identificar eventos de interés en grabaciones donde solo se conoce la presencia de un evento dentro de un segmento de tiempo más extenso.

Los enfoques multi-instancia están en constante evolución. Algunos de los más usados son:

- Diversidad de densidades: Busca un punto en el espacio de las características que esté cerca de al menos una instancia en cada bolsa positiva y lejos de todas las instancias en las bolsas negativas.
- Algoritmos basados en SVM: Se modifican para manejar etiquetas de bolsa en vez de etiquetas de instancia.
- Algoritmos de emparejamiento de instancias: Estimación de la probabilidad de que cada instancia contribuya a la etiqueta de la bolsa y aplican métodos de ponderación.
- Deep Learning: Se adapta su arquitectura y función de pérdida para tratar con el esquema de etiquetado de multi-instancia.

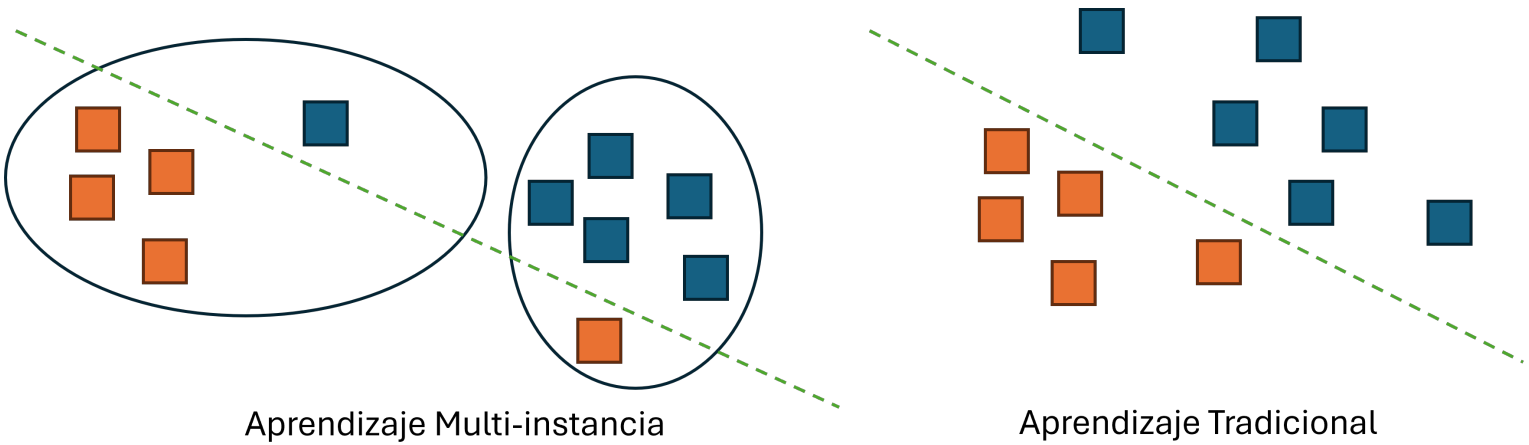


Figure: Método de SVM para Aprendizaje multi-instancia

- El aprendizaje multitarea es una técnica de aprendizaje automático que implica entrenar un algoritmo para abordar múltiples tareas utilizando una representación común para todas ellas.
- Múltiples aplicaciones: procesamiento del lenguaje natural, el reconocimiento de voz, visión artificial,el descubrimiento de fármacos etc..
- Enfoques en Redes neuronales:
  - Compartir parámetros duros: Se aplica compartiendo las capas ocultas entre todas las tareas, mientras se mantienen varias capas de salida específicas de la tarea.
  - Compartir parámetros suaves: Cada tarea tiene su propio modelo con sus propios parámetros pero, se regulariza la distancia entre los parámetros del modelo para fomentar que los parámetros sean similares.

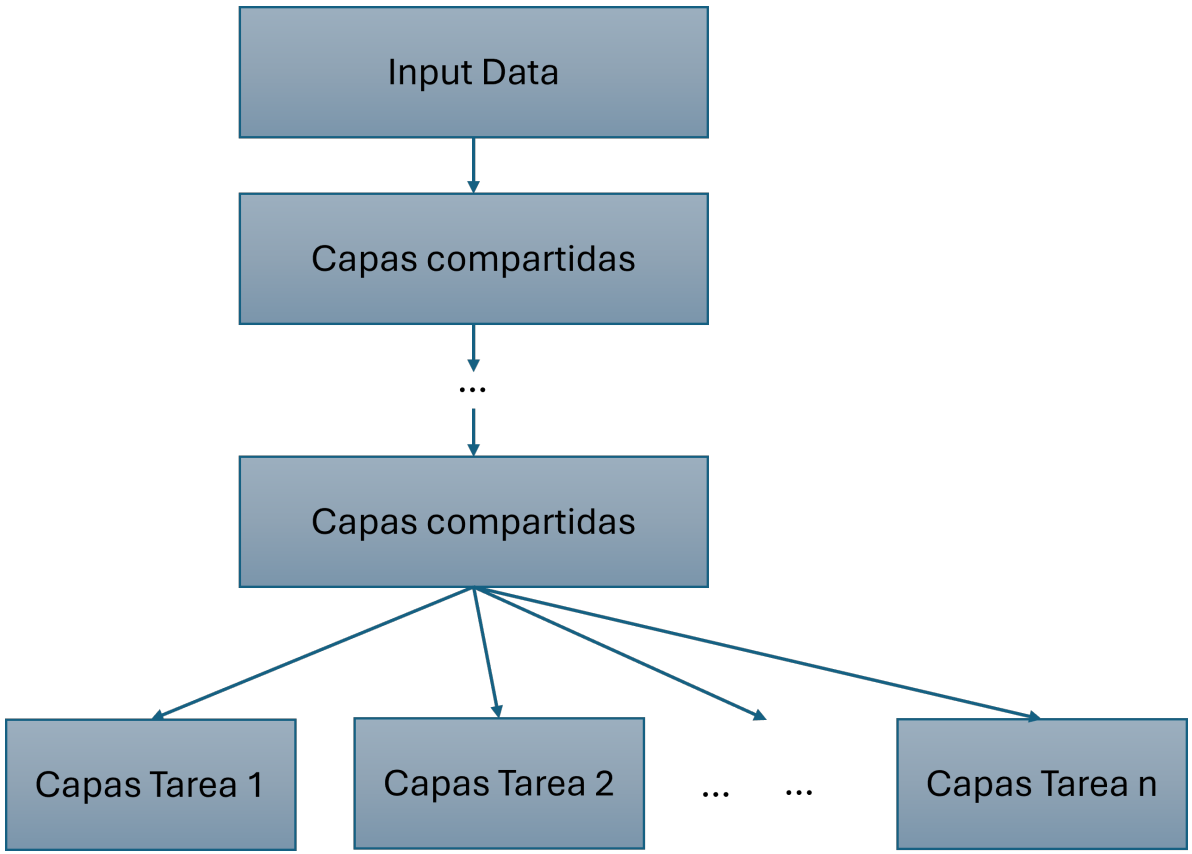


Figure: Estructura de técnica multitarea

- El aprendizaje incremental se refiere a cuando no tenemos todos los datos disponibles desde el principio.
- El modelo se va entrenando conforme los datos se van recibiendo. Sus beneficios son:
  - Flexibilidad: permite que el modelo se adapte y aprenda de nuevos datos a medida que estos se presentan, lo que le otorga una mayor flexibilidad.
  - Actualización continua: el modelo puede actualizarse y mejorarse en cualquier momento, sin necesidad de ser entrenado desde cero.
  - Eficiencia en el uso de recursos: al trabajar con lotes de datos más pequeños, el aprendizaje incremental optimiza el uso de recursos computacionales, evitando la necesidad de entrenar con todo el conjunto de datos.
  - Adaptabilidad: los modelos de aprendizaje incremental son altamente adaptables y pueden mantenerse actualizados en entornos en constante evolución.

Enfoques de aprendizaje incremental

- Un enfoque común es el uso de métodos de conjunto, donde se entrenan múltiples modelos en diferentes subconjuntos de datos y sus predicciones se combinan para mejorar la precisión general.
- Redes neuronales con memoria aumentada, que pueden almacenar y recuperar modelos pasados.
- Enfoque de transfer learning que permite mejorar el desempeño en tareas relacionadas, respaldando aún más el proceso de aprendizaje incremental.

Problemas:

- Un modelo puede perder información previamente aprendida cuando se expone a nuevos datos, esto se puede solventar revisando periódicamente datos pasados.
- La distribución de datos cambia con el tiempo, lo que requiere que los modelos se adapten rápidamente para mantener la precisión y relevancia.

- En el aprendizaje en línea, el modelo se entrena de manera incremental con cada nueva muestra que se recibe, o en grupos pequeños de muestras conocidos como mini-batches.
- Las principales características del aprendizaje online:
  - Aprendizaje Secuencial: Los datos se procesan y aprenden en orden secuencial a medida que se van disponiendo.
  - Consumo Mínimo de Recursos: Los modelos de aprendizaje en línea requieren recursos computacionales mínimos para actualizarse e incorporar nuevos datos, lo que los hace adecuados para entornos con limitaciones de recursos.
  - Actualizaciones Adaptativas del Modelo: Los parámetros del modelo se actualizan continuamente en función de los datos entrantes, permitiendo ajustes en tiempo real para optimizar la precisión predictiva y el rendimiento.

- Las técnicas del aprendizaje online se centran en minimizar el error de predicción para la siguiente instancia basándose en los datos vistos anteriormente.
- Algunos de los algoritmos más utilizados son el Ascenso Gradiente Estocástico incremental, los algoritmos Pasivo-Agresivos y el Perceptrón.
- El aprendizaje online siempre es aprendizaje incremental, pero el aprendizaje incremental no tiene porque ser online.
- Ejemplos: Detección de fraude de tarjetas, cambios de precios dinámicos en e-commerce, mantenimiento de infraestrcuturas en tiempo real, etc.



- El aprendizaje correcto probablemente aproximado (PAC) es un marco bajo el cual se probaron numerosos resultados en teoría de aprendizaje, y presenta los siguientes supuestos:
  - Los conjuntos de entrenamiento y de prueba siguen la misma distribución.
  - Los ejemplos de entrenamiento son escogidos de forma independiente
- En este tipo de aprendizaje busca seleccionar una función de generalización (llamada hipótesis) de una determinada clase de funciones posibles. El objetivo es que, con alta probabilidad (la parte ”probable”), la función seleccionada tenga un error de generalización bajo (la parte ”aproximadamente correcta”).
- Además, la función a seleccionar debe de ser eficientes (requisitos de tiempo y espacio limitados.
- El paradigma PAC tiene gran interés teórico, aunque su aplicación practica es bastante limitada.

Otros tipos de Aprendizaje
Aprendizaje extremo

- El aprendizaje extremo (ELM - maquinas de aprendizaje extremo) se basa en redes de neuronas artificiales con una sola capa oculta, conectada con pesos aleatorios a la capa de entrada y en la que solo se entrenan los pesos que la conectan con la capa de salida mediante un algoritmo de mínimos cuadrados.
- La teoría de las EML muestra que el valor del peso de esta capa oculta no necesita ser sintonizado y, por lo tanto, independiente de los datos de entrenamiento.
- En ELM los nodos ocultos se seleccionan aleatoriamente y los nodos de salida se determinan mediante un proceso de regresión lineal que minimiza el error de entrenamiento
- Su funcionamiento se basa en: 1) estudios teóricos que garantizan el que una red de tipo "Single-hidden Layer Feedforward Networks" mantiene sus capacidades de aproximación universal y clasificación universal, incluso si sus pesos ocultos son seleccionados aleatoriamente y 2) la teoría de Barlett (1998), según la cual entre menor es el error de entrenamiento y la salida de los pesos mejor tiende a ser la generalización.

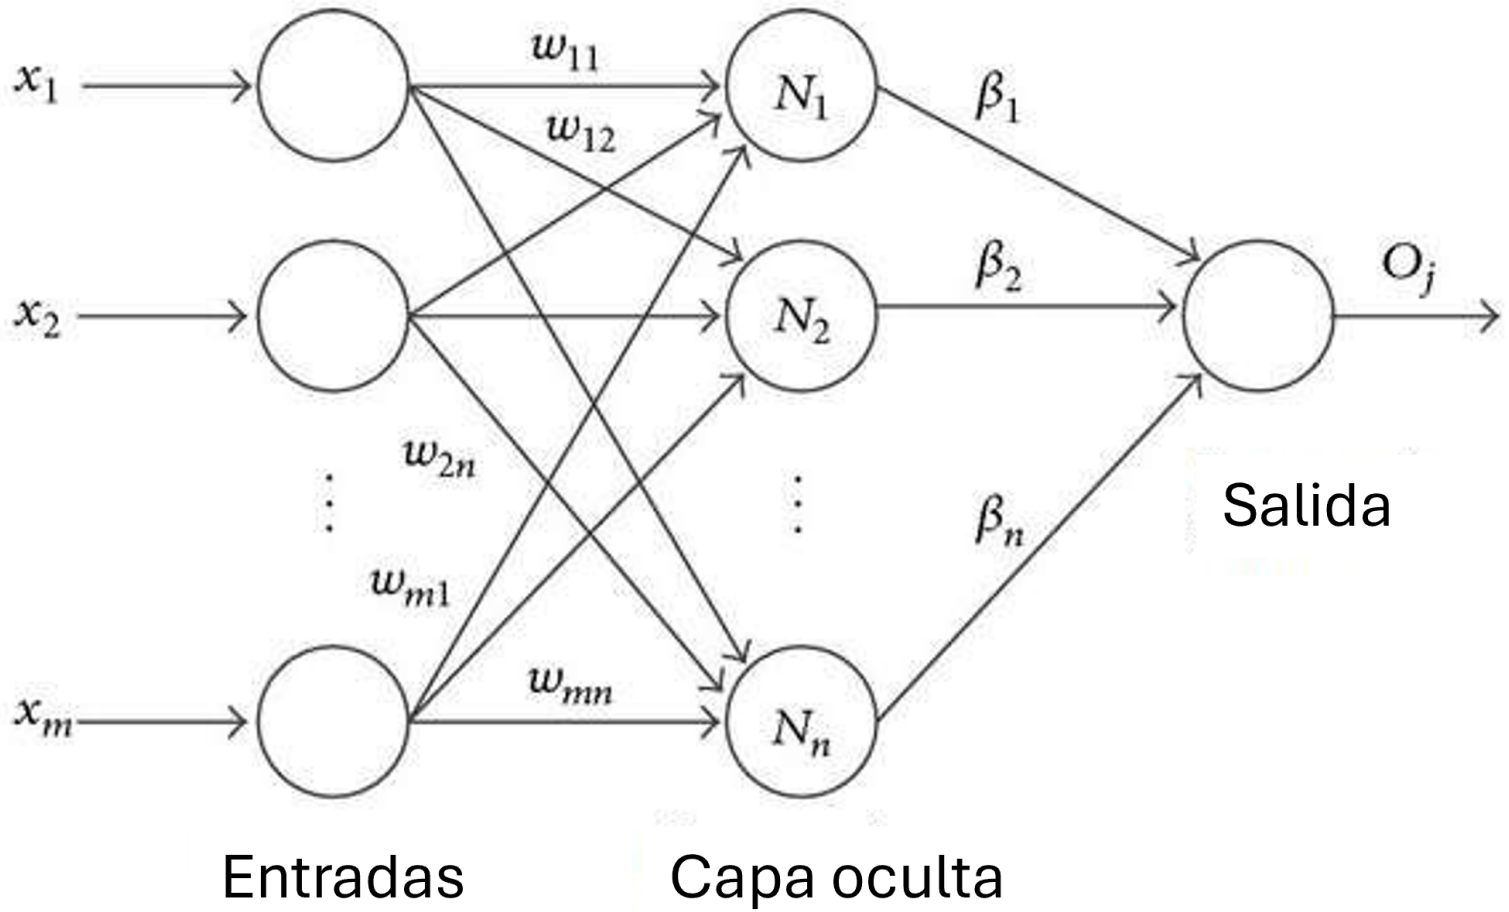


Figure: Esquema de una técnica de apredizaje extremo

- El aprendizaje por refuerzo es una técnica donde un agente informático aprende a realizar una tarea mediante interacciones repetidas de prueba y error en un entorno dinámico. Este enfoque permite que el agente tome decisiones que optimizan una métrica de recompensa asociada con la tarea, sin intervención humana y sin estar programado de manera explícita para llevar a cabo dicha tarea.
- El aprendizaje por refuerzo genera estrategias de forma automática, entre otras aplicaciones, que permiten el mantenimiento predictivo y la personalización de las experiencias del cliente.
- El sistema se encarga de explotar los datos, analizando las estrategias que han sido efectivas en el pasado y replicándolas cuando surgen situaciones similares en el futuro.
- El sistema explora nuevas acciones o estrategias, evaluando su efectividad para mejorar las anteriores y prepararse para nuevos escenarios.

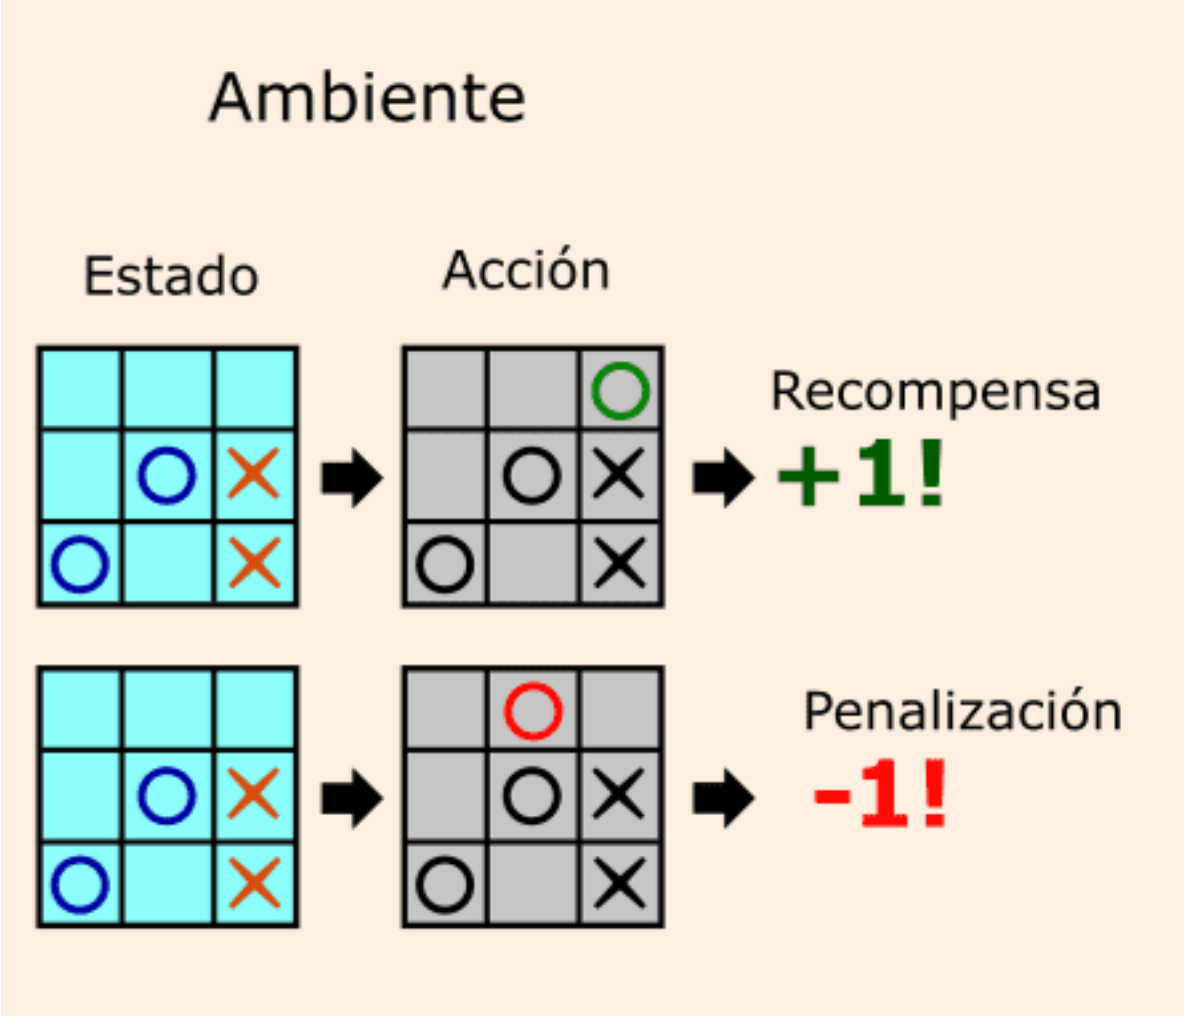


Figure: Ejemplo de aprendizaje por refuerzo

Algunas técnicas de aprendizaje por refuerzo::

- Q-Learning: Esta técnica aprende un valor Q para cada par estado-acción. El valor Q representa la recompensa futura esperada de realizar una acción específica en un estado particular. El agente puede entonces elegir la acción con el mayor valor Q para maximizar su recompensa a largo plazo.
- SARSA (State-Action-Reward-State-Action): Esta técnica es similar al Q-learning, pero aprende una función de valor para cada par estado-acción. Actualiza el valor en función de la recompensa recibida tras realizar una acción y el siguiente estado observado.
- Métodos de gradiente de políticas: Estas técnica aprenden directamente la función de política, que mapea estados a acciones. Utilizan gradientes para actualizar la política en la dirección que se espera conduzca a mayores recompensas.
- Deep Q-Networks (DQN): Estas técnicas combinan Q-learning con redes neuronales profundas para manejar espacios de estado de alta dimensión, que a menudo se encuentran en entornos complejos como los videojuegos.

- El aprendizaje federado, tambien llamado aprendizaje colaborativo, se presenta como una solución a las crecientes inquietudes sobre la seguridad y la privacidad de los datos, permitiendo a las organizaciones utilizar IA sin poner en riesgo la confidencialidad de la información.
- El aprendizaje federado hace posible que los algoritmos de IA obtengan experiencia a partir de una amplia gama de datos ubicados en diferentes sitios.
- El enfoque permite que varias organizaciones colaboren en el desarrollo de modelos, pero sin necesidad de compartir directamente datos.
- Los modelos federados se entrenan en su localización original y luego se agregan en un servidor central para mejorar un modelo global.
- La arquitectura descentralizada no solo respeta la privacidad de los datos, sino que también capitaliza la capacidad computacional distribuida, generando una sinergia entre privacidad y eficiencia.
- Los frameworks de aprendizaje federado incluyen bibliotecas y protocolos que facilitan la comunicación entre los nodos y el servidor central, asegurando una sincronización efectiva durante el proceso de entrenamiento.

- Algunas técnicas de aprendizaje federado:
  - TensorFlow Federated es un framework de código abierto para el aprendizaje federado. Permite implementar algoritmos de aprendizaje federado, permitiendo la ejecución en una amplia gama de escenarios. Por ejemplo, se puede usar para mejorar modelos de IA basados en datos generados en dispositivos móviles sin acceder directamente a esos datos.
  - OpenFL es otro framework que facilita la creación y evaluación de modelos de aprendizaje federado. Con OpenFL, los desarrolladores pueden definir y entrenar modelos federados, promoviendo una colaboración efectiva entre diversas partes sin necesidad de compartir datos directamente.
  - IBM Federated Learning ofrece una plataforma sólida para el entrenamiento de modelos de IA en datos distribuidos. Proporciona un entorno seguro y escalable que permite a las empresas utilizar datos distribuidos para entrenar modelos de IA, preservando la privacidad de la información. También incluye características avanzadas como la gestión de modelos, la supervisión del rendimiento y soporte para diversos algoritmos de aprendizaje federado.

- El aprendizaje inductivo, también conocido como aprendizaje por descubrimiento, es un proceso en el que el aprendiz descubre reglas al observar ejemplos.
- Una de las aplicaciones del aprendizaje inductivo en la IA es la evaluación del riesgo crediticio. El objetivo de la evaluación del riesgo crediticio es predecir la probabilidad de que una persona sea incapaz de devolver un préstamo. Al examinar los registros financieros de un prestatario y otros factores importantes, los prestamistas pueden utilizar la evaluación del riesgo crediticio para tomar decisiones informadas sobre si ofrecer o no un crédito y en qué condiciones.

- La inferencia deductiva utiliza reglas para razonar sobre nuevos datos y hacer predicciones o tomar decisiones basadas en esos datos.
- Un ejemplo de inferencia deductiva seria: Imagina que se quiere reclutar nuevos personajes para los vengadores. Tenemos las siguientes reglas:
  - Si la persona tiene fuerza sobrehumana y puede volar
  - Si una persona tiene un nivel de genio y tecnología avanzada
  - Si una persona tiene habilidades mágicas y está dispuesta a proteger la Tierra
- Para cada nuevo candidato el sistema deductivo aplicará estrictamente estas reglas predefinidas, realizando deducciones lógicas sobre la idoneidad de cada candidato para el equipo de Vengadores.

- La transducción se utiliza en el campo de la teoría del aprendizaje estadístico para referirse a la predicción de ejemplos específicos dados ejemplos específicos de un dominio.
- Se diferencia de la inducción, que implica aprender reglas generales a partir de ejemplos específicos, es decir, de lo específico a lo específico.
- A diferencia de la inducción, no se requiere generalización; en su lugar, se utilizan directamente ejemplos específicos. De hecho, esto puede ser un problema más simple de resolver que la inducción.

- El Transfer Learning consiste en transferir conocimientos adquiridos gracias a la resolución de problemas para resolver otros problemas.
- El Transfer Learning ha tenido un gran éxito con el crecimiento del Deep Learning.
- El transfer learning utiliza como punto de partida modelos pre-entrenados, para desarrollar rápidamente nuevos modelos eficaces y resolver problemas complejos de visión artificial o de Lenguaje Natural.

- Estrategias de transfer Learning:
  - Aprendizaje por transferencia inductiva: El campo de origen y el de destino son idénticos (con los mismos datos), pero las tareas de origen y destino son diferentes, aunque similares. La propuesta consiste en utilizar los modelos existentes para optimizar el ámbito de aplicación de los modelos posibles. Ejemplo: es posible utilizar un modelo entrenado para la detección de animales en imágenes para construir un modelo capaz de identificar perros.
  - Aprendizaje por transferencia no supervisada: Los campos de origen y destino son similares, aunque las tareas son distintas. Sin embargo, los datos en ambos campos no están etiquetados. Ejemplo: Hacer clúster con métodos sin etiquetar en un área y utilizar ese clúster base para aplicarlo a otra área.
  - Aprendizaje por transferencia transductiva: En este método, las tareas de origen y destino son similares, pero sus campos correspondientes difieren en términos de datos o distribuciones de probabilidad marginales. Ejemplo: Entreno un modelo de procesamiento de lenguaje natural con datos de un periódico y utilizo ese modelo para entrenar mensajes de las redes sociales.

- La clasificación sensible al costo considera que todos los errores no son igual de importantes.
- Las técnicas sensibles al coste tienen en cuenta el coste de una clasificación errónea. Su objetivo es minimizar el coste total generado por los modelos.
- Algunos ejemplos son:
  - Árboles de decisión sensibles al coste.
  - Regresión logística sensible al coste.
  - Máquinas de vectores de soporte sensibles al coste.

GRIDCV y RandomGridCV. son dos estrategias son totalmente válidas y generan buenos resultados, sobretodo cuando se tiene criterio para acotar el rango de búsqueda para buscar mejores parámetros.

- Estas estrategias tienen una carencia y es ambas crean modelos independientes y explorar el espacio de búsqueda de forma independiente, no tienen en cuenta la soluciones previas.
- Una alternativa es la búsqueda de hiperparámetros con métodos de optimización bayesiana.
- La optimización bayesiana de hiperparámetros implica construir un modelo probabilístico en el que el valor de la función objetivo corresponde a la métrica de validación del modelo, como el RMSE, AUC o precisión.
- Con la estrategia bayesiana, la búsqueda se orienta en cada iteración hacia las áreas de mayor interés. El objetivo final es minimizar el número de combinaciones de hiperparámetros que se evalúan, seleccionando únicamente los mejores candidatos.

Los paquetes rBayesianOptimization y ParBayesianOptimization.

Referencias I

L. Breiman. Bagging predictors. *Machine learning*, 24(2):123–140, 1996.

T. G. Dietterich. Ensemble methods in machine learning. In *International workshop on multiple classifier systems*, pages 1–15. Springer, 2000.

T. G. Dietterich and G. Bakiri. Solving multiclass learning problems via error-correcting output codes. *Journal of artificial intelligence research*, 2:263–286, 1994.

T. G. Dietterich, R. H. Lathrop, and T. Lozano-Pérez. Solving the multiple instance problem with axis-parallel rectangles. *Artificial intelligence*, 89 (1-2):31–71, 1997.

Y. Freund and R. E. Schapire. Experiments with a new boosting algorithm. In *Thirteenth International Conference on Machine Learning*. Citeseer, 1996.

J. Gama and P. Brazdil. Cascade generalization. *Machine learning*, 41(3): 315–343, 2000.

T. K. Ho. The random subspace method for constructing decision forests. *IEEE transactions on pattern analysis and machine intelligence*, 20(8): 832–844, 1998.

Referencias II

B. Parmanto, P. W. Munro, and H. R. Doyle. Improving committee diagnosis with resampling techniques. In *Advances in neural information processing systems*, pages 882–888, 1996.

J. R. Quinlan. Bagging, boosting, and c4. 5. In *Proceedings of the AAAI/IAAI'96, Vol. 1*, pages 725–730, 1996.

D. H. Wolpert. Stacked generalization. *Neural networks*, 5(2):241–259, 1992.