



Asignatura *Visión Artificial*

Orientaciones para los miniproyectos

Curso 2026/2027

Recursos orientativos: datasets públicos y modelos preentrenados

Esta guía es *orientativa y en absoluto debe considerarse limitativa*. Sirve únicamente para que veáis ejemplos que podrían considerarse perfectamente válidos, e inspiraros así en la elección de vuestro propio **dataset**, **tarea** (clasificación, detección, segmentación, pose, vídeo, AR, profundidad, reconstrucción 3D, visión-lenguaje, etc.) y/o **modelo base**. Cualquier recurso adicional con licencia adecuada y documentación clara podría considerarse igualmente válido para vuestros propios miniproyectos.

1. Ejemplos de datasets públicos

Clasificación de imágenes

- **ImageNet (ILSVRC)**: ~1,2M imágenes, 1,000 clases; estándar de preentrenamiento y evaluación. Normalmente se usa vía modelos preentrenados. *Sitio*: <https://image-net.org>
- **CIFAR-10/100**: 60k imágenes 32×32 (10/100 clases). Excelente para prototipos rápidos o entrenar desde cero. *Sitio*: <https://www.cs.toronto.edu/~kriz/cifar.html>
- **Open Images**: ~9M imágenes con etiquetas, cajas (15.7M) y máscaras; diversidad alta para tareas múltiples. *Sitio*: <https://storage.googleapis.com/openimages/web/index.html>

Detección y segmentación por instancia

- **MS COCO**: >330k imágenes, 80 clases, cajas, máscaras, *keypoints* y *captions*. Estándar para detección/segmentación. *Sitio*: <https://cocodataset.org>
- **PASCAL VOC 2007–2012**: ~11k imágenes, 20 clases; tamaño moderado, idóneo para proyectos con recursos limitados. *Sitio*: <http://host.robots.ox.ac.uk/pascal/VOC/>
- **Cityscapes**: 5k imágenes con anotación densa para segmentación urbana (+20k *coarse*). *Sitio*: <https://www.cityscapes-dataset.com>
- **KITTI**: conducción autónoma (detección 2D/3D, *tracking*, estéreo, LiDAR). Usar subconjuntos acotados. *Sitio*: <https://www.cvlibs.net/datasets/kitti/>

Segmentación semántica y pose

- **ADE20K**: ~25k imágenes, 150 clases (interior/exterior) para segmentación semántica general. *Sitio*: <https://groups.csail.mit.edu/vision/datasets/ADE20K/>
- **COCO (seg./keypoints)**: máscaras por instancia y 17 *keypoints* corporales (pose multi-persona). *Sitio*: <https://cocodataset.org>
- **LFW**: ~13k rostros con identidad; útil para verificación/identificación (más evaluación que entrenamiento, y siempre atendiendo a las consideraciones éticas de este tipo de datos). *Sitio*: <https://www.tensorflow.org/datasets/catalog/lfw>

Vídeo: acciones y seguimiento

- **UCF101**: 13,320 clips, 101 acciones; buen punto de entrada a reconocimiento de acciones. *Sitio*: <https://pytorch.org/vision/stable/generated/torchvision.datasets.UCF101.html>
- **MOT17**: secuencias con anotaciones para *tracking* multi-objeto (personas). Estándar para seguimiento. *Sitio*: <https://motchallenge.net/data/MOT17/>

Profundidad, RGB-D y estructura 3D

- **NYU Depth V2**: escenas interiores RGB-D, útil para estimación de profundidad, segmentación y análisis 3D a escala manejable. *Sitio*: https://cs.nyu.edu/~fergus/datasets/nyu_depth_v2.html
- **ScanNet**: reconstrucciones RGB-D de interiores con poses de cámara, geometría 3D y anotaciones semánticas; usar subconjuntos muy acotados. *Sitio*: <http://www.scan-net.org>

2. Ejemplos de modelos preentrenados recomendados

- **MediaPipe (Google)**: soluciones ligeras para cara, manos, *pose*, segmentación/fondo; idóneo para tiempo real. *Docs*: <https://ai.google.dev/edge/mediapipe>
- **Ultralytics YOLO**: detección, segmentación y pose con API Python sencilla; versiones como YOLOv8/YOLO11 y variantes desde móviles a alto rendimiento. *Docs*: <https://docs.ultralytics.com>
- **CLIP (OpenAI)**: espacio imagen–texto para *zero-shot* y *retrieval*; útil como clasificador sin *fine-tuning* o como *embedder*. *Repo*: <https://github.com/openai/CLIP>
- **SAM / SAM2 (Meta)**: segmentación por *prompts* en imágenes y, con SAM2, también en vídeo; útil para máscaras iniciales, propagación temporal o segmentación asistida. *SAM2*: <https://ai.meta.com/research/sam2/> *Repo*: <https://github.com/facebookresearch/sam2>
- **DINOv2 / DINOv3 (Meta)**: *embeddings* auto-supervisados robustos; muy útiles como extractores de características con clasificadores ligeros (SVM/MLP) o para comparación con descriptores clásicos. *Repo*: <https://github.com/facebookresearch/dinov3>
- **Depth Anything V2**: estimación de profundidad monocular con buena generalización, interesante para explorar mapas de profundidad, segmentación geométrica o preprocesado 3D. *Repo*: <https://github.com/DepthAnything/Depth-Anything-V2>
- **VGGT (Meta)**: modelo reciente para inferir cámaras, profundidad, nubes/mapas de puntos y estructura 3D de una escena desde una o varias vistas. *Repo*: <https://github.com/facebookresearch/vggt>
- **Detectron2 (Meta)**: framework con detectores/segmentadores (Mask/Faster R-CNN, RetinaNet) preentrenados en COCO. *Repo*: <https://github.com/facebookresearch/detectron2>
- **Modelos estándar en librerías**: ResNet, EfficientNet, ViT, etc. en *torchvision*/Keras, listos para *fine-tuning* o como extractores. *Docs*: <https://pytorch.org/vision/stable/models.html>
- **Hugging Face Model Hub**: repositorio amplio de modelos de visión y multimodales. *Sitio*: <https://huggingface.co/models>

3. Ejemplos de tareas

- **Clasificación específica**: DINOv2/DINOv3/CLIP como *embedder* + SVM/MLP; comparar con *fine-tuning* de ResNet/ViT.
- **Detección y conteo**: YOLO + NMS propio o analizado + filtros morfológicos; evaluar con mAP/F1 y casos de falso positivo/negativo.
- **Segmentación asistida**: SAM/SAM2 con *prompts* + refino por transformada de distancia/*watershed*; métricas IoU/Dice y, si procede, propagación en vídeo.
- **Visión–lenguaje**: CLIP o un VLM local para *zero-shot*, *retrieval* o descripción controlada sobre un repositorio de imágenes del dominio.
- **Profundidad y estructura 3D**: Depth Anything V2 o VGGT para estimar profundidad/cámaras/nubes de puntos, seguido de análisis geométrico, medición aproximada o visualización 3D.
- **AR y medición**: marcadores/plantilla (homografía y pose) + overlay 3D; activación condicionada por detección semántica.

Notas adicionales:

- Verificar siempre las condiciones de uso (aunque prácticamente nadie pone pegas a usos académicos como el nuestro).
- Muchos datasets/modelos ofrecen también APIs directas de descarga en `torchvision` / `tensorflow` / `keras` / `kaggle` / `huggingface`, o *frameworks* similares.
- Una sugerencia práctica sería también que, antes de descargar datasets voluminosos o modelos muy grandes, consideréis emplear subconjuntos filtrados, versiones ya preprocesadas o variantes ligeras, documentando los correspondientes *splits* (porciones del dataset), clases usadas, pesos empleados y técnicas de *data augmentation* utilizadas para intentar garantizar en la medida de lo posible la reproducibilidad de los resultados en entornos de cómputo no excesivamente exigentes.