

Visión artificial

Sesión 3. Matriz de cámara

Matemática Aplicada

Dept. Ingeniería y Tecnología de Computadores

Universidad de Murcia

Máster en Inteligencia Artificial

2026/2027






El Modelo de Cámara y la Matriz M

Estimación de M : Algoritmo DLT

Cálculo de parámetros a partir de M

El Modelo de Cámara y la Matriz M

- ▶ El modelo lineal de cámara tipo *pinhole* define la proyección de rayos desde una escena 3D a través de un centro óptico C hacia el plano de imagen π .
- ▶ Si situamos C en el origen mirando hacia el eje Z , un punto 3D (X, Y, Z) interseca el plano en $x = f \frac{X}{Z}, y = f \frac{Y}{Z}$.
- ▶ Esta transformación preserva rectas pero no ángulos ni paralelismo.





La ecuación anterior presupone que:

- ▶ El centro de la imagen está en el pixel $(0,0)$
- ▶ Los píxeles son cuadrados
- ▶ No hay distorsión de los píxeles

Esto no es cierto para todas las cámaras, por lo que hay que modificar esta matriz de proyección para tener en cuenta la configuración de la cámara

¿Por qué calibrar? La importancia de la matriz M



- ▶ La matriz de proyección M (de 3×4) define el comportamiento de la cámara.
- ▶ Relaciona de forma exacta las coordenadas 3D de la escena con los píxeles 2D de nuestro sensor.
- ▶ Calibrar la cámara es el proceso de estimar esta matriz M para separar lo que pertenece a la física de la lente (K) de lo que pertenece a su pose en el espacio (R, t)

¿Por qué calibrar? realidad aumentada



¿Cómo colocar un dinosaurio o un mueble virtual sobre una superficie usando el móvil?

- ▶ El motor gráfico (ej. Unity) debe proyectar el objeto virtual en la pantalla usando **exactamente la misma matriz M** que tiene la cámara física de tu móvil.
- ▶ Si M es incorrecta o desconocida, el objeto flotará en el vacío, se deformará o se "deslizará" al mover el móvil.
- ▶ Si M es exacta (calibrada), el mundo digital y el real se acoplan de forma sólida con una precisión geométrica milimétrica.




- ▶ Dependen únicamente de la construcción de la cámara.
- ▶ La matriz de calibración K posee 5 gdl :

$$K = \begin{bmatrix} f & s & o_x \\ 0 & fr & o_y \\ 0 & 0 & 1 \end{bmatrix}$$

- ▶ f : Distancia focal efectiva en píxeles.
- ▶ r : Relación de aspecto (*aspect ratio*).
- ▶ s : Sesgo o *skew* de los píxeles.
- ▶ (o_x, o_y) : Coordenadas del punto principal en la imagen.


Parámetros Intrínsecos: La Matriz K



$$\begin{bmatrix} f & 0 & 0 \\ 0 & f & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

1 *gdl*


Píxel cuadrado,
focal única,
pp centrado



$$\begin{bmatrix} f_x & 0 & 0 \\ 0 & f_y & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

2 *gdl*


Punto principal
centrado



$$\begin{bmatrix} f & 0 & o_x \\ 0 & f_r & o_y \\ 0 & 0 & 1 \end{bmatrix}$$

4 *gdl*

Píxel
rectangular



$$\begin{bmatrix} f & s & o_x \\ 0 & f_r & o_y \\ 0 & 0 & 1 \end{bmatrix}$$

5 *gdl*

Cámara
general

- complejidad (-parámetros)




+ expresividad (+parámetros)

Parámetros Extrínsecos: R y C

En general la cámara no tiene por qué estar en el origen ni apuntando en la dirección del eje Z

- ▶ Los parámetros extrínsecos definen el cambio del sistema de coordenadas del mundo al sistema de la cámara.
- ▶ Poseen 6 grados de libertad en total.
- ▶ **Centro Óptico (C):** 3 gdl para la traslación espacial.
- ▶ **Rotación (R):** 3 gdl definidos por los ángulos pan, tilt y roll. Es una matriz ortogonal que cumple $R \cdot R^T = I$.





La proyección completa de la escena 3D al plano de imagen se representa mediante la matriz de cámara M de dimensiones 3×4 . Es homogénea, por lo que tiene 11 grados de libertad (gdl) independientes.

La matriz M se forma combinando tres matrices:

$$M = K \cdot R \cdot [I | -C] = K [R|t]$$


Donde el vector de traslación se define como $t = -RC$.

Componentes:

- ▶ K : Matriz triangular superior de parámetros intrínsecos (3×3).
- ▶ R : Matriz de rotación ortogonal (3×3).
- ▶ C : Posición del centro óptico de la cámara (3×1).

Estimación de M: Algoritmo DLT

- **Objetivo:** Dadas coordenadas de puntos 3D conocidos y sus proyecciones 2D en la imagen, queremos estimar la matriz M .
- Conociendo M , podremos extraer la pose de la cámara, los intrínsecos y realizar realidad aumentada.
- Dado que M tiene 11 gdl, requerimos un mínimo de 5.5 correspondencias 2D-3D (en la práctica, al menos 6 puntos).





Para calcular la matriz M podemos usar el algoritmo DLT que ya vimos para calcular homografías

- ▶ Cada correspondencia entre un punto 3D $\mathbf{X}$ y un punto 2D en la imagen $\mathbf{x} = (p, q, 1)^T$ impone una restricción: $M \cdot \mathbf{X} = \lambda \mathbf{x}$.
- ▶ Para eliminar la escala desconocida λ , aplicamos el producto vectorial algebraicamente:

$$\mathbf{x}^T \times (M \cdot \mathbf{X}) = \mathbf{0}$$

- ▶ Esto genera un sistema con dos ecuaciones lineales independientes por cada par de puntos analizado.




- ▶ Al apilar las ecuaciones de todos los puntos $N \geq 6$, construimos una matriz de coeficientes A de tamaño $2N \times 12$.
- ▶ El objetivo es encontrar los 12 coeficientes m_i de la matriz M , formulando un sistema homogéneo:

$$A \cdot \mathbf{m} = 0$$

- ▶ Como vimos este tipo de sistemas pueden resolverse usando SVD.

Ejemplo de uso de DLT



Coords 3D
(unids. = 4x53 mm)

Coords 2D
(unids. píxel)

$$\begin{pmatrix} x & y & z \\ 0 & 2 & -1 \\ 0 & 1 & -1 \\ 0 & 0 & -1 \\ 0 & 2 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \\ 1 & 2 & 0 \\ 1 & 1 & 0 \\ 1 & 0 & 0 \end{pmatrix} \rightarrow \begin{pmatrix} p & q \\ -123 & 2 \\ -107 & -47 \\ -87 & -117 \\ -81 & 89 \\ -57 & 51 \\ -23 & -5 \\ 5 & 58 \\ 40 & 18 \\ 91 & -40 \end{pmatrix}$$

Redefinición coords imagen
(0,0) en centro de imagen

Para nuestro ejemplo, la matriz de coeficientes (A) del sistema homogéneo completo (usando las 9 correspondencias disponibles) sería:

$$\begin{bmatrix} 0 & 0 & 0 & 0 & 0 & -2 & 1 & -1 & 0 & 4 & -2 & 2 \\ 0 & 2 & -1 & 1 & 0 & 0 & 0 & 0 & 0 & 246 & -123 & 123 \\ 0 & -4 & 2 & -2 & 0 & -246 & 123 & -123 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & -1 & 1 & -1 & 0 & -47 & 47 & -47 \\ 0 & 1 & -1 & 1 & 0 & 0 & 0 & 0 & 0 & 107 & -107 & 107 \\ 0 & 47 & -47 & 47 & 0 & -107 & 107 & -107 & 0 & 0 & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & 0 & 0 & -1 & 0 & 0 & -1 & -40 & 0 & 0 & -40 \\ 1 & 0 & 0 & 1 & 0 & 0 & 0 & 0 & -91 & 0 & 0 & -91 \\ 40 & 0 & 0 & 40 & 91 & 0 & 0 & 91 & 0 & 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} m_1 \\ m_2 \\ \vdots \\ m_{12} \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

(Se muestran sólo las líneas correspondientes a las correspondencias 1, 2 y 9)



Al igual que ocurría en el cálculo de homografías debemos tener en cuenta que:

- ▶ Antes de construir la matriz A , es crucial pre-transformar los puntos 2D y 3D para evitar inestabilidad e imprecisión numérica.
- ▶ Consiste en trasladar el centroide de los puntos al origen $(0, 0, 0)$ y escalar las distancias para que la distancia media sea cercana a la unidad.
- ▶ Tras estimar la matriz con datos normalizados M' , aplicamos una “desnormalización” multiplicando por las matrices de pre-transformación: $M = T_{2D}^{-1} \cdot M' \cdot T_{3D}$.

Cálculo de parámetros a partir de M



Como hemos visto, la matriz M se forma combinando tres matrices:

$$M = K \cdot R \cdot [I | -C] = K [R | t]$$

Donde el vector de traslación se define como $t = -RC$.

Componentes:

- ▶ K : Matriz triangular superior de parámetros intrínsecos (3×3).
- ▶ R : Matriz de rotación ortogonal (3×3).
- ▶ C : Posición del centro óptico de la cámara (3×1).

Nuestro objetivo es, una vez calculada M , calcular K , R y C

¿Por qué descomponer M ? óptica vs. pose



La matriz $\mathbf{M}$ de 3×4 es una "caja negra" que mezcla toda la información. En la práctica, trabajar con $\mathbf{M}$ como un bloque indivisible puede ser inviable.

Ventajas de Conocer K , R y C

- ▶ En robótica o SLAM, la lente ($\mathbf{K}$) se calibra una sola vez en fábrica. Al movernos, solo monitorizamos los cambios en la pose ($\mathbf{R}$, $\mathbf{C}$).
- ▶ Motores como Unity definen la óptica ($\mathbf{K}$) por un lado (para el campo de visión de la cámara virtual) y la pose ($\mathbf{R}$, $\mathbf{t}$) por otro (para situar el holograma).
- ▶ Para conseguir una reconstrucción en estéreo (3D), para triangular un punto en el espacio usando dos cámaras, necesitamos conocer la distancia física real entre sus centros ópticos $\mathbf{C}_1$ y $\mathbf{C}_2$.

Obtención del centro óptico C (SVD)



- ▶ Por definición geométrica, el centro óptico proyecta al origen $(0, 0, 0)$ en el plano de imagen.
- ▶ Algebraicamente, esto significa que el vector homogéneo $C_{4 \times 1}$ es el espacio nulo de la matriz de cámara: $M \cdot C = 0$.
- ▶ Volvemos a usar la SVD, esta vez sobre la matriz M .
- ▶ El centro de la cámara C es el último vector singular (la última columna de V en la SVD de M).



- ▶ Sabemos que la submatriz izquierda 3×3 de la matriz de cámara cumple: $M_{1:3} = K \cdot R$.
- ▶ Necesitamos separar estas matrices, sabiendo que K es triangular superior y R es ortogonal.
- ▶ Por tanto, nuestro objetivo es descomponer una matriz como producto de dos matrices
 - ▶ Una matriz triangular superior
 - ▶ Una matriz ortogonal



Cualquier matriz real cuadrada A de $n \times n$ se puede descomponer como el producto $A = Q \cdot R$ de una matriz ortogonal Q y una matriz triangular superior R :

- ▶ **La matriz Q (ortogonal):**
 - ▶ Cumple la propiedad fundamental: $Q^T Q = I \implies Q^{-1} = Q^T$.
 - ▶ Geométricamente, representa una rotación pura (quizás con una simetría).
- ▶ **La matriz R (triangular superior):**
 - ▶ Es una matriz que contiene únicamente ceros por debajo de la diagonal principal.
- ▶ **¿Cómo se calcula?:** Es la generalización matricial del proceso de **ortogonalización de Gram-Schmidt**. Computacionalmente se resuelve con métodos más estables.



- ▶ **¿Por qué no sirve QR ?** La descomposición estándar $A = QR$ factoriza una matriz colocando la componente ortogonal a la **izquierda** y la triangular a la **derecha**.
- ▶ Podemos calcular la descomposición RQ utilizando la descomposición QR y la matriz de permutación J (que revierte el orden de filas y columnas):

$$J = \begin{bmatrix} 0 & 0 & 1 \\ 0 & 1 & 0 \\ 1 & 0 & 0 \end{bmatrix} \quad (1)$$



La factorización RQ no es única. Debemos imponer restricciones basadas en la **física del sensor**:

1. **Normalización de escala:** Forzamos a que el elemento de la esquina inferior derecha de la matriz K sea exactamente 1
2. **Focales estrictamente positivas ($\text{diag}(K) > 0$):** Si alguna focal es negativa cambiaremos a la vez el signo de la columna correspondiente de K y de la fila de R
3. **Evitar reflexiones en la rotación ($\det(R) = +1$):** Si el determinante es -1 (lo que representaría una reflexión física imposible) se cambia el signo de M



Para aislar los parámetros intrínsecos y la rotación:

1. Extraemos la submatriz $M_{3 \times 3}$ de M .
2. Aplicamos la descomposición RQ: $M_{3 \times 3} = R_{rq} \cdot Q_{rq}$.
3. Identificamos directamente:

$$\mathbf{K} = \mathbf{R}_{rq}$$

$$\mathbf{R} = \mathbf{Q}_{rq}$$

Aplicación: realidad aumentada

Una vez calculada M

- ▶ Es como tener acceso a un sistema de referencia virtual dentro de la escena que estamos viendo
- ▶ Usando ese sistema podemos incluir cualquier objeto 3D

